



地图综合图卷积神经网络点群简化方法

肖天元^{1,2}, 艾廷华^{1,2}, 余华飞^{1,2}, 杨 敏^{1,2}, 刘鹏程³

1. 武汉大学资源与环境科学学院, 湖北 武汉 430079;
2. 地理信息系统教育部重点实验室, 湖北 武汉 430079;
3. 华中师范大学城市与环境科学学院, 湖北 武汉 430079

收稿日期: 2022-10-14; 修回日期: 2023-07-27

中图分类号: P208

文献标识码: A

文章编号: 1001-1595(2024)01-0158-15

基金项目: 国家自然科学基金(42071455; 42071450)

第一作者简介: 肖天元(1995—), 男, 博士生, 研究方向为地图综合。 E-mail: xiaotianyuan@whu.edu.cn

通信作者: 艾廷华 E-mail: tinghuaai@whu.edu.cn

摘 要:地图综合是一个多因素影响的复杂决策过程, 针对不同场景判断下的综合算子优化选择常规上通过基于规则的方法实施。顾及不同特殊条件影响, 这些地图综合规则需要“打补丁”, 导致地图综合规则体系越来越复杂, 从而失去普适性。人工智能技术下的数据驱动综合方案通过机器学习提取典型案例中隐含的综合规则, 并迁移到新的数据场景, 为处理特殊规则下的地图综合提供了一种思路。本文引入深度学习技术, 采用领域知识与数据驱动相结合的策略, 提出了一种基于图卷积神经网络的点群自动综合方法。本文方法通过样本训练与深度学习获取不同数据场景下的地图综合知识, 同时融入既有规则进行引导, 可以更有效地向人工地图综合结果的目标迈进。首先, 构建 Delaunay 三角网, 在点群之间建立空间邻域关系, 并根据地理空间上下文关联、空间异质性等领域知识计算各个点的特征信息, 构造点群的特征向量。其次, 引入拓扑自适应图卷积神经网络, 构建点群数据自动综合网络模型。试验表明本文方法在局部区域与整体地图上均可以保持原始点群的各项特征, 体现在相对数量保持、上下文特征继承、属性特征一致方面均有良好的表达效果。

关键词: 地图综合; 点群; Delaunay 三角网; 图卷积神经网络; 数据驱动

长期以来, 地图自动综合是地理信息科学领域中的重要问题^[1]。在地图比例尺由大到小的转变过程中, 地图符号的冲突和拥挤不可避免, 目标的选取与化简成为解决问题的基本策略, 其中包含复杂的决策过程。传统上采用基于规则的方法, 以空间领域知识为基准, 尝试总结各种规则应对不同数据场景下的地图综合判断, 同时建立多种度量指标描述尺度变换中目标的重要性支持选取决策。然而, 由于某些特殊条件的存在, 往往使得选取规则要不断“打补丁”, 需要将多种判断结合, 从而导致地图综合规则体系越来越复杂。在难以穷尽不同特殊

条件建立地图综合规则体系的背景下, 寻求新的地图综合思路很有必要。另一方面, 地图领域存在大量既有系列比例尺产品, 选取典型地区建立样本, 通过案例学习获得综合规则知识, 运用数据驱动方法建立地图综合过程, 人工智能方法在地图综合领域应用的条件是具备的。

在人工智能时代, 自深度学习概念被提出以来^[2], 由于其良好的性能及无须先验知识的特性, 这种基于数据驱动的技术可以很好地避免人为设定的条件及阈值对结果的影响, 目前正在越来越多的决策任务中应用, 以取代基于规则的方法。例如,

引文格式: 肖天元, 艾廷华, 余华飞, 等. 地图综合图卷积神经网络点群简化方法[J]. 测绘学报, 2024, 53(1): 158-172. DOI: 10.11947/j. AGCS. 2024. 20220584.
XIAO Tianyuan, AI Tinghua, YU Huafei, et al. A point cluster simplification approach of graph convolutional neural network for map generalization[J]. Acta Geodaetica et Cartographica Sinica, 2024, 53(1): 158-172. DOI: 10.11947/j. AGCS. 2024. 20220584.

在遥感领域中,通过深度学习方法可以从不同的神经元或层结构自动在不同的图像数据中提取特征^[3-4],并通过进一步操作实现对遥感影像的去噪^[5]、增强^[6]及分类^[7]等。然而,与遥感影像数据的处理相比,地图综合在人工智能应用中遇到了一些挑战。对于矢量化的地理空间数据而言,由于其数据组织方式并不是阵列式的,属于非规则结构,难以直接应用诸如卷积模型(convolutional neural network, CNN)这种依靠二维卷积层来对图像空间信息进行提取的模式,且并不适用于矢量数据。因此,传统的深度学习方法很难广泛应用在地理信息科学领域中。同时矢量数据表达的样本库建立有强结构性,与影像数据也存在区别,而且具有多尺度特征,这些都加大了矢量地图综合应用深度学习的难度^[8]。

深度学习领域的后起之秀图神经网络的诞生,使得用深度学习技术处理空间矢量数据成为可能^[9],因为大多数地理矢量数据都可以抽象化为GCN(graph convolutional network)可处理的图结构数据模式^[8]。相比于纯数据驱动的学习模式,对于地理信息科学领域而言,领域知识与数据驱动相结合的混合智能方法可能更适合处理蕴含丰富空间信息的矢量数据。一方面,地图数据是由结构化的地理实体组成的,其图结构中的节点和边是独立的,分别对应着空间实体和相互关系。图中的节点代表地理实体,边则对应节点之间的邻接关系,可以加载诸如重要程度、上下文特征等信息。另一方面,这些信息可以作为向量进行存储并输入到模型中,这也意味着地图综合中的领域知识可以被抽象化为特征向量来驱动GCN模型。目前大多数基于此的研究都专注于线要素与面要素,包括交通流量预测^[10-12]、道路模式识别^[13-14]、河网模式识别^[15-16],以及建筑群模式识别等^[17-21]。此类研究主要集中在对空间数据的“静态模式”识别,而对地图综合这种“动态行为”决策的研究则相对较少。地图综合的行为决策是基于特定的场景条件,在众多尺度变换算子中选取最优的,并在模式识别的基础上伴随着的行为决策。以点群综合为例,由于点状要素是地理实体的高度抽象化表示且其维度为零,因此地图综合决策主要集中在点的选取上,省掉了图形形态的化简。目前,大多数学者提出的方法从点要素的坐标位置入手,构造衡量其可保留程度的量化指标作为控制参数,从而实现对点群的化简。例如,文献[22]提出的沉降间距比与分布系数,文献[23]提出的局部密度与相对局部密度,文献[24—27]分

别在直角坐标系与极坐标系下构建的圆增长相关系数,都是较为常用的控制参数。另一类方法基于点要素的邻域特征从点的空间邻近关系入手,在综合过程中循环构造Delaunay三角网,并提取Voronoi图面积作为控制参数实现了点群的自动综合^[28]。文献[29]在此基础上对算法进行了改进。除此类空间算法以外,也有一些研究采用其他算法实现了点群综合:文献[30—31]将遗传算法引入到点群综合问题中,文献[32]提出了一种随机生成点群并连续近似迭代算法,文献[33—35]采用的机器学习方法也较好地解决了相关的综合问题。本文尝试将传统的地理空间知识与深度学习相结合,综合考虑两种决策过程,通过构建Delaunay三角网提取点群的虚拟图结构,并分别从空间邻近关系、上下文及要素内部属性3个方面提取参数作为输入特征,最后引入拓扑自适应图神经网络(TAGCN)^[36],设计一种针对点群数据综合的决策模型,实现了群点的综合选取。

1 图结构下的点群特征分析

点群目标具有聚集特征,在地理学第一定律作用下表现出空间格局的自相似性与异质性特征。点群结构的分布中心、分布轴线、分布边界与分布密度从不同维度上刻画了群结构的几何性质^[28]。为了从整体上系统描述点群特征,可采用图结构的几何构造对其建模,图的节点、边分别表达点实体及邻域关系,衍生出的密度、走势、范围等信息特征在高层次上描述点群。同时,图结构的建立为图卷学习模型GCN的应用提供了数据基础,GCN就是基于图结构的。

1.1 点群图结构构建

为显式地表达点群目标间的联系,依据就近原则建立点群图结构。由于Delaunay三角网具有最邻近连接的特点,一般采用Delaunay三角网构造几何模型^[37-39]。为获得逼近真实分布范围的点群图,剥皮算法^[28]是一种有效的解决方案,如图1(b)所示,由原始点群直接生成的Delaunay三角网包含一些由红色线段表示的狭长边,通过剥皮算法将这些狭长边识别并删除后所剩下黑色线段的集合即为该点群可运用到GCN模型中去的抽象图结构。


1.2 特征提取

1.2.1 几何特征

在地图综合过程中,空间邻接关系是衡量地图

中每个单独要素重要程度的有效评估指标^[33]。在空间分析中,地理学第一定律所体现的空间自相关特征,以及不同区域下的空间异质性等领域知识,也蕴含在点群分布的几何邻近性指标中。为将点

群分布的地理学领域知识引入综合模型,在数据准备特征表达中本研究先定义如下特征指标,并设计相应几何计算方法实现其度量。



(a) 原始点群 (b) Delaunay三角网构建

图1 点群的 Delaunay 三角网构建过程

Fig. 1 The process of Delaunay triangulation construction for point cluster

特征 1: 点的 Delaunay 构造边数量 N_D 。点 V 参与连接的 Delaunay 边与其相邻点的个数一致, 可通过计算点群图结构的度矩阵获得, 表示为 Degree(V)。该参数可有效反映该点的拓扑关系并衡量其在局部区域内的重要程度。

特征 2: 点的 Delaunay 构造边平均长度 L_{Mean} 。在与点 V 相连接 n 条 Delaunay 边中, 第 i 条的长度记为 d_i , 则平均长度可表示为 $\sum_{i=1}^n d_i / n$ 。

特征 3: 点连接的最短 Delaunay 构造边长度 L_{Min} 。表示为 $\{d_j \mid \forall d \in \{d_j\}_{j=1}^n, d_j \leq d\}$ 。

特征 4: 点的 Voronoi 图面积 S_V 。对点群的 Delaunay 三角网构建其对偶图, 点 V 所在多边形 Polygon_V 的面积即为所求。该特征可准确地反映并量化点群中各个点与周围部分区域的密度分布情况。

1.2.2 上下文特征

跨要素间的依存关系与上下文联系反映了地理现象间的互相关特征, 是地图综合中需要关注的重要领域知识与地理规则。点群化简中目标的选取应顾及相关其他要素的上下文影响, 包括道路、居住区、河流等。一般来说, 更靠近这类地物的点在综合过程中更不容易被删除。在本文中, 受使用的样本数据特性影响, 选择道路交叉口作为上下文影响因素, 通常情况下, 越靠近道路交叉口的点更容易在地图综合的过程中被保留。本文模型中提取的上下文特征包括如下 2 个特征。

特征 5: 与点的相邻道路交叉口的数量 N_{ad} 。点邻近的道路交叉口越多, 则表明该点包含更丰富的上下文信息。

特征 6: 与点相距最近的道路交叉口距离 ad_{Min} 。在与点 V 相邻近的 n 个道路交叉口中, 第 i 条的长度记为 ad_i , 则最近道路交叉口距离表示为 $\{ad_j \mid \forall ad \in \{ad_j\}_{j=1}^n, ad_j \leq ad\}$ 。

1.2.3 属性特征

点的属性作为其蕴含的内部特征, 在点选取的重要性判断、语义层次分析上发挥重要作用。建筑物最小外接矩形方向 (SBRO) 的连续性也是综合过程中的影响因素之一, 如图 2(b)、(c) 所示, 两种化简策略对于点状要素来说都是可行的, 但是将点还原为建筑物时, 图 2(d) 中方案 1 的效果要明显优于方案 2。

在本文模型中提取的属性特征如下。

特征 7: 点所对应建筑物的最小外接矩形方向 θ_{SBRO} 。方向的度量方法如图 3 所示。

在获取点要素的全部 7 个特征后, 即可将其组合为该点的特征向量。

2 GCN 模型构建

2.1 图卷积神经网络

图神经网络把抽象为图结构数据的问题视为图中节点之间的连接和信息传播的问题, 对节点之间的

依赖关系进行建模,是处理图结构数据的有效手段。对于图结构 G 所构成的 Laplace 矩阵 L ,将其进行分解可得 $L=U\Lambda U^T$ 。其中 U 是以列向量为单位特征向量的矩阵, Λ 为 n 个特征值构成的对角阵。以 U^T 作为图傅里叶变换基,即可得到图卷积的表达式

$$(f * g)_G = U((U^T g) \odot (U^T f)) \quad (1)$$

式中, f 为图上的 n 维特征向量; g 为卷积核; $\odot$ 为哈达马积运算。对于第 ℓ 个隐藏层上的第 f 个卷积

核 $G_f^{[\ell]}$, 可通过多项式形式表示为

$$G_f^{[\ell]} = \sum_{k=0}^K g_{f,k}^{[\ell]} T_k(\tilde{\Lambda}) \quad (2)$$

式中,切比雪夫多项式 $T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x)$; $\{g_{f,k}^{[\ell]}\}_{k=0}^K$ 为多项式的系数向量; $\tilde{\Lambda}$ 为缩放后的特征向量矩阵。目前,由于卷积计算的运算成本较高,现有的研究大多采用切比雪夫多项式的一阶展开作为卷积核的近似值。




图 2 属性特征对综合结果的影响

Fig. 2 Influence of attribute features on generalization results

2.2 点群综合网络模型

对于点群所构成的图结构而言,由于 Delaunay 三角网的特性,距离较近的两个点可能并不会是彼此的一阶邻居,而是二阶或三阶邻居。根据地理学第一定律^[40],这类相距不远且并未连接的点仍会在空间上互相影响,因此,此类邻居在综合上仍是一个不应被忽略的影响因素。拓扑自适应图卷积网络(TAGCN)中的图卷积被严格定义为图邻接矩阵多项式的乘法,可以从高阶邻域获取特征,且该卷积不是近似值。所以,相比于传统的只保留一阶切比雪夫多项式的 GCN 模型而言,可以从更远处节点获取信息的 TAGCN 更适用于点群的自动综合。

在 TAGCN 卷积运算中,为避免线性近似,构造了一组大小为 $1 \sim K$ 的过滤器,超参数 K 为保留过滤器层的数量。以 $K=3$ 为例, K 阶过滤器在一组大小为 $1 \sim 3$ 的感知域上提取局部特征。受超参数的影响,输出特征 $y_f^{[\ell]}$ 为不同大小过滤器卷积结

果的加权和。其表达式为

$$y_f^{[\ell]}(i) = \sum_{k=1}^K \sum_{c=1}^{C_\ell} \sum_j g_{c,f,k}^{[\ell]} \omega(p_{j,i}^k) x_c^{[\ell]}(j) + b_f \mathbf{1}_{N_\ell} \quad (3)$$

式中, j 为距离顶点 i 的长度为 k 的路径集合; C_ℓ 为第 ℓ 隐藏层上的特征数量; $x_c^{[\ell]}$ 为第 c 个特征所有节点的输入数据; $\omega(p_{j,i}^k)$ 表示所有长度为 k 路径的权重和; b_f 为偏置项; $\mathbf{1}_{N_\ell}$ 表示以图中节点数量为维数且数值为 1 的向量。式(3)表明,第 ℓ 隐藏层上的每个神经元都连接着顶点域中的一个自适应性局部区域。对式(3)得到的结果应用非线性运算 $\sigma(\cdot)$,即可得到下一个隐藏层上的输入特征。据此,结合点群综合的特性,本文设计了一个基于 TAGCN 网络的综合模型。模型结构如图 4 所示。

在该模型的特征提取部分,采用线性整流单元(rectified linear unit, ReLU)作为非线性激活函数,则第 $\ell+1$ 隐藏层上的输入特征 $x_f^{[\ell+1]}$ 可表示为

$\text{ReLU}(\mathbf{y}_f^{[i]})$ 。模型的最后一层为全连接层,点群中每个节点被保留的概率由归一化指数函数 $\text{Softmax}(\cdot)$

计算而得,并结合方根模型决定了节点在综合过程中是否会被保留。




图3 点群的特征向量提取方法

Fig. 3 Feature vector extraction method for point cluster

该 GCN 综合模型与常规的数据驱动方法相比,引入了领域知识参与到模型的学习过程中,使得模型可以更专注于特定领域上的具体任务,极大地提高了模型的可用性与可解释性,主要体现在以下 3 个方面。

(1) 传统针对矢量数据的数据驱动方法只考虑了单纯的位置坐标,而本文模型结合了地理学的关联性、自相似性作为领域知识,表现在网络模型的输入层:领域知识可以协助获取有用的空间邻域信息,提取隐藏的特征并定义特征向量输入到数据驱

动模型中。




图 4 图卷积网络模型结构

Fig. 4 Architecture of the graph convolutional network model

(2) 地理学第一定律作为经典的地理学领域知识为图卷积运算模型的选择,以及超参数的设定提供了依据,表现在网络模型的卷积层:领域知识可以根据不同的需求选择合适的网络搭建模型,并通过样本数据驱动特征信息的逐层传递。

(3) 尺度变换中的数量衰减定律作为地图综合的经典领域知识在模型中的概率决策部分中发挥作用,表现在网络模型的输出层:领域规则算法可以在深度学习模型完成分类概率计算的基础上,实现最终的认知决策。

3 试验与结果

3.1 试验数据

本文采用四川省德阳市中江县建筑物的抽象化点群作为试验数据。该试验数据集包括 92 803 个点数据用于训练与测试本文模型。建筑物与规则建筑群模式不同,此类建筑的分布较为分散与随机,相比于城市中较为规则的建筑群,更适合抽象为点状数据进行综合试验。训练集包括东南方向的 21 个乡镇,其余的 24 个乡镇作为测试集。其中,训练集数据占比 51.7%,测试集数据占比 48.3%。试验区域如图 5 所示。

在本文试验中,点群综合模型中使用的拓扑自适应图卷积网络包括 3 个卷积层,滤波层的数量被

设定为 3。此外,经过多次试验,设置学习率、正则化权重、训练次数分别为 0.1、0.000 5 和 2000,并选用 Adam 经过改进后的 AdamW 作为优化器。




图 5 试验区域

Fig. 5 Experimental area

3.2 样本构建

本文用于训练的样本数据采用几何算法与人工干预相结合的方法生成,其中,几何算法保证了样本在空间上的均匀分布,人工干预进一步考虑了语义、上下文、属性等附加条件,优化了样本数据在其他方面上的表现效果(图6)。文献[28]提出的基于 Voronoi 图面积的算法是一种较为常用的几何综合方法,该算法可以很好地保持点群的空间分布特

征,并已经广泛应用于工业领域。将经过 Voronoi 算法综合后的结果经过人工处理后,即可获得最终的样本数据。在样本数据的结构存储上,将简化过程中的被删除点与人工综合后的保留点分为两个类别并分别设置标签值为 0 和 1,即得到了可供模型训练的样本数据输入。对点群进行样本标记后,保留点的占比为 73.3%。




图6 点群的样本构造过程

Fig. 6 Sample construction process for a point cluster

3.3 基于 GCN 的点群综合决策

对于地图综合这种非常规的分类问题,相比于传统的模式分类而言,“综合”这种动态的操作的策略则是从多分类转变到二分类。在得到经过本文模型训练后的各个点所属的类别后,保留 Label 为 1 的点,并删除所有 Label 为 0 的点,即可得到最终的点群综合结果。然而,对于 GCN 在其他矢量数据的应用,例如建筑群模式识别、水系模式识别等,经过 Softmax 函数计算得到的结果是识别对象属于某一个模式的概率,这个概率的数值目前只用于挑拣出一些最高概率不占绝对优势的对象,并对这种模糊的对象采取人工识别方法进行最终决策。而在现有的研究中,模型却无法利用这些概率的数

值。因此,在点群综合的决策中可充分利用经过 GCN 模型计算得到的每个点的概率值,将所有 n 个点的概率 p_i 组合成向量 $\mathbf{V}_p = (p_1, p_2, \dots, p_n)$ 。对 $\mathbf{V}_p$ 按照从大到小的规则进行排序,即可得到表示点重要性顺序的索引向量 $\mathbf{I}_v$,表示为

$$\mathbf{I}_v = (I_1, I_2, \dots, I_i, \dots, I_n) \quad (4)$$

式中, $p_{I_i} > p_{I_{i+1}}$; I_i 为重要性排名为 i 点的索引。由于 $\mathbf{I}_v$ 记录了所有点重要程度的顺序,因此,点群的综合可以通过逐渐删除该向量的末尾元素所对应的点来实现。根据这个综合规则,就可以实现根据化简需求自由设定保留点数。如图 7 所示,在不同的综合比率下,点群的简化结果在视觉上具有较好的层次性。




图 7 GCN 方法在不同简化比率下的综合结果

Fig. 7 Generalization results of different simplification levels using GCN model

3.4 对比分析

3.4.1 数量保持性分析

在整体视角上,为保证图幅中包含的要素数量与地图比例尺相匹配,一般采用方根模型对地图在不同比例尺上保留的要素数量进行近似估计。方根模型于 1966 年被提出^[41],该模型为地图比例尺由大到小的转变过程中提供了量化的参考,其表达式为

$$n_F = n_A \sqrt{\frac{M_A}{M_F}} \quad (5)$$

式中, M_A 、 n_A 、 M_F 、 n_F 分别为原始地图与综合后地图的比例尺分母及点的数量。本文研究数据的初始点数与比例尺已知,基于已知的参数及人工自由设定的比例尺,即可通过式(5)计算出目标比例尺上地图所需保留的点数 n_F 。保留向量 I_V 中前 n_F 个元素所对应的点,即可得到目标点群在任意比例尺上的综合结果。

尽管在方根模型的约束下,综合后的地图在整体上会保持适当的点数,但在局部上仍不可避免地会出现不同子区域之间综合程度不均衡的情况。为检验本文模型综合结果在各个局部区域上的均衡程度,首先对中江县的测试集部分按照乡界对数据进行分块,并进一步检测综合后地图在各个乡镇内的点数量保持情况。表 1 以 1:250 000 的目标比例尺为例,将人工选择法(训练样本数据),随机选择法及本文方法的综合结果在目标比例尺上与各个比例尺保留点数的数学期望差值进行了对比。

表 1 中,GCN 综合方法所得结果的总误差率与样本数据相近,分别为 2.91% 与 2.96%,明显小于

随机化简结果的 4.32% 误差率。在多个比例尺的试验中,如表 2 所示,GCN 综合在统计上的优势更为明显:人工综合样本的整体趋势虽然随着比例尺的增大而逐渐减小,但稳定性不佳;随机综合结果在小比例尺地图上的误差率较大,明显高于人工与 GCN 的综合结果。GCN 综合算法在 1:50 000 到 1:250 000 比例尺区间内可以将误差率控制在 2%~3% 之间,相比于其他方法,在误差率与数量保持上都具有更好的稳定性。图 8 对比了多种综合方法在不同比例尺下的局部点群综合情况,包括空间 Voronoi 算法、传统机器学习算法 SVM 及基于注意力机制的 GAT 网络算法。通过对比可以发现,Voronoi 算法比较注重空间上的均匀分布,SVM 的综合结果较为不均衡,而本文方法的综合结果在保持整体特征的前提下,在局部特征的保持上也略优于 GAT 算法。

3.4.2 分布密度检验

在地图可视化的视角上,地图在综合前后是否具有相似的视觉感知特征是评价综合结果的重要指标之一。对于矢量数据而言,现有的研究一般关注单一地理特征的比较,而对于点群这种多要素的地理对象,则需要将其转化为二维的图像形式进行比较,如点密度图等。点密度图可以根据每个像素附近的点密度来分配灰度值,并将点群数据转化为能够反映整体视觉效果图像。对于两幅图像而言,结构相似性(structural similarity, SSIM)是衡量两者之间相似程度的常用参数之一^[42]。该参数可以有效衡量点群简化前后密度图的相似性。分别对各尺度下的综合结果生成点密度图,并计算了 3 种综合方法在各个尺度上的 SSIM 值,见表 3。

表 1 比例尺为 1 : 250 000 的数量误差对比结果

Tab. 1 Comparative results of quantitative errors at a scale of 1 : 250 000

乡镇 名称	原始 点数	目标 点数	人工综合方法		随机综合方法		GCN 综合方法	
			点数	误差率/(%)	点数	误差率/(%)	点数	误差率/(%)
古店乡	1696	339.2	348	2.59	338	0.35	344	1.42
石泉乡	1300	260	267	2.69	236	9.23	237	8.85
合兴乡	1304	260.8	265	1.61	279	6.98	262	0.46
兴隆镇	2570	514	517	0.58	490	4.67	497	3.31
辑庆镇	3256	651.2	633	2.79	641	1.57	677	3.96
南山镇	884	176.8	175	1.02	158	10.63	175	1.02
集凤镇	2671	534.2	538	0.71	560	4.83	539	0.90
富兴镇	2979	595.8	602	1.04	575	3.49	624	4.73
瓦店乡	681	136.2	149	9.40	151	10.87	130	4.55
青市乡	780	156	161	3.21	142	8.97	172	10.26
黄鹿镇	1913	382.6	393	2.72	401	4.81	406	6.12
永太镇	2149	429.8	454	5.63	418	2.75	422	1.81
杰兴镇	491	98.2	109	11.00	96	2.24	106	7.94
南华镇	2277	455.4	463	1.67	406	10.85	444	2.50
凯江镇	3	0.6	0	—	1	—	1	—
东北镇	1300	260	272	4.62	295	13.46	266	2.31
通济镇	1530	306	321	4.90	316	3.27	307	0.33
回龙镇	3046	609.2	605	0.69	610	0.13	611	0.30
玉兴镇	1846	369.2	354	4.12	395	6.99	376	1.84
悦来镇	2210	442	421	4.75	449	1.58	429	2.94
清河乡	876	175.2	177	1.03	182	3.88	174	0.68
龙台镇	2742	548.4	539	1.71	537	2.08	516	5.91
永安镇	3055	611	562	8.02	605	0.98	594	2.78
柏树乡	3284	656.8	643	2.10	687	4.60	659	0.33
总计	44 843	8 968.6	8968	2.96	8968	4.32	8968	2.91

表 2 不同比例尺的 3 种方法总误差对比结果

Tab. 2 Comparison of the total error of the three methods at different scales

比例尺	目标 点数	人工综合方法		随机综合方法		GCN 综合方法	
		总误差	误差率/(%)	总误差	误差率/(%)	总误差	误差率/(%)
1 : 1000 000	4 484.3	220.9	4.93	290.1	6.47	252.7	5.64
1 : 750 000	5178	82.9	1.6	304.4	5.88	264.5	5.11
1 : 500 000	6 341.8	294.3	4.64	339	5.35	270	4.26
1 : 250 000	8 968.6	265.8	2.96	387	4.32	261	2.91
1 : 200 000	10 027.2	212	2.11	339.6	3.39	285.8	2.85
1 : 150 000	11 578.4	411	3.55	422.2	3.65	290.3	2.51
1 : 100 000	14 180.6	430.9	3.04	401.1	2.83	300.7	2.12
1 : 50 000	20 054.4	572.7	2.86	479.8	2.39	423.1	2.11

表 3 不同比例尺下 3 种方法的 SSIM 值对比结果

Tab. 3 Comparison of the SSIM values of the three methods at different scales (%)

比例尺	人工综合方法	随机综合方法	GCN 综合方法
1 : 1 000 000	90.89	88.06	89.15
1 : 750 000	92.32	89.11	90.32
1 : 500 000	92.78	90.54	91.75
1 : 250 000	94.39	92.68	94.77
1 : 200 000	95.90	93.18	95.25
1 : 150 000	95.43	94.00	95.61
1 : 100 000	96.47	95.44	96.34
1 : 50 000	97.33	96.67	96.44

由表 3 可知,在大多数比例尺下,GCN 方法综合结果的 SSIM 值与人工方法接近,且优于随机算法,尤其是在化简率较高的小比例尺地图上,这也说明了 GCN 综合方法可以较好地保持点群的整体形态。对比 3 种方法生成的点密度图可以发现:人工综合方法由于其综合结果分布较为均匀,其点密度图相比于其他两种方法更为平滑,这会导致其在点分布稀疏的地方也会得到与原图像较为相似的灰度值,因此其 SSIM 值较高。而与人工综合方法相比,GCN 的综合结果则在点密度较高的区域化简

程度更加恰当。如图 9 所示,在 1 : 250 000 的比例尺下,对比 3 种方法点密度图中较密集的区域,可以发现 GCN 综合结果在深色区域的分布与原始图像

更为相似,相比于其他两种方法在局部区域上可以更好地体现原图像的密度分布特征。




图 8 不同比例尺下多种综合方法的局部点群对比

Fig. 8 Comparison of local point cluster of multiple generalization methods at different scales




图 9 3 种综合方法密集区域点密度图的对比

Fig. 9 Comparison of dot density maps of dense areas for the three generalization methods

3.4.3 上下文保持性分析

上下文关系是地理矢量数据的关键性特征。在地图综合中,如果原始数据与其他地理实体之间存在明显的相关关系,则综合过程中应尽量维持这种上下文特征。由于本文用于训练的样本已经考虑了上下文影响因素,为了检验本文模型在上下文方面的学习能力,本节采用了未考虑上下文关系的Voronoi 化简算法的综合结果重新标记了样本并再次训练,进而计算重新训练过的模型所得到的综合结果。分别对 4 种化简结果在各个比例尺上的平均临近道路交叉点个数进行统计,结果见表 4。

表 4 不同比例尺下 4 种化简结果的平均临近道路交叉点个数

Tab. 4 Average number of adjacent intersections for the four generalization methods at different scales

比例尺	人工综合方法	Voronoi 综合方法	人工样本训练结果	Voronoi 样本训练结果
1 : 1 000 000	0.209	0.142	0.145	0.121
1 : 750 000	0.198	0.144	0.146	0.127
1 : 500 000	0.189	0.144	0.147	0.128
1 : 250 000	0.177	0.145	0.153	0.137
1 : 200 000	0.175	0.150	0.156	0.141
1 : 150 000	0.173	0.152	0.159	0.145
1 : 100 000	0.171	0.156	0.160	0.148
1 : 50 000	0.168	0.158	0.162	0.154
1 : 10 000 (原始比例尺)	0.167	0.167	0.167	0.167

可以发现,经过人工样本训练过的结果的上下文保持程度在各个比例尺上均优于 Voronoi 样本训

练后的结果。这表明在包含上下文信息样本数据的驱动下,经过 GCN 模型训练后得到的综合结果在整体上更倾向于保留接近道路交叉点的点要素,这同时也说明该 GCN 综合模型可以准确捕捉并学习样本特征数据中蕴含的上下文特征。

为验证在局部区域上 GCN 综合模型对上下文特征的保持效果,图 10 分别在 1 : 250 000 比例尺下对不同综合方法在 4 个区域内的化简结果进行了对比,其中蓝色框线内的棕色点表示与道路交叉口(绿色点)相距较近的保留点。在 4 个原始区域中,4 个框内点的数量从上到下依次为:29、21、11、16,根据方根模型计算可知,在该比例尺下数据应有 80% 的化简比率,从而得到目标比例尺保留点数的期望值分别为 5.8、4.2、2.2、3.2。通过比较可以发现,以人工综合结果作为样本经过 GCN 模型训练后,在局部区域上下文保持上的误差较小,且明显优于其他方法。

3.4.4 属性相关特征保持性分析

不同类别的原始数据包含不同类型的属性数据,各种属性在地图综合中的重要性也不尽相同。本文的研究重点在于点状要素的化简,因此属性数据的作用是在保证点综合效果的前提下,尽量保持局部建筑群的朝向的连续性,在模型中起到辅助简化的效果。如图 11 所示,经过 GCN 训练后得到的综合结果与人工综合保留的建筑物有着相似的朝向,且与其他综合方法相比具有更好的建筑物方向连续性。




图 10 4 个区域内比例尺为 1 : 250 000 的局部区域上下文保持对比

Fig. 10 Contextual preservation of local areas at a scale of 1 : 250 000 in four regions for comparison




图 11 目标比例尺为 1 : 500 000 的综合结果重建建筑物方向连续性对比

Fig. 11 Comparison of generalized results of reconstructed building orientation continuity at a target scale of 1 : 500 000

4 结 论

本文将深度学习技术引入到地图综合中,以传统的地理空间知识为基础,构建图卷积神经网络模型,进而提出了一种将领域知识与数据驱动相结合的点群自动综合方法。这种综合策略的优点在于:第一,与纯数据驱动模式相比,充分发挥了领域知识的基础性作用。地理知识是地图综合领域在几十年的发展中得到的重要成果,虽然其中的每个单独的方面在某些层面上存在一定的局限性,但仍能从中获取到点要素上丰富的邻域特征信息。第二,图神经网络可以将提取到的特征结合起来并合理均衡各因素之间的影响,使得经过训练后的模型不仅可以学习到综合后点群的分布规律,也能避免人为设置参数对简化结果的影响。本文模型分别从空间、上下文、属性 3 个方面从原始数据中提取输入

特征,采用人工干预后的 Voronoi 算法综合结果作为样本,并以 TAGCN 作为训练网络学习综合规则,最终在方根模型的控制下,实现了点群的自动综合。试验结果表明:经过 GCN 综合模型得到的化简结果在各个比例尺上均有良好的可视化效果,且在数量、形态、上下文关系等方面相较于其他算法可以更好地保留原始数据的特征。在今后的工作中,对于不同的训练和测试图结构所产生的空间基准不一致问题,如何从给定的数据中学习通用的模式,迁移到未知的综合任务上,并合理构建例如 GAT、GIN 等归纳式网络模型,仍需在未来的研究中继续探索。此外,本文只采用了单一比例尺的人工综合结果作为输入样本。如何充分利用点群在多个比例尺上的综合结果,并从小比例尺地图不均衡的标签数据上学习特征,也同样是一个值得关注的问题。

参考文献

- [1] 艾廷华,张翔. 地理信息科学中尺度概念的诠释与表达[J]. 测绘学报, 2022, 51(7):1640-1652. DOI: 10.11947/j. AGCS. 2022. 20220143. AI Tinghua, ZHANG Xiang. An interpretation and representation of scale concept in geo-information sciences[J]. Acta Geodaetica et Cartographica Sinica, 2022, 51(7):1640-1652. DOI: 10.11947/j. AGCS. 2022. 20220143.
- [2] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504-507.
- [3] WANG Z, TIAN S. Ground object information extraction from hyperspectral remote sensing images using deep learning algorithm[J]. Microprocessors and Microsystems, 2021, 87: 104394.
- [4] GONG J, JI S. Photogrammetry and deep learning[J]. Journal of Geodesy and Geoinformation Science, 2018, 1(1): 1-15.
- [5] ZHU Y, ABDALLA A, TANG Z, et al. Improving rice nitrogen stress diagnosis by denoising strips in hyperspectral images via deep learning[J]. Biosystems Engineering, 2022, 219: 165-176.
- [6] LALITHA V, LATHA B. A review on remote sensing imagery augmentation using deep learning[J]. Materials Today: Proceedings, 2022, 62: 4772-4778.
- [7] LUO M, JI S. Cross-spatiotemporal land-cover classification from VHR remote sensing images with deep learning based domain adaptation[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2022, 191: 105-128.
- [8] 艾廷华. 深度学习赋能地图制图的若干思考[J]. 测绘学报, 2021, 50(9): 1170-1182. DOI: 10.11947/j. AGCS. 2021. 20210091. AI Tinghua. Some thoughts on deep learning enabling cartography[J]. Acta Geodaetica et Cartographica Sinica, 2021, 50(9): 1170-1182. DOI: 10.11947/j. AGCS. 2021. 20210091.
- [9] KIPF T N, WELING M. Semi-supervised classification with graph convolutional networks[EB/OL]. [2022-11-20]. <https://arxiv.org/abs/1609.02907.pdf>.
- [10] ZHANG Yang, CHENG Tao, REN Yibin, et al. A novel residual graph convolution deep learning model for short-term network-based traffic forecasting[J]. International Journal of Geographical Information Science, 2020, 34(5): 969-995.
- [11] ZHANG Zhihao, HAN Yong, PENG Tongxin, et al. A comprehensive spatio-temporal model for subway passenger flow prediction[J]. ISPRS International Journal of Geo-Information, 2022, 11(6): 341.
- [12] WANG Yi, JING Changfeng. Spatiotemporal graph convolutional network for multi-scale traffic forecasting[J]. ISPRS International Journal of Geo-Information, 2022, 11(2): 102.
- [13] 王米琪,艾廷华,晏雄峰,等. 图卷积网络模型识别道路正交网格模式[J]. 武汉大学学报(信息科学版), 2020, 45(12): 1960-1969. WANG Miqi, AI Tinghua, YAN Xiongfeng, et al. Grid pattern recognition in road networks based on graph convolution network model[J]. Geomatics and Information Science of Wuhan University, 2020, 45(12): 1960-1969.
- [14] 王米琪. 基于图卷积神经网络的道路网模式识别[D]. 武汉: 武汉大学, 2021. WANG Miqi. Road network pattern recognition based on graph convolution neural network[D]. Wuhan: Wuhan University, 2021.
- [15] YU H, AI T, YANG M, et al. A recognition method for drainage patterns using a graph convolutional network[J]. International Journal of Applied Earth Observation and Geoinformation, 2022, 107: 102696.
- [16] YU H, AI T, YANG M, et al. Automatic segmentation of parallel drainage patterns supported by a graph convolution neural network[J]. Expert Systems with Applications, 2023, 211: 118639.

- [17] YAN X, AI T, YANG M, et al. A graph convolutional neural network for classification of building patterns using spatial vector data[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2019, 150: 259-273.
- [18] YAN Xiongfeng, AI Tinghua, YANG Min, et al. Graph convolutional autoencoder model for the shape coding and cognition of buildings in maps[J]. International Journal of Geographical Information Science, 2021, 35(3): 490-512.
- [19] YAN Xiongfeng, AI Tinghua, YANG Min, et al. A graph deep learning approach for urban building grouping[J]. Geocarto International, 2022, 37(10): 2944-2966.
- [20] 晏雄锋. 深度卷积学习支持下的建筑物模式分析[D]. 武汉: 武汉大学, 2019.
YAN Xiongfeng. Building pattern analysis supported by deep convolution learning[D]. Wuhan: Wuhan University, 2019.
- [21] ZHAO Rong, AI Tinghua, YU Wenhao, et al. Recognition of building group patterns using graph convolutional network[J]. Cartography and Geographic Information Science, 2020, 47(5): 400-417.
- [22] LANGRAN C, POICKER T. Integration of name selection and name placement[C]//Proceedings of the 2nd International Symposium on Spatial Data Handling. Washington: IEEE, 1986: 50-64.
- [23] SADAHIRO Y. Cluster perception in the distribution of point objects[J]. Cartographica: the International Journal for Geographic Information and Geovisualization, 1997, 34(1): 49-62.
- [24] VAN K M, VAN O R, SNOEYINK J. Efficient settlement selection for interactive display[C]//Proceedings of 1997 Auto Carto Conference. Bethesda: IEEE, 1997: 287-296.
- [25] 钱海忠, 武芳, 邓红艳. 基于 CIRCLE 特征变换的点群选取算法[J]. 测绘科学, 2005, 30(3): 83-85.
QIAN Haizhong, WU Fang, DENG Hongyan. A model of point cluster selection with circle characters[J]. Science of Surveying and Mapping, 2005, 30(3): 83-85.
- [26] 钱海忠, 武芳, 谢鹏, 等. 基于 CIRCLE 特征变换的点群选取改进算法[J]. 测绘科学, 2006, 31(5): 69-70, 59.
QIAN Haizhong, WU Fang, XIE Peng, et al. An improved algorithm of point cluster selection based on circle characteristic transformation[J]. Science of Surveying and Mapping, 2006, 31(5): 69-70, 59.
- [27] QIAN H, MENG L, ZHANG M. Network simplification based on the algorithm of polarization transformation[C]//Proceedings of 2007 International Cartographic Conference (ICC). Moscow: IEEE, 2007.
- [28] 艾廷华, 刘耀林. 保持空间分布特征的群点化简方法[J]. 测绘学报, 2002, 31(2): 175-181.
AI Tinghua, LIU Yaolin. A method of point cluster simplification with spatial distribution properties preserved[J]. Acta Geodaetica et Cartographica Sinica, 2002, 31(2): 175-181.
- [29] YAN H, WEIBEL R. An algorithm for point cluster generalization based on the Voronoi diagram[J]. Computers & Geosciences, 2008, 34(8): 939-954.
- [30] 邓红艳, 武芳, 钱海忠, 等. 基于遗传算法的点群目标选取模型[J]. 中国图象图形学报, 2003, 8(8): 124-130.
DENG Hongyan, WU Fang, QIAN Haizhong, et al. A model of point cluster selection based on genetic algorithms[J]. Journal of Image and Graphics, 2003, 8(8): 124-130.
- [31] WANG Lin, GUO Qingsheng, LIU Yuangang, et al. Contextual building selection based on a genetic algorithm in map generalization[J]. ISPRS International Journal of Geo-Information, 2017, 6(9): 271.
- [32] DE BERG M, BOSE P, CHEONG O, et al. On simplifying dot maps[J]. Computational Geometry: Theory and Applications, 2004, 27(1): 43-62.
- [33] LEE J, JANG H, YANG J, et al. Machine learning classification of buildings for map generalization[J]. ISPRS International Journal of Geo-Information, 2017, 6(10): 309.
- [34] KARSZNIA I, SIELICKA K. When traditional selection fails: how to improve settlement selection for small-scale maps using machine learning[J]. ISPRS International Journal of Geo-Information, 2020, 9(4): 230.
- [35] KARSZNIA I, WEIBEL R. Improving settlement selection for small-scale maps using data enrichment and machine learning[J]. Cartography and Geographic Information Science, 2018, 45(2): 111-127.
- [36] DU Jian, ZHANG Shanghang, WU Guanhang, et al. Topology adaptive graph convolutional networks[EB/OL]. [2022-10-25]. <https://arxiv.org/abs/1710.10370.pdf>.
- [37] 艾廷华. Delaunay 三角网支持下的空间场表达[J]. 测绘学报, 2006, 35(1): 71-76, 82.
AI Tinghua. A spatial field representation model based on Delaunay triangulation[J]. Acta Geodaetica et Cartographica Sinica, 2006, 35(1): 71-76, 82.
- [38] 杨伟, 艾廷华. 运用约束 Delaunay 三角网从众源轨迹线提取道路边界[J]. 测绘学报, 2017, 46(2): 237-245. DOI: 10.11947/j. AGCS.2017.20160233.
YANG Wei, AI Tinghua. The extraction of road boundary from crowd sourcing trajectory using constrained delaunay triangulation[J]. Acta Geodaetica et Cartographica Sinica, 2017, 46(2): 237-245. DOI: 10.11947/j. AGCS.2017.20160233.
- [39] AI Tinghua, KE Shu, YANG Min, et al. Envelope generation and simplification of polylines using Delaunay triangulation[J]. International Journal of Geographical Information Science, 2017, 31(2): 297-319.
- [40] TOBLER W R. A computer movie simulating urban growth in the Detroit region[J]. Economic Geography, 1970, 46(s1): 234-240.
- [41] TÖPFER F, PILLEWIZER W. The principles of selection[J]. The Cartographic Journal, 1966, 3(1): 10-16.
- [42] WANG Z, BOVIK A C, SHEIKH H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.

(责任编辑:张艳玲)

A point cluster simplification approach of graph convolutional neural network for map generalization

XIAO Tianyuan^{1,2}, AI Tinghua^{1,2}, YU Huafei^{1,2}, YANG Min^{1,2}, LIU Pengcheng³

1. *School of Resource and Environmental Sciences, Wuhan University, Wuhan 430079, China;*

2. *Key Laboratory of Geographic Information System, Ministry of Education, Wuhan 430079, China;*

3. *School of Urban and Environmental Sciences, Central China Normal University, Wuhan 430079, China*

Abstract: Map generalization is a complex decision-making process with multiple factors, and the optimal selection of generalization operators for different scenarios is routinely implemented through a rule-based approach. These map generalization rules need to be "patched" to take into account the influence of different special conditions, resulting in an increasingly complex system of map generalization rules that lose their universality. The data-driven simplification scheme with artificial intelligence technology provide a new way of thinking about map generalization under special rules by extracting the generalization rules implied in typical cases through machine learning and migrating them to new data scenarios. In this paper, deep learning techniques are introduced and a strategy combining domain knowledge and data-driven is used to propose an automatic generalization method for point clusters based on graph convolutional neural networks. This method obtains the knowledge of map generalization in different data scenarios through sample training and deep learning, while incorporating established rules for guidance, which can move more effectively toward the goal of artificial map generalization results. Firstly, a Delaunay triangulation network is constructed to establish spatial neighbourhood relationships between points and to calculate the feature information of each point based on domain knowledge such as geospatial contextual associations and spatial heterogeneity to construct the feature vectors of the point cluster. Secondly, the topological adaptive graph convolutional neural network is introduced to construct an automatic generalization network model of the point cluster data. The experiments show that the algorithm can maintain the features of the original point cluster in both the local area and the overall map, which is reflected in the relative quantity maintenance, contextual feature inheritance and attribute feature consistency.

Key words: map generalization; point cluster; Delaunay triangulation; GCN; data-driven

Foundation support: The National Natural Science Foundation of China (Nos. 42071455; 42071450)

First author: XIAO Tianyuan (1995—), male, PhD candidate, majors in map generalization.

E-mail: xiaotianyuan@whu.edu.cn

Corresponding author: AI Tinghua

E-mail: tinghuaai@whu.edu.cn