

一种面向地图综合建筑多边形化简的 Transformer 模型

刘鹏程^{1,2}, 成晓强³, 肖天元⁴, 杨 敏⁴, 艾廷华⁴

1. 华中师范大学地理过程分析与模拟湖北省重点实验室, 湖北 武汉 430079;
2. 华中师范大学城市与环境科学学院, 湖北 武汉 430079;
3. 湖北大学资源环境学院, 湖北 武汉 430062;
4. 武汉大学资源与环境科学学院, 湖北 武汉 430079

收稿日期: 2025-06-30; 修回日期: 2026-01-05

中图分类号: P208

文献标识码: A

文章编号: 1001-1595(2026)01-0124-14

基金项目: 国家自然科学基金(42471486; 42071455); 中央高校基本科研业务费专项资金(CCNU25JC043)

第一作者简介: 刘鹏程(1968—), 男, 博士, 教授, 研究方向为地图综合、空间模式识别和空间智能分析。

E-mail: liupc@ccnu.edu.cn

摘 要:针对地图综合中建筑多边形化简方法依赖人工规则、自动化程度低且难以利用已有化简成果的问题, 本文提出了一种基于 Transformer 机制的建筑多边形化简模型。该模型首先把建筑多边形映射至一定范围的网格空间, 将建筑多边形的坐标串表达为网格序列, 从而获取建筑多边形化简前后的 Token 序列, 构建出建筑多边形化简样本对数据; 随后采用 Transformer 架构建立模型, 基于样本数据利用模型的掩码自注意力机制学习点序列之间的依赖关系, 最终逐点生成新的简化多边形, 从而实现建筑多边形的化简。在训练过程中, 模型使用结构化的样本数据, 设计了忽略特定索引的交叉熵损失函数以提升化简质量。试验设计包括主试验与泛化验证两部分。主试验基于洛杉矶 1:2000 建筑数据集, 分别采用 0.2、0.3 和 0.5 mm 3 种网格尺寸对多边形进行编码, 实现了目标比例尺为 1:5000 与 1:10 000 的化简。试验结果表明, 在 0.3 mm 的网格尺寸下模型性能最优, 验证集上的化简结果与人工标注的一致率超过 92.0%, 且针对北京部分区域的建筑多边形数据的泛化试验验证了模型的迁移能力; 与 LSTM 模型的对比分析显示, 在参数规模相近的条件下, LSTM 模型无法形成有效收敛, 并生成可用结果。本文证实了 Transformer 在处理空间几何序列任务中的潜力, 且能够有效复用已有化简样本, 为智能建筑多边形化简提供了具有工程实用价值的途径。

关键词: 地图综合; 建筑多边形化简; Tokenization; Transformer 模型; 上下文工程

地图综合是实现地理要素跨尺度表达的核心技术, 同时也是在特定地图用途、比例尺和制图区域地理特点的条件下, 通过对地图内容的选取、化简、概括和关系协调, 建立能反映目标比例尺下区域地理规律的一种制图方法^[1]。作为刻画城市空间结构的重要载体, 建筑多边形的化简是地图综合中的重要内容, 其化简质量直接关系到地图产品的视

觉效果、美学质量及后续空间分析的准确性。建筑多边形化简通常遵循以下基本原则: ①多边形的边应趋向平行与正交; ②复杂轮廓应简化为规则的矩形形态; ③保留主要形状特征, 简化次要细节, 以维持形状的相似性; ④尽量保持建筑多边形面积的相对稳定。传统建筑多边形化简方法主要依赖预设规则与特征提取技术, 大致可分为 3 类: 基于规则的

引文格式: 刘鹏程, 成晓强, 肖天元, 等. 一种面向地图综合建筑多边形化简的 Transformer 模型[J]. 测绘学报, 2026, 55(1): 124-137. DOI:10.11947/j.AGCS.2026.20250262.
LIU Pengcheng, CHENG Xiaoqiang, XIAO Tianyuan, et al. A Transformer model for building polygon simplification in map generalization[J]. Acta Geodaetica et Cartographica Sinica, 2026, 55(1): 124-137. DOI:10.11947/j.AGCS.2026.20250262.



方法、基于模板匹配的方法和基于图像处理的方法。基于规则的方法借助计算几何与模式识别技术来判断多边形几何单元的结构模式(尤其关注边角特征)。文献[2]基于模式识别对街区块轮廓进行化简。文献[3]依据主方向对建筑物实施直角化,通过组合与筛选特征边实现化简。文献[4—5]采用带约束的最小二乘优化方法调整顶点位置以实现角度直角化。文献[6—7]则分别对连续四点或五点构成的图形单元进行分类,并针对不同类型实施相应的综合策略。基于模板匹配的方法则依据建筑物类别构建形状模板库,通过将原始多边形替换为最相似的模板实现化简^[8-12]。此类方法适用于形状模式相对有限的建筑群,其核心在于模板库的设计与形状相似性匹配算法的开发。文献[8]利用多边形角度转向构建形状特征序列,借助序列距离算法实现要素与字母模板的匹配,进而完成乡村居民地的示意性表达。文献[11—12]则分别采用链码、傅里叶描述子及转角函数进行形状相似性计算,最终通过模板替换完成化简。基于图像处理的方法充分利用栅格数据在逻辑运算中的优势。文献[13]基于栅格数据的差分组合思想,通过子图形的分解与组合实现建筑物化简;文献[14]则结合数学形态学与神经网络技术完成建筑多边形的化简。上述方法各有优势,共同将计算机图形学、模式识别与空间认知理论引入建筑多边形化简领域。然而,这些算法在具体应用中仍较多依赖专家经验以选择合适的化简策略,在自动化与泛化能力方面仍有提升空间。

近年来,随着数据资源的日益丰富与人工智能技术在地图制图领域中的广泛渗透,基于深度学习的建筑多边形化简研究逐渐兴起。人工神经网络(ANN)^[15-16]、生成对抗网络(GAN)^[17]及自编码器(AE)^[18]等模型已被尝试用于要素化简及算法选择任务,展现出数据驱动方法在地图综合中的潜力。文献[19]借助深度学习模型评估了4种建筑多边形化简方法的适用性,以期为不同形态的多边形推荐最优化简策略。文献[20]则通过监督学习构建了建筑物形状编码与化简算法之间的映射关系,形成了一种能够依据输入形状特征自适应选择化简算法的机制。尽管如此,这类基于数据与特征双驱动的方法仍受到特征表达能力与选取模型的制约,虽在自动化与智能化方面较传统方法有所突破,但整体性能方面仍有待提高。

近年来,自然语言大模型(large language models, LLMs)取得了突破性进展,其强大的序列建模与生成能力也为地图综合的自动化与智能化提供了全

新路径^[21]。目前,大模型在GIS领域中主要在提示词工程、检索增强生成、模型微调与智能体4种范式上发挥作用^[22]。以Transformer^[23]为核心架构的大语言模型所取得的成功,进一步激发了将其核心机制迁移至各类序列化“上下文工程”任务中的研究兴趣。然而,现有基于Transformer的空间数据分析研究多集中于栅格数据。文献[24]构建了基于Transformer的土地覆盖分类模型,显著提升了分类精度。文献[25]提出一种无监督跨视角无人机图像地理定位方法,同样以栅格数据为基础。目前,尚未有研究将Transformer直接用于处理以坐标序列表示的空间矢量实体。在利用深度学习进行曲线化简方面,当前的多数方法通过将问题转化为节点分类任务来进行实现,文献[26]通过对曲线上的关键节点进行识别,从而实现对线状要素的形状化简。本文借鉴大语言模型的基本思想,将建筑多边形的原始几何坐标序列视作一种“空间语言”。具体而言,通过词元化(Tokenization)将原始坐标离散化为网格编码序列,并利用Transformer架构的自回归生成能力,学习从原始序列到目标简化序列的端到端映射,从而构建一个“坐标序列到坐标序列”的建筑多边形化简模型。该方法的核心优势在于能够通过大量化简样本隐式地学习其中所蕴含的化简规则,而无须依赖显式的特征提取,并能实现更程度的自动化。研究的理论基础在于:多边形的空间特征与结构模式蕴含于顶点序列及其连接关系中,类似于自然语言中语义信息隐藏于词元序列及其上下文关联——而这正是Transformer实现高效特征提取的关键机制。

1 建筑多边形化简的大模型

1.1 多边形的词元化

词元化(Tokenization)作为大语言模型的基础环节,其核心任务是将原始数据分解为离散且有限的词元(Token),这一过程对构建基于Transformer架构的多模态模型尤为关键^[27]。本文中,模型面临的核心挑战在于如何将建筑多边形高精度密集性坐标串转为适合Transformer模型输入的离散Token序列。大型语言模型(如DeepSeek-R1或GPT-4)通常依赖一个预先定义且规模有限的词表作为输入。尽管地理空间坐标在特定精度(如毫米级)下可视为离散值,但如果直接按其原始空间粒度进行词元化,将导致词表规模过大,显著增加模型计算与存储负担,在实际应用中难以实施。因此,为有

效应用 Transformer 处理几何坐标序列,本模型的词元化策略需解决两个相互关联的关键问题:①控制词表规模并实现有效离散化。通过网格化方法,将连续的几何坐标映射至一个固定范围且具有合理粒度的空间网格系统,从而将原始坐标离散化为有限的网格单元标识符,确保生成词表的规模可控且有限。②满足目标几何精度要求。网格单元尺寸的选择必须确保多边形顶点在离散化后仍能满足目标地图比例尺及应用场景(如显示或绘图)的几何分辨率需求。这两项要求紧密耦合:在严格保证几何精度的前提下有效控制词表规模,构成了将连续空间几何信息高效转换为 Transformer 可处理词元序列的关键基础。

1.1.1 建筑多边形的表示空间

本文为建筑多边形定义了一个标准化的表示空间:一个边长为 L 的正方形区域,用于容纳并离散化多边形轮廓。该空间的主要作用是将地图中所有建筑多边形映射至统一空间,从而为后续的词元化过程提供基础词汇表。表示空间大小根据具体建筑多边形数据来确定,可以选择所有建筑多边形中最大的外接正方形。但如果只有少数较大的建筑多边形,可以人为确定表示空间的范围,对于外接矩形大于表示空间的多边形,另行选择综合方法。这样能有效控制词表规模,降低问题的复杂度,提高模型的运行效率。

1.1.2 建筑多边形的网格尺寸

建筑多边形的网格尺寸须综合考虑数据的精度、模型词表规模和计算效率。网格尺寸对应的实际地面距离由式(1)计算得出

$$D = d \times 10^{-3} \times S \quad (1)$$

式中, D 为实际距离,单位为 m; d 为地图上网格尺寸,单位为 mm; S 为源地图比例尺分母。对于 1:2000 比例尺的地形图,当网格距离 d 为 0.2 mm,对应的实际距离 D 为 0.4 m;而对于 1:5000 的地形图,0.2 mm 网格尺寸的实际距离 D 为 1.0 m。在实际应用中,可以根据表达空间的尺度 L 适当调整网格尺寸 d 。为保证网格划分的规整性,通常要求 L 能被 d 所对应的实际距离整除。这样表示空间单边方向上的网格数量为 $\frac{L}{d}$,整个表示空间的总的网格单元数为 $\frac{L}{d} \times \frac{L}{d}$ 。不难发现,为了保持相同的几何表达精度,源地图比例尺 $\frac{1}{S}$ 越大,地图上的网格尺寸 d 需要更小。这会导致表示空间范围内的网

格单元总数显著增加,不可避免地增大模型的计算复杂度和存储需求。

1.1.3 建筑多边形序列化表达

化简模型以制图人员完成的建筑多边形化简前后样本对作为训练数据。针对每对样本的源要素(化简前)与目标要素(化简后),按以下流程进行坐标序列化处理。

步骤 1 坐标归一化:提取源多边形的最小坐标值 $(x_{\min}, y_{\min})$,将要素所有顶点坐标平移至以该最小点为原点的相对坐标系中,即 $(\Delta x_i, \Delta y_i) = (x_i - x_{\min}, y_i - y_{\min})$ 。

步骤 2 网格化映射:将平移后原点定位于 1.1.2 节所建网格的第 10 行、第 10 列网格单元的中心,然后根据式(2)计算多边形中每个顶点 i 所在网格中的行号和列号

$$\left. \begin{aligned} \text{row}_i &= \left\lfloor \frac{\Delta Y_i}{D} \right\rfloor + 10 \\ \text{col}_i &= \left\lfloor \frac{\Delta X_i}{D} \right\rfloor + 10 \end{aligned} \right\} \quad (2)$$

式中, $\lfloor \cdot \rfloor$ 为向下取整函数; row_i 、 col_i 分别为待求第 i 点所在的行、列号; (x_i, y_i) 为第 i 点的坐标; D 为网格对应的实地距离。此处行、列值加 10 是为了预留边界空间,避免因化简后多边形的顶点坐标超出表示空间边界。

步骤 3 序列编码:按照先行后列的顺序,从 0 开始为网格单元生成全局唯一序号。每个顶点 i 所在网格单元对应的序号由式(3)计算

$$\text{ID}_i = \text{row}_i \times N + \text{col}_i = \text{row}_i \times \frac{L}{d} + \text{col}_i \quad (3)$$

式中, ID_i 为顶点 i 所在网格单元的序号; N 为空间单边方向上的网格数量; L 为空间的实际边长,每个网格对应一个唯一的词元。词元在网格内按照逐列(从左到右)逐行(从下到上)排列,即第 0 行、第 0 列的 Token 值为 0;第 0 行的 Token 值为 0,1,2,..., $N-1$;第 1 行的 Token 值为 $N, N+1, N+2, \dots, 2N-1$;以此类推。图 1 为 200×200 网格的实例,网格中每 1 行为 200 个 Token,其中第 1 行为 0~199,第 2 行为 200~399。

为了在后续处理中将化简结果由格网坐标索引还原回原始坐标框架,需要记录每对要素对应的最小坐标 $(x_{\min}, y_{\min})$,并作为元数据存储于关联文件中。

步骤 4 要素序列表达:对于一个包含 n 个点的多边形,经过前述处理流程,最终将被表达成一个离散序列 $\text{ID} = \{\text{ID}_1, \text{ID}_2, \dots, \text{ID}_n\}$ 。以图 2 进行示例说明,图 2(a)为原始建筑多边形,图 2(b)为化

简后的多边形,图左侧列出了两个多边形各自的顶点坐标,图右侧展示了以实际网格尺寸进行词元化的结果示意图。图中原始要素序列:{47 552,61 067,67 545,53 530,56 017,47 510,41 030,31 020,25 042,35 052,25 090,16 082,5127,17 640,23 615,40 132,46 112,35 100,47 552},而综合后要素序列:{47 552,61 067,67 544,37 514,7130,17 640,23 615,40 132,46 112,35 100,47 552}。

39 800	39 801	39 802	...	...	...	39 996	39 997	39 998	39 999
39 600	39 601	39 602	...	...	...	39 796	39 797	39 798	39 799
39 400	39 401	39 402	...	...	...	39 596	39 597	39 598	39 599
...	...	...	...	...	...	...	...	...	...
...	...	...	...	...	...	...	...	...	...
...	...	...	...	...	...	...	...	...	...
...	...	...	...	...	...	...	...	...	...
400	401	402	403	...	...	496	497	498	599
200	201	202	203	...	...	396	397	398	399
0	1	2	3	...	...	196	197	198	199

图 1 网格与 Token 的对应关系

Fig.1 Grid-to-Token correspondence




图 2 建筑多边形原要素与综合要素的 Tokenization

Fig.2 The original feature and generalized feature of the building polygon Tokenization process

当前输出 Token 时仅关注其前方的 Token,防止信息泄露。此自注意力层的输出经 Dropout 处理后,与模块的原始输入相加实现残差机制。

1.2.3 输出模块

该模块(图 3(a)的 Output layer),对来自前一模块的输出首先进行层归一化处理。随后,归一化后的特征通过分类器层生成词汇表上所有可能 Token 的概率分布。模型在推理阶段采用贪心解

码(greedy decoding)策略,即逐位生成化简结果序列:在每一步预测中,选择当前输出概率最大的 Token 索引,并将该 Token 作为化简序列的下一个元素输入,通过逐步输入和输出最终形成完整的化简后 Token 序列。再计算各 Token 对应表示空间的行列号,最后根据各多边形的网格尺寸和所记录的各多边形的坐标最小值将其还原到原始坐标框架中。




图 3 化简模型的整体结构

Fig.3 Overall structure of simplified model

2 模型的样本数据格式设计和损失函数计算

2.1 模型样本格式设计

本文模型的训练机制在形式上类似于 ChatGPT 等自然语言模型,其核心在于基于已生成的历史词元预测下一个词元在整个词表上的概率分布。然而,地图空间与自然语言存在本质上的不同,建筑多边形的坐标序列缺乏内在的、类似语法或语义的结构化模式。因此,本文模型的核心策略是聚焦于学习映射机制:利用大量样本数据(源建筑多边形及其对应的人工化简结果),直接学习从源多边形序列到化简后多边形序列的转换关系。模型性能的最终评估标准在于其生成的多边形与专业制图人员化简结果在顶点位置、几何形状以及整体结构

模式上的一致性程度。

与传统大语言模型的输入形式不同,本文模型的输入序列由源建筑多边形和化简后建筑多边形的顶点词元共同构成。损失函数的计算仅需关注模型生成的目标要素部分,必须屏蔽源要素对应的词元及填充标记。假设源要素和目标要素的最大顶点数分别为 M 和 N (包含序列结束符 EOS),则模型输入样本的具体构造方式如下:输入向量由两部分拼接而成,总长度为 $M+N$ 。第一部分(长度 M)的起始为源要素各顶点的位置编码词元,其后为序列结束符,剩余部分使用填充符填充至固定长度 M 。第二部分(长度 N)的起始为目标化简要素各顶点的位置编码词元,其后为序列结束符,剩余部分使用填充符填充至固定长度 N 。其中序列结束符定义为最大网格词元值(即词表大小减 1)加 1,即

$\text{EOS} = \text{max_grid_token} + 1$; 填充符定义 $\text{max_grid_token} + 2$ 。若在某个网格配置下, 最大网格词元值为 39 999 (即词表大小为 40 000), 则 $\text{EOS} = 39\,999 + 1 = 40\,000$, $\text{Padding} = 39\,999 + 2 = 40\,001$ 。

目标向量的长度与输入向量相同, 均为 $M + N$ 。其构造规则如下: 前 M 个位置全部填充为特殊值 -100 用于屏蔽输入向量第一部分对应的所有内容, 包括源要素词元、源序列结束符 EOS 及源序列填充符。第 $M + 1$ 至 $M + N$ 位先放置目标化简要素各顶点的位置编码词元, 再添加序列结束符, 剩余位置填充为 -100 至总长度 $M + N$ 。值 -100 在目标向量中用作填充符, 其特殊含义是忽略索引

(ignore_index), 即在损失函数计算时, 模型不会对标记为 -100 的位置进行预测或计算损失。

图 4 展示了模型样本格式的一个具体实例: 源建筑多边形 (化简前) 包含 12 个顶点, 其词元序列为 $\{421, 2, 2206, 5005, 4801, 6800, 7219, 5019, 5015, 2416, 2420, 421, \text{EOS}\}$ 。目标化简多边形 (化简后) 包含 5 个顶点, 其词元序列为 $\{219, 4, 7002, 7217, 219, \text{EOS}\}$ 。试验中设定 $M = 26$ (源序列最大长度, 包含 EOS 和 Padding) 和 $N = 23$ (目标序列最大长度, 包含 EOS 和 Padding)。图中展示了根据上述源序列、目标序列及参数 M 和 N 构造的输入张量和目标张量, 两者长度均为 49 (即 $M + N = 49$)。



图 4 样本数据的 input 和 target 张量的构成

Fig.4 Composition of the input and target tensors of the sample data

2.2 模型损失函数

模型在每个位置 ($t = 1$ 至 $M + N$) 的输出是整个词表上的概率分布。因此, 模型最终的输出是一个形状为 $(M + N, S)$ 的概率张量, 其中 S 为词表大小 (即所有可能的词元数量, 包含网格单元词元、EOS 和 Padding)。模型采用 PyTorch 的 CrossEntropyLoss 作为损失函数。由于模型的核心优化目标是正确生成化简后的建筑多边形序列, 损失函数应仅针对目标张量中对应化简要素部分的词元预测误差进行计算。为此, 充分利用 CrossEntropyLoss 函数的特性: 通过设置 $\text{ignore_index} = -100$ 参数, 目标向量中标记为 -100 的位置 (即屏蔽部分) 将被完全排除在损失计算之外。这种机制严格确保了损失计算的焦点完全集中于模型需要生成的化简要素序列上。

3 试验与分析

3.1 样本数据介绍

本文采用美国洛杉矶周边特定区域 (图 5(a)) 的 1:2000 比例尺建筑多边形数据集作为样本来

源, 共包含约 18 万个建筑物多边形要素。在该区域内, 进一步选取 4 个小范围区域 (图 5(a) 中红色多边形标示) 包含的 1.6 万个建筑多边形作为验证集。基于该数据集, 开展了 1:5000 与 1:10 000 两种目标比例尺下的建筑多边形化简试验。样本化简流程如下: 首先, 借助 ArcGIS Pro 中的“简化建筑物”工具进行初步自动化处理。针对 1:5000 比例尺, 设置简化容差为 3 m, 最小面积为 4 m^2 ; 针对 1:10 000 比例尺, 简化容差设为 6 m, 最小面积为 12 m^2 。在此基础上, 对初步结果逐一进行人工综合处理, 主要包括直角化修正、平行边处理, 以及修正不合理的形状扭曲、重要特征丢失等问题。在整个综合过程中, 未执行要素删除或合并操作, 以确保源数据与化简后数据之间严格保持一一对应关系。

3.2 模型的训练及收敛性分析

基于 1.2 节的模型架构, 试验在配备 14 核 Intel(R) Xeon(R) Gold 6348 处理器与单块 NVIDIA A800-80GB GPU 的计算平台上进行。本文试验的部分关键超参数设置如下: 词嵌入维度为 516; 模型包含

12 个串联堆叠的 Transformer 层;每个 Transformer 层由 6 个注意力头构成;所有 Dropout 层的丢弃率统一设置为 0.3。模型优化采用 AdamW 优化器,该优

化器的学习率在区间 $[0.000\ 1, 0.02]$ 内进行调优;权重衰减率设为 0.2。训练数据采用随机采样方式构建训练批次, batch 大小设定为 128。




图 5 研究区域及部分样本数据

Fig.5 The study area and selected sample data

由于试验中绝大部分建筑多边形的外接矩形小于 200 m, 因而取 $L = 200$ m, 采用 0.2、0.3 和 0.5 mm 3 种网格尺寸进行模型的训练与性能评估, 对于外接矩形大于 200 m 的多边形则另行处理。基于此, 可以计算不同网格尺寸下建筑多边形顶点所产生的平均点位偏移, 该指标量化了网格离散化对几何精度的影响。表 1 系统呈现了网格尺寸 d 与平均点位偏移、词汇表尺寸及模型参数量之间的对应关系。

表 1 网格尺寸与点位平均偏移、词汇表尺寸、模型参数量的关系

Tab.1 Relationship between grid size and position offset, Token size, and model size

参数	网格尺寸		
	0.2 mm	0.3 mm	0.5 mm
点位平均偏移/m	0.26	0.39	0.49
词汇表尺寸	250 002	110 891	40 002
模型参数量	2.9×10^8	1.5×10^8	8×10^7

由表 1 中“点位平均偏移”指标可知, 3 种网格尺寸所产生的点位平均偏移均小于 1 : 5000 与 1 : 10 000 比例尺地形图所对应的精度阈值 (分别为 0.5 m 和 1.0 m)。表 1 列出了各网格尺寸所对应的词汇表规模及模型参数量级。表 2 进一步比较了 3 种网格尺寸在不同目标比例尺下的试验参数与性能表现。综合以上分析, 可得出如下结论:

(1) 在模型精度方面, 0.3 mm 网格表现最优。在 1 : 5000 与 1 : 10 000 目标比例尺下, 该网格在验证集上的一致性分别达到 92.3% 与 94.3%, 优于

0.2 mm 网格 (32.0%/34.3%), 与 0.5 mm 网格 (90.6%/92.1%) 基本持平。0.2 mm 网格因词表规模过大 (达 250 002), 在当前模型参数量条件下难以有效拟合人工化简结果, 导致其一致率偏低, 不具备实用价值。

(2) 在几何保真度方面, 3 种网格均表现良好。其面积变化率均低于 1.0%, 直角化率均高于 89.0%, 说明不同网格设定对几何形态的整体保持能力相当。

(3) 在计算效率方面, 0.2 mm 网格的训练成本显著偏高。其在 1 : 5000 与 1 : 10 000 比例尺下的训练耗时分别为 2650 min 与 2730 min, 约为 0.5 mm 网格的 1.4 倍。这主要由于细粒度网格导致输出词元序列增长, 而 Transformer 自注意力机制的计算复杂度与序列长度呈平方关系 ($O(n^2)$), 因而大幅增加训练负荷。

表 2 模型在不同比例尺与网格尺寸下的训练效率与几何精度对比

Tab.2 Comparison of the source building polygons, manually simplified polygons, and model-generated polygons

参数	目标比例尺	网格尺寸			目标比例尺	网格尺寸		
		0.2 mm	0.3 mm	0.5 mm		0.2 mm	0.3 mm	0.5 mm
训练时间/min		2650	2130	1980		2730	2440	1802
训练损失值		0.43	0.035	0.039		0.54	0.13	0.13
验证损失值	1 :	0.45	0.038	0.043	1 :	0.54	0.14	0.14
一致率/(%)	5000	32.0	92.3	90.6	10 000	34.3	94.3	92.1
面积增量/(%)		-0.14	0.14	0.23		-0.20	0.21	0.32
直角率/(%)		93.3	96.7	97.0		89.8	97.2	97.8

综合来看,考虑到验证集一致性对模型性能的关键影响,以及原始数据比例尺为 1:2000 对几何表达精度的要求,本文确定 0.3 mm 为最优网格尺寸。

图 6(a)、(b)、(c)分别展示了模型在 0.2、0.3 与 0.5 mm 网格尺寸下,执行 1:2000 至 1:5000 比例尺化简任务时训练集与验证集的损失函数收敛情况。横轴以 epoch 为单位,纵轴为交叉熵损失值。可见在 3 种网格设定下,训练集与验证集的损失均呈现同步下降,模型在初始阶段收敛迅速,随后逐渐趋缓。约在 80、20、20 个 epoch 后,损失均降至较

低水平,表明模型已充分收敛。结合表 2 的验证集一致率(即模型输出与人工结果几何匹配的比率)可进一步分析如下:在 0.2 mm 网格下,模型在 1:5000 与 1:10 000 任务中的一致率分别为 32.0% 与 34.3%,表现较差,未达到实用要求。在 0.3 mm 网格下,两项任务的一致率分别提升至 92.3% 与 94.3%,说明绝大多数建筑的化简结果与人工综合高度一致。而在 0.5 mm 网格下,一致率分别为 90.6% 与 92.1%,略低于 0.3 mm 网格;同时该网格对应的点位精度损失也较大(表 1),因此综合性能不及 0.3 mm 网格。




图 6 多边形化简大模型训练精度与验证精度的收敛

Fig.6 Convergence of the training and validation accuracy for the building polygon simplification model

图 7 展示了验证集中某区域在 0.3 mm 网格模型下,由 1:2000 分别化简至 1:5000 与 1:10 000 比例尺的结果。可以观察到,随着目标比例尺的减小,模型输出的建筑轮廓逐渐呈现出更为明显的正交化与规则化趋势,符合地图综合中对建筑物化简的基本要求。表 3 进一步对比了验证集中 20 个代表性建筑多边形的人工化简与模型化简结果,同时也对标注模型输出与人工结果的一致性

进行了评估。分析表明:前 10 个样本中,模型输出与人工化简完全一致;后 10 个样本中,两者存在一定差异。其中,前 5 个样本的模型结果虽与人工方式不同,但化简效果仍符合规范要求,属于可接受的有效结果;而后 5 个样本则出现局部扭曲或结构不合理等错误,无法直接使用,需后续人工干预修正。


















图 7 验证区模型化简的局部区域

Fig.7 Partial map of the validation area after model simplification

表 3 源建筑多边形、人工化简多边形及模型生成多边形的对比

Tab.3 Comparison diagram of the source building polygons, manually simplified polygons and model-generated polygons

序号	原始要素	人工综合	模型综合	一致性评价	序号	原始要素	人工综合	模型综合	一致性评价
1				Y Y	11				N Y
2				N Y					N Y
3				N Y					N Y
4				N Y					N N
5				N Y					N N
6				N N					N N
7				N N					N N
8				N N					N N
9				N N					N N
10				Y Y	20				N N


3.3 模型泛化能力分析

为评估模型的泛化能力,本文选取北京市某区域(图 8 中绿色多边形标识范围)的建筑多边形作为测试对象,其中红色多边形区域作为验证集。基于 3.1 节所构建的预训练模型,对该区域数据进行了全参数微调。图 9 展示了微调过程中训练集与验证集的损失收敛曲线。可见,模型在经过约 20 个训练周期后,训练损失与验证损失均降至较低水平,总

微调时长为 430 min。值得关注的是,微调开始时训练集与验证集的初始损失值分别为 5.3 和 5.4,显著低于原始模型在自身数据集上的初始损失(图 5(b)中约为 10.4)。这一差异反映出新区域与原始训练区域在建筑多边形空间模式上存在明显不同,也说明未经微调的原始模型难以直接适用于新区域。对比图 5(b)与图 9 可进一步发现,新区域上的初始损失较低,结合微调过程中模型收敛速度

快、所需训练时间短的特点,表明预训练模型已具备一定的跨区域迁移能力,能够有效提升在新目标区域上的训练效率。经微调后,模型在验证集上表现出优异的化简准确性,其输出与人工化简结果的

一致性达到 99.6%。图 10 展示了验证区域内部分建筑多边形的化简效果。放大后的视图清晰表明了模型在化简过程中有效地融入了正交化、形状相似性保持及面积稳定性等多重人工综合原则。



注:红框内为验证数据。

图 8 北京研究区域
Fig.8 Beijing study area





图 9 模型微调训练精度与验证精度的收敛
Fig.9 The convergence during fine-tuning of the model



(a) 原始数据 (b) 模型化简
图 10 北京试验部分区多边形化简效果

Fig.10 Effect of polygon simplification in the Beijing experimental area

3.4 与 LSTM 模型的比较试验

为验证本文模型,构建了一个长短期记忆网络(LSTM)模型作为对比。该 LSTM 模型在参数配置上参考了 1.2 节所述并在 3.2 节使用的 0.3 mm 网格 Transformer 模型:输入层结构为[batch,51],

词汇表大小设为 250 002,嵌入维度为 516,LSTM 堆叠层数为 12,隐藏层维度为 516,Dropout 概率设为 0.2,输出层用于预测词汇表中各词元的概率分布,模型总参数量约为 1.5×10^8 ,其结构如图 11 所示。




图 11 LSTM 模型的结构
Fig.11 The structure of LSTM model

使用 3.2 节中 0.3 mm 网格尺寸的数据集对 LSTM 模型进行训练与评估。图 12 展示了其训练收敛过程,可见模型在约 40 个训练周期后损失逐渐稳定,最终训练损失与验证损失均收敛于 2.1。然而,模型在验证集上的输出与人工化简结果的一致率仅为 13.7%,表明该 LSTM 模型未能有效学习建筑多边形的化简规律,其输出结果不具备实用价值。该结果从侧面印证了本文所构建的 Transformer 模型在捕捉建筑多边形内部空间结构与几何模式方面具有显著优势,其性能明显优于传统序列建模方法。




图 12 LSTM 模型训练收敛

Fig.12 The LSTM model convergence

4 分析与讨论

本文提出了一种基于 Transformer 架构的建筑多边形化简模型,其核心创新在于构建了“几何-符号-序列”的转换框架。该框架通过网格离散化预处理,将建筑多边形的连续坐标映射为离散符号序列,实质上构建了能够描述建筑形态的“词元”词汇表。这一设计有效契合了 Transformer 对离散化输入的结构要求,但也需合理设定网格尺寸,以在计算效率与地图表达精度之间取得平衡。模型的核心处理机制依托 Transformer 的掩码自注意力,有效捕捉多边形中的结构特征,并依据顶点顺序逐步生成简化后的多边形序列。该生成方式与人工作业中“逐步优化轮廓”的认知逻辑高度一致,从而实现了从原始几何序列到目标简化序列的端到端智能映射。

在试验过程中,Tokenization 步骤网格尺寸的设定对模型性能具有关键影响,其选择直接关系到模型参数量、训练耗时与最终化简精度。综合顾及模型效率与精度需求,大小为 0.3 mm 的网格被证

实能够有效满足 1:5000 与 1:10 000 比例尺下的建筑多边形化简要求。在不同的目标比例尺下,该模型均能以可控的参数量实现高效化简,不仅能够准确捕捉直角性、正交轮廓等关键几何特征,更重要的是,模型能够从数据中学习制图人员的隐式综合规范,而非依赖预定义的显式几何规则。在化简质量方面,模型在面积一致性、形状相似性与直角化等核心目标上表现优异:在包含 18 万个建筑多边形的洛杉矶验证集上,1:5000 与 1:10 000 比例尺化简前后的面积变化率均低于 1.0%;由表 4 可知,模型通过“削凸补凹”策略有效维持了面积平衡;最终输出的多边形直角化率均高于 96.0%。定量结果与典型样例共同表明,该模型已具备学习并模拟专业制图人员在人造地物化简中所采用综合策略的能力。

在验证过程中,部分模型输出的化简结果虽与人工标注的目标形态不完全一致,但其几何质量仍符合制图规范要求,因而被判定为可接受案例。这一现象揭示了人工综合过程中存在的主观性与随机性:即便是同一建筑要素,在不同轮次的综合操作中亦可能产生形态差异。此类人工标注的不确定性,客观上为模型学习过程引入了噪声。值得指出的是,模型所生成的化简结果,本质上并非对某一样本的机械复制,而是对训练集中大量相似形态样本所隐含的化简策略进行综合学习后的体现。因此,其输出往往表现为对多种“合理”人工化简模式的融合与折中。进一步分析表明,验证集中部分错误案例实际上源于人工综合结果本身存在的模糊性或逻辑矛盾。

表 4 综合前后建筑多边形面积差异比较

Tab.4 Comparison of building polygon area differences before and after generalization

序号	化简对比图	面积差百分比 / (%)	序号	化简对比图	面积差百分比 / (%)
1		-1.2	6		1.0
2		2.6	7		-3.0
3		-1.4	8		3.4
4		0.5	9		0.8
5		2.8	10		1.7

本文框架与以往主要基于判别式模型的地图

综合深度学习方法不同,实际上是属于生成式模型的范畴。该模型主要基于一项核心认知,即建筑多边形的空间特征在本质上蕴含于其几何坐标序列的有序结构中,而无须依赖传统方法中繁复的人工特征工程。通过直接学习离散化后的坐标序列,模型实现了从原始序列到简化序列的端到端映射,从而完成了建筑多边形的智能化简任务。这一生成式建模路径展现出多方面的优势:①通过直接对坐标序列进行建模,有效规避了人工设计特征的瓶颈,显著提升了对复杂建筑形态的捕捉能力;②由于直接处理原始坐标序列,模型具备良好的算法兼容性,能够无缝集成各类传统化简算法的输出结果,从而为构建具有广泛代表性的训练数据集奠定基础。尤为关键的是,模型的有效性在 LSTM 对比试验中得到进一步验证,这突显了本文框架的实用价值,也展现了其潜在的泛化能力。

5 结 语

本文提出了一种基于 Transformer 框架的的建筑多边形化简模型,将 Transformer 架构与词元化技术引入地理空间数据处理领域。通过将建筑多边形映射至固定尺寸的网格空间并进行规范化表示,模型将原始几何坐标转化为适于 Transformer 处理的序列格式,实现了端到端的建筑多边形自动

化简。试验结果表明,采用 0.3 mm 网格尺寸的模型所生成的化简结果与人工综合成果高度一致,一致率达 92.0%,显示出其在模拟人类专家化简策略方面的优越性能。本文研究表明,大模型具备从海量数据中隐式学习专业知识的能力,能够有效捕捉建筑多边形的化简规律,从而降低地图生产过程中对人工经验的依赖。通过将语言模型的核心技术迁移至空间几何数据处理,并结合网格化与词元化方法,解决了多边形数据与 Transformer 架构的适配问题,为人工智能在地图综合中的深度应用开辟了新路径。

然而,本文仍存在若干局限性:模型在面对不同类型或结构复杂的建筑多边形时的适应能力尚未充分验证,可能影响其实际适用范围;对模型泛化能力的分析仍显不足,特别是在分布外数据上的表现有待进一步评估。为提升模型的稳健性与泛化能力,后续研究可从以下方面推进:①引入建筑形态学分类体系,以指导训练样本的筛选与标注流程,提升样本的一致性与代表性;②采用规模更大的训练数据集,以覆盖更丰富的建筑形态变化与综合可能性;③探索参数量级更大的模型架构,以增强其对复杂空间模式的学习能力与歧义消解能力。本文为地理信息科学与人工智能的交叉融合提供了一种思路,在空间数据智能处理方面展现出广阔的应用前景。

参考文献

- [1] 王家耀,孙群,王光霞,等.地图学原理与方法[M]. 2版. 北京:科学出版社,2014.
WANG Jiayao, SUN Qun, WANG Guangxia, et al. Principle and method of cartography[M]. 2nd ed. Beijing: Science Press, 2014.
- [2] WANG Zeshen, LEE D. Building simplification based on pattern recognition and shape analysis[C] //Proceedings of the 9th International Symposium on Spatial Data Handling. Beijing:[s.n.], 2000: 58-72.
- [3] 尹烁,闫小明,晏雄锋.基于特征边重构的建筑物化简方法[J].测绘学报,2020,49(6):703-710. DOI: 10.11947/j. AGCS. 2020.20190299.
YIN Shuo, YAN Xiaoming, YAN Xiongfeng. Simplification method of building polygon based on feature edges reconstruction[J]. Acta Geodaetica et Cartographica Sinica, 2020, 49(6): 703-710. DOI: 10.11947/j. AGCS. 2020.20190299.
- [4] SESTER M. Generalization based on least squares adjustment[C] //Proceedings of 2000 International Archives of Photogrammetry and Remote Sensing. Amsterdam: International Society for Photogrammetry & Remote Sensing, 2000: 931G938.
- [5] 刘鹏程,艾廷华,邓吉芳.基于最小二乘的建筑物多边形的化简与直角化[J].中国矿业大学学报,2008,37(5):699-704.
LIU Pengcheng, AI Tinghua, DENG Jifang. Simplification and rectangularity of building polygon based on least squares adjustment[J]. Journal of China University of Mining and Technology, 2008, 37(5): 699-704.
- [6] 许文帅,龙毅,周侗,等.基于邻近四点法的建筑物多边形化简[J].测绘学报,2013,42(6):929-936.
XU Wenshuai, LONG Yi, ZHOU Tong, et al. Simplification of building polygon based on adjacent four point method[J]. Acta Geodaetica et Cartographica Sinica, 2013, 42(6): 929-936.
- [7] 李俐俐,李成名,卢小平,等.顾及邻近五点的建筑物多边形化简方法[J].测绘通报,2019(3):41-45.
LI Lili, LI Chengming, LU Xiaoping, et al. Simplification of building polygon based on adjacent five-point method[J]. Bulletin of surveying and mapping, 2019(3): 41-45.
- [8] RAINSFORD D, MACKANESS W. Template matching in support of generalization of rural buildings[M] //RICHARDSON D E, VAN OOSTEROM P. Advances in spatial data handling. Berlin: Springer, 2002: 137-151.

- [9] 刘鹏程, 艾廷华, 胡晋山, 等. 基于原型模板形状匹配的建筑多边形化简[J]. 武汉大学学报(信息科学版), 2010, 35(11): 1369-1371.
LIU Pengcheng, AI Tinghua, HU Jinshan, et al. Building-polygon simplification based on shape matching of prototype template[J]. Geomatics and Information Science of Wuhan University, 2010, 35(11): 1369-1372.
- [10] AI Tinghua, CHENG Xiaoqiang, LIU Pengcheng, et al. A shape analysis and template matching of building features by the Fourier transform method[J]. Computers, Environment and Urban Systems, 2013, 41: 219-233.
- [11] YAN X, AI T, ZHANG X. Template matching and simplification method for building features based on shape cognition[J]. International Journal of Geo-Information, 2017, 6(8): 250.
- [12] 晏雄锋, 艾廷华, 杨敏. 居民地要素化简的形状识别与模板匹配方法[J]. 测绘学报, 2016, 45(7): 874-882. DOI: 10.11947/j.AGCS.2016.20150162.
YAN Xiongfeng, AI Tinghua, YANG Min. A simplification of residential feature by the shape cognition and template matching method[J]. Acta Geodaetica et Cartographica Sinica, 2016, 45(7): 874-882. DOI: 10.11947/j.AGCS.2016.20150162.
- [13] 郭仁忠, 艾廷华. 制图综合中建筑物多边形的合并与化简[J]. 武汉测绘科技大学学报, 2000, 25(1): 25-30.
GUO Renzhong, AI Tinghua. Simplification and aggregation of building polygon automatic map generalization[J]. Journal of Wuhan Technical University of surveying and Mapping, 2000, 25(1): 25-30.
- [14] 王辉连, 武芳, 张琳琳, 等. 数学形态学和模式识别在建筑多边形化简中的应用[J]. 测绘学报, 2005, 34(3): 269-276.
WANG Huilian, WU Fang, ZHANG Linlin, et al. The application of mathematical morphology and pattern recognition to building polygon simplification[J]. Acta Geodaetica et Cartographica Sinica, 2005, 34(3): 269-276.
- [15] 武芳, 杜佳威, 钱海忠, 等. 地图综合智能化研究的发展与思考[J]. 武汉大学学报(信息科学版), 2022, 47(10): 1675-1687.
WU Fang, DU Jiawei, QIAN Haizhong, et al. Overview of research progress and reflections in intelligent map generalization[J]. Geomatics and Information Science of Wuhan University, 2022, 47(10): 1675-1687.
- [16] YAN X, YANG M, AI T. Deep learning in automatic map generalization: achievements and challenges[J]. Geo-Spatial Information Science, 2025: 1-22.
- [17] FENG Y, THIEMANN F, SESTER M. Learning cartographic building generalization with deep convolutional neural networks[J]. International Journal of Geo-Information, 2019, 8(6): 258.
- [18] YAN X, YANG M. A deep learning approach for polyline and building simplification based on graph autoencoder with flexible constraints[J]. Cartography and Geographic Information Science, 2024, 51(1): 79-96.
- [19] YANG M, YUAN T, YAN X, et al. A hybrid approach to building simplification with an evaluator from a backpropagation neural network[J]. International Journal of Geographical Information Science, 2022, 36(2): 280-309.
- [20] 晏雄锋, 袁拓, 杨敏, 等. 建筑物形状特征分析表达与自适应化简方法[J]. 测绘学报, 2022, 51(2): 269-278. DOI: 10.11947/j.AGCS.2020.20190299.
YAN Xiongfeng, YUAN Tuo, YANG Min, et al. An adaptive building simplification approach based on shape analysis and representation[J]. Acta Geodaetica et Cartographica Sinica, 2022, 51(2): 269-278. DOI: 10.11947/j.AGCS.2020.20190299.
- [21] HU Y, GOODCHILD M, YUAN M, et al. A five-year milestone: reflections on advances and limitations in GeoAI research[J]. Annals of GIS, 2024, 30(1): 1-14. DOI: 10.1080/19475683.2024.2309866.
- [22] 吴华意, 沈张骁, 侯树洋, 等. 大语言模型驱动的 GIS 分析: 方法、应用与展望[J]. 测绘学报, 2025, 54(4): 621-635. DOI: 10.11947/j.AGCS.2025.20240468.
WU Huayi, SHEN Zhangxiao, HOU Shuyang, et al. Large language model-driven GIS analysis: methods, applications, and prospects[J]. Acta Geodaetica et Cartographica Sinica, 2025, 54(4): 621-635. DOI: 10.11947/j.AGCS.2025.20240468.
- [23] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach: Curran Associates Inc., 2017: 5998-6008.
- [24] ZHU G, TANG M, MA Y, et al. LandGPT: a multimodal large language model for parcel-level land use classification with multi-source data[J]. International Journal of Geographical Information Science, 2025: 1-24.
- [25] LI H, XU C, YANG W, et al. Unsupervised multiview UAV image geo-localization via iterative rendering[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025, 63: 1-15.
- [26] DU J, WU F, YIN J, et al. Polyline simplification based on the artificial neural network with constraints of generalization knowledge[J]. Cartography and Geographic Information Science, 49(4): 313-337.
- [27] HUANG F, LÜ J R, LI G L, et al. SPOK: tokenizing geographic space for enhanced spatial reasoning in GeoAI[J]. International Journal of Geographical Information Science, 2025: 1-41. <https://doi.org/10.1080/13658816.2025.2497810>.

(责任编辑:陈品馨)

A Transformer model for building polygon simplification in map generalization

LIU Pengcheng^{1,2}, CHENG Xiaoqiang³, XIAO Tianyuan⁴, YANG Min⁴, AI Tinghua⁴

1. Key Laboratory for Geographical Process Analysis & Simulation of Hubei Province, Central China Normal University, Wuhan 430079, China;

2. School of Urban and Environmental Sciences, Central China Normal University, Wuhan 430079, China;

3. Faculty of Resources and Environmental Science, Hubei University, Wuhan 430062, China;

4. School of Resources and Environmental Sciences, Wuhan University, Wuhan 430079, China

Abstract: Addressing the issues in building polygon simplification within map generalization—such as reliance on manual rules, low automation, and difficulty in reusing existing simplification results—this paper proposes a building polygon simplification model based on the Transformer mechanism. The model begins by mapping building polygons into a grid space of a certain scale, representing coordinate strings of the polygons as grid sequences. This process allows the acquisition of Token sequences before and after simplification, thereby constructing paired datasets of building polygon simplification samples. Utilizing the Transformer architecture, the model learns dependencies between point sequences through its masked self-attention mechanism, ultimately generating new simplified polygons point by point to achieve building polygon simplification. During training, the model employs structured sample data and incorporates a cross-entropy loss function that ignores specific indices to enhance simplification quality. The experimental design consists of two parts: a main experiment and a generalization validation. The main experiment, based on the Los Angeles 1 : 2000 building dataset, encodes polygons using three grid sizes—0.2, 0.3, and 0.5 mm—to achieve simplifications at target scales of 1 : 5000 and 1 : 10 000. Results indicate that the model performs optimally with a grid size of 0.3 mm, achieving a consistency rate exceeding 92.0% with manual annotations on the validation set. A generalization experiment on building polygon data from parts of Beijing further verified the model's transferability. Comparative analysis with an LSTM model, under similar parameter scales, showed that the LSTM model failed to converge effectively and could not produce usable results. This study confirms the potential of Transformer in handling spatial geometric sequence tasks and demonstrates its ability to effectively reuse existing simplification samples. The proposed approach offers a new, engineering-practical pathway for intelligent building polygon simplification.

Key words: map generalization; buildings polygon simplification; Tokenization; Transformer model; context engineering

Foundation support: The National Natural Science Foundation of China (Nos. 42471486; 42071455); The Fundamental Research Funds for the Central Universities (No. CCNU25JC043)

First author: LIU Pengcheng (1968—), male, PhD, professor, majors in map generalization, spatial pattern recognition and GeoAI.

E-mail: liupc@ccnu.edu.cn