

基于预训练模型的矢量海岸线形态模式判别方法

杨 敏¹, 马宏然¹, 孔 博¹, 刘鹏程^{2,3}, 艾廷华¹

1. 武汉大学资源与环境科学学院, 湖北 武汉 430079;
2. 华中师范大学地理过程分析与模拟湖北省重点实验室, 湖北 武汉 430079;
3. 华中师范大学城市与环境科学学院, 湖北 武汉 430079

收稿日期: 2025-08-26; 修回日期: 2026-03-17

中图分类号: P208

文献标识码: A

文章编号: 1001-1595(2026)03-0404-11

基金项目: 国家自然科学基金(42471486; 42571519)

第一作者简介: 杨敏(1985—), 男, 教授, 研究方向为地理空间深度学习与智能制图。 E-mail: yangmin2003@whu.edu.cn

通信作者: 孔博 E-mail: bokong@whu.edu.cn

摘 要: 矢量海岸线形态模式判别对海岸演化监测、海洋灾害预警、沿海区域规划等具有重要意义, 也是海岸线制图表达的重要步骤。传统机器学习的判别方法依赖人工定义特征, 同时需要大量标注样本进行长周期训练。为此, 本文提出了海岸线通用几何特征学习与下游形态模式判别解耦的预训练模型方法。首先, 通过运用坐标系重置和坐标归一化操作, 将海岸线转化为适用于嵌入学习的 Token 序列。然后, 设计基于随机遮掩的自监督坐标预测任务, 结合基于 Transformer 的双向编码器表征模型构建海岸线通用几何特征学习的预训练模型。最后, 利用标注数据集微调模型, 迁移至海岸线形态模式判别任务。为了验证本文方法的有效性, 基于开源海岸线数据构建了包含 195 649 条样本的预训练数据集和 1000 条样本的标注数据集。试验结果表明, 本文方法在包含 5 种海岸线形态模式的判别任务中取得了 90.72% 的 F_1 值, 相较于 LSTM 和 1D-CNN 的方法提升了 7.31%~9.38%。

关键词: 矢量海岸线; 形态模式判别; 预训练模型; BERT 模型

海岸线是地图空间表达海岸特征的基本要素, 具有重要的资源价值和生态功能属性^[1]。由于受到各种自然因素和人类活动的影响, 海岸线在几何形态上呈现不同的模式结构。这些形态模式信息不仅反映了海岸性质, 如泥沙质海岸的岸线平缓圆滑、岩质海岸的岸线曲折生硬, 而且有助于揭示地质环境特点与海岸演化过程^[2], 对海岸带管理、海洋灾害预警、沿海区域规划等具有重要价值^[3-4]。因此, 地图制图过程中需要对海岸线形态特征进行准确分析与模式判别, 继而保持甚至增强不同区域海岸线的原有形态模式。

早期研究主要从几何学角度开展海岸线的形态特征描述与模式判别。文献[5—6]利用约束

Delaunay 三角网提取河口湾海岸线的骨架结构, 建立了海岸线几何特征的层次化表达模型。文献[7]从弯曲性、延展性和复杂度 3 个维度定义海岸线形态描述参量, 在此基础上运用贝叶斯模型构建模式判别方法。文献[8]运用分形几何理论解决海岸线形态复杂度的量化描述难题。然而, 上述方法大多依赖人工定义特征获取海岸线形态信息, 模式判别结果容易受到主观性因素影响。同时, 规则驱动及基于传统机器学习方法的判别模型泛化能力不足, 难以应对海岸线复杂多变的形态模式。

相比传统机器学习方法, 深度学习模型具备从原始数据直接学习特征的能力, 从而缓解对人工设计特征的依赖。同时, 深度学习模型的局部连接性

引文格式: 杨敏, 马宏然, 孔博, 等. 基于预训练模型的矢量海岸线形态模式判别方法[J]. 测绘学报, 2026, 55(3): 404-414. DOI:10.11947/j. AGCS. 2026. 20250352.
YANG Min, MA Hongran, KONG Bo, et al. A pre-trained model-based method for discriminating morphological patterns of vector-based coastlines[J]. Acta Geodaetica et Cartographica Sinica, 2026, 55(3): 404-414. DOI:10.11947/j. AGCS. 2026. 20250352.

特点和多层次卷积操作,与地物形态模式判别任务中强调的空间关联性和多尺度特征分析相互契合^[9]。因此,相关学者引入深度学习技术构建了面向不同类型地物的形态模式判别方法,包括建筑物形状分类模型^[10-13]、立交桥模式判别模型^[14-15]、河网分布模式判别模型^[16-17]、等高线表达的地貌类型判别模型^[18]等。文献[19]将海岸线剖分为一系列弯曲结构并定义相关描述特征,然后采用长短期记忆网络(long short-term memory, LSTM)建立判别模型。文献[20]将线状地图目标离散化表达为线元序列,以线元端点间的横纵坐标差为描述特征,运用一维卷积神经网络(one-dimensional convolutional neural network, 1D-CNN)构建线元特征学习模型,从而判别线状目标的不同几何形态类型。

上述深度学习模型依赖充足的标注样本数据,训练周期长且容易出现过拟合现象。相比较之下,预训练模型采用特征学习与下游任务解耦的策略,先利用深度神经网络在大规模无标注数据上学习通用特征,再通过标注数据微调以适配特定任务。一方面,预训练过程建立了高质量的模型初始参数,仅需少量标注数据微调即可适配下游任务,从而提升模型的稳健性和训练效率。另一方面,预训练模型广泛采用的 Transformer 架构具备出色的全局上下文感知能力,运用多头自注意力机制动态捕捉输入序列元素(Token)间的长程依赖关系,展现出优异的全局特征提取能力。这些特点使得预训练模型在自然语言处理^[21]、蛋白质结构预测^[22]等任务中广泛应用并取得巨大成功。海岸线作为由连续坐标点构成的序列数据,具备与 Transformer 结合的潜力。为此,本文引入基于 Transformer 的双向编码器表征(bidirectional encoder representations from Transformer, BERT)模型^[23]进行矢量海岸线数据预训练,在此基础上微调模型以适配形态模式分类任务,从而实现少量标注样本条件下对复杂海岸线形态模式的高效判别。

1 本文方法

本文方法的具体流程如图1所示。首先,依据预训练与微调的任务需求,分别构建预训练数据集和标注数据集。考虑到原始海岸线坐标差异过大,通过坐标系重置和坐标归一化操作重构海岸线坐标信息,将其转化为适用于嵌入学习的 Token 序列。然后,设计随机遮掩的自监督坐标预测任务,

结合 BERT 模型构建面向海岸线通用几何特征学习的预训练模型。最后,利用标注数据集对预训练模型进行微调,使其适配海岸线形态模式的判别任务。




图1 基于预训练模型的矢量海岸线形态模式判别方法

Fig. 1 A pre-trained model-based method for discriminating the morphological patterns of vector-based coastlines

1.1 海岸线的 Token 化处理

Token 化是将输入数据离散化为有意义的基片,便于后续预训练模型理解与计算。在自然语言处理任务中,Token 化表现为将文本切分成一系列 Token 单元(如词、子词或字符)。矢量海岸线同样可离散化为若干 Token 单元,如节点、直线段、特定长度弧段、弯曲结构^[24]。考虑到节点是海岸线最基本的构成单元,高层次形态特征隐含在节点序列上下文信息中,本研究将每个节点视为一个 Token 单元。

针对每个 Token 单元,采用节点坐标值作为特征向量。然而,不同区域海岸线原始节点的坐标值差异显著,不利于模型对几何形态特征的高效学习与提取^[25]。为此,首先实施坐标系重置和坐标归一化操作。如图2所示,假设构成某段海岸线的原始节点序列为 $\text{Seq} = \{p_1, p_2, \dots, p_n\}$, 每个节点 p_i 的坐标为 (x_i, y_i) , $i \in \{1, 2, \dots, n\}$, n 表示节点数量(即序列长度)。通过移动坐标原点位置和旋转坐标轴得到新的坐标系,其中坐标系原点移位至海岸线最小外接矩形的几何中心 $O(x_o, y_o)$, x 轴和 y 轴分别与最小外接矩形长轴和短轴方向一致。坐标系重置后,节点 p_i 的新坐标 $p'_i(x'_i, y'_i)$ 计算公式如下

$$\begin{bmatrix} x'_i \\ y'_i \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} x_i - x_o \\ y_i - y_o \end{bmatrix} \quad (1)$$

式中, θ 表示坐标轴的旋转角度。然后, 将 p'_i 的坐标值除以长度 R (即海岸线最小外接矩形对角线长度的一半) 进行归一化处理, 得到对应的 Token

$T_i = (x'_i/R, y'_i/R)$ 。通过上述操作, 获得海岸线 Token 序列 $T = (T_1, T_2, \dots, T_n)$ 。




图2 矢量海岸线的 Token 化处理过程

Fig. 2 Tokenization process of a vector-based coastline

考虑到 BERT 模型批处理训练时要求输入的 Token 序列具有固定长度, 当输入海岸线的节点序列长度大于预设长度时, 则预先进行分段处理。当输入海岸线的节点序列长度小于预设长度时, 则填充与终点坐标相同的虚拟节点并标记为 PAD。

1.2 海岸线预训练模型构建

面向海岸线几何特征学习的预训练模型如图 3 所示, 包括 Token 序列的随机遮掩、Token 嵌入学习、BERT 模型嵌入学习、Token 嵌入还原 4 个阶段。




图3 面向海岸线几何特征学习的预训练模型

Fig. 3 A pre-trained model for learning coastline geometric features

(1) Token 序列的随机遮掩。本文采用基于随机遮掩的自监督学习策略进行模型训练。具体地, 随机替换部分 Token 为特定掩码 (0, 0), 并将这些掩码记作 MASK, 后续通过遮掩 Token 的坐标预测任务实现对上下文信息的高效学习与提取。

(2) Token 嵌入学习。给定 Token 序列 $T = (T_1, T_2, \dots, T_n)$, 将其映射为对应的嵌入向量序列 $E = (E_1, E_2, \dots, E_n)$, 作为后续 BERT 模型的输入。每个 Token T_i 的嵌入向量 E_i 由坐标嵌入向量 A_i 和位置嵌入向量 B_i 相加得到, 如式 (2) 所示

$$E_i = A_i + B_i \quad (2)$$

式中, 坐标嵌入向量 A_i 通过一个 l 层全连接网络非线性映射而来。第 j 层 ($j \in \{1, 2, \dots, l\}$) 的输出 $A_{(i,j)}$ 由式 (3) 计算得到

$$A_{(i,j)} = \tanh(W_j A_{(i,j-1)} + b_j) \quad (3)$$

式中, $A_{(i,0)} = T_i$, 为输入向量; $A_{(i,j)}$ 为第 j 层的输出向量; W_j 和 b_j 分别为第 j 层的权重矩阵和偏置向量; $\tanh$ 为双曲正切激活函数。当 $j = l$ 时, 输出的 $A_{(i,l)}$ 即为坐标嵌入向量 A_i 。

位置嵌入向量 B_i 表达 T_i 在序列 T 的绝对和相对位置信息, 其第 j 个分量通过正弦位置编码函数^[26] 计算, 如式 (4) 所示

$$B_{(i,j)} = \begin{cases} \sin\left(\frac{i-1}{100^{\frac{j}{d}}}\right) & j \text{ 为偶数} \\ \cos\left(\frac{i-1}{100^{\frac{j-1}{d}}}\right) & j \text{ 为奇数} \end{cases} \quad (4)$$

式中, d 为位置嵌入向量 B_i 的维度; j 为分量索引, 且 $j \in \{1, 2, \dots, d\}$ 。

(3) BERT 模型嵌入学习。将嵌入向量序列 $E = (E_1, E_2, \dots, E_n)$ 输入 BERT 模型, 通过多个 Transformer 编码器学习 Token 间上下文信息, 进而优化每个 Token 的嵌入向量, 以实现海岸线几

何形态特征的提取。Transformer 编码器由多头注意力层和前馈神经网络层组成。多头注意力层借助自注意力机制捕捉序列中每个 Token 与其他 Token 之间的关系,其输入是序列 X^{nd} , 输出是 Token 之间的注意力矩阵 Z , n 和 d 分别表示序列长度和 Token 的嵌入向量维度。每个注意力头将 X^{nd} 与 3 个权重矩阵 W^Q 、 W^K 、 W^V 相乘得到查询矩阵 Q 、键矩阵 K 和数值矩阵 V 。给定注意力头的注意力矩阵 Z_i 根据式(5)计算

$$Z_i = \text{Softmax}(QK^T / \sqrt{d_k}) \times V \quad (5)$$

式中, K^T 为 K 的转置矩阵; d_k 表示键矩阵 K 的维度; QK^T 表示序列中 Token 间的初始相似度。经过 $1/\sqrt{d_k}$ 缩放并通过 Softmax 函数归一化后, 所得相似度乘以 V 可获得注意力矩阵 Z_i , 表示序列中各 Token 间的相关性。需要注意的是, W^Q 、 W^K 、 W^V 为随机初始化参数, 且通过训练和反向传播不断优化, 以更新注意力矩阵。

多头注意力层的多个注意力头可理解为从多个视角学习 Token 间的上下文信息, 可得到多个注意力矩阵 $Z_1, Z_2, \dots, Z_h$ 。这些矩阵被拼接后, 再乘以一个权重矩阵 W 以获得最终的注意力矩阵 $Z = \text{Concatenate}(Z_1, Z_2, \dots, Z_h) \times W$, h 为注意力头和注意力矩阵的数量。

前馈网络层以注意力矩阵为输入, 计算 Token 嵌入作为输出。该过程通过两个全连接层及激活函数实现, 激活函数对每个 Token 嵌入进行非线性变换, 以提升 Token 嵌入的表示能力及模型性能。BERT 模型将当前编码器输出的嵌入向量作为下一编码器的输入, 直至最后编码器输出优化后的 Token 嵌入向量。经过 BERT 模型嵌入学习, Token T_i 的嵌入向量 E_i 被更新为 E'_i 。

(4) Token 嵌入还原。借助全连接层将 $E' = (E'_1, E'_2, \dots, E'_n)$ 还原为二维向量 $T' = (T'_1, T'_2, \dots, T'_n)$ 。定义被遮掩 Token 的真实值与预测值之间的均方误差作为模型训练的损失函数, 计算公式如下

$$\text{MSE} = \frac{1}{|M|} \sum_{k \in M} \|T_k - T'_k\|^2 \quad (6)$$

式中, M 和 $|M|$ 分别为被遮掩 Token 的位置索引集合及集合中元素的数量。在此基础上, 通过反向传播更新模型参数, 包括 Token 嵌入学习阶段的全连接层、BERT 模型嵌入学习阶段的编码器、Token 嵌入还原阶段的全连接层参数。

1.3 适应海岸线形态模式判别的下游任务微调

完成自监督预训练后, 利用标注数据通过监督

学习进行模型微调, 使其适配海岸线形态模式的判别任务。如图 4 所示, Token 序列 $T = (T_1, T_2, \dots, T_n)$ 经预训练模型的 Token 嵌入学习与 BERT 模型嵌入学习阶段后, 输出嵌入向量序列 $E' = (E'_1, E'_2, \dots, E'_n)$; 然后, 将 E' 输入分类模块, 输出海岸线形态模式的判别结果。其中, 分类模块由平均池化层和全连接层构成, 前者对每个输入 Token 的 d 维嵌入向量取平均值, 输出一个 d 维的嵌入向量; 后者进一步将此嵌入向量非线性映射为概率向量 $\{P_1, P_2, \dots, P_s\}$, 对应于不同形态模式的概率值。




图4 适应海岸线形态模式判别的微调模块

Fig. 4 Fine-tuning module for coastline morphological pattern discrimination

鉴于预训练任务与下游任务在学习目标与特征分布上可能存在差异, 微调过程将协同更新预训练模型和分类模块的参数。其中, 损失值定义为海岸线形态模式的标注类别与模型预测类别的交叉熵损失, 计算公式如下


$$L = - \sum_{c=1}^s Y_c \ln(P_c) \quad (7)$$

式中, s 为类别总数; c 为类别索引; Y_c 为样本真实类别的 one-hot 编码分量(当样本的真实类别是 c 时取值为 1, 否则为 0); P_c 为模型预测样本属于类别 c 的概率。

2 试验分析与评价

2.1 试验数据与模型参数设置

试验数据为 OSMCoastline(<https://osmdata.openstreetmap.de/data/coastlines.html>)提供的全球矢量海岸线。采用通用横轴墨卡托投影,将海岸线经纬度坐标转换为平面投影坐标。然后,通过随机开窗策略提取 195 649 条海岸线样本构建预训练数据集,并按 8:2 随机划分为训练集和验证集。标注样本根据海岸线形态特点由人工提取得到,分为光滑型、粗糙型、狭长型、宽谷型和人工型(图 5)。标注数据集包含 1000 条海岸线样本,其中每种形态模式 200 条,并按 6:4 划分为训练集和测试集,分别用于模型微调 and 判别性能测试。



(a) 光滑型 (b) 粗糙型 (c) 狭长型 (d) 宽谷型 (e) 人工型

图 5 不同形态模式的海岸线

Fig. 5 Coastlines with different morphological patterns

在预训练模型中,参照 BERT-base 采用 12 层 Transformer 编码器^[23]。考虑到判别式任务的复杂度低于生成式任务,将嵌入维度设置为 256、注意力头数设为 4,从而兼顾特征建模能力与参数规模。输入 Token 序列长度设为 256,以覆盖大部分标注样本的节点数量。在 Token 嵌入学习与嵌入还原阶段各采用两层全连接网络,以实现坐标与嵌入向量的非线性映射,并控制计算开销。预训练过程的超参数设置如下:初始学习率 1×10^{-4} ,批次大小 1024,Dropout 为 0.1,优化器为常用的 Adam。大批次与较低学习率有助于训练稳定性与收敛效率,较小的 Dropout 有利于保持模型表达能力的同时增强泛化能力。鉴于标注样本规模有限,微调阶段将批次大小减至 64,并采用早停策略,以缓解过拟合风险。

2.2 预训练模型评价

图 6 展示了预训练过程中训练损失和验证损失的变化情况,两个损失值均先快速下降后趋于平稳,表明模型训练过程中逐渐达到稳定并收敛。同时,训练损失值曲线始终高于验证损失值曲线。这主要源于自监督训练过程中训练数据集的数据情形复杂多样,并且训练阶段采用 Dropout 策略屏蔽部分神经元导致学习难度提升,而验证阶段利用完整网络进行预测,使得验证损失值相对较低。




图 6 预训练过程的模型损失变化情况

Fig. 6 Changes of model losses during the pre-training process

图 7 展示了预训练模型对遮掩节点(对应于序列中被遮掩的 Token)的坐标预测结果。其中,坐标预测值的平均偏差为 19.93 m,表明预训练模型较好地还原了海岸线的几何位置信息。进一步分析发现,连续节点被遮掩的情形下坐标预测值的误差相对较大,但是真实海岸线的形态特征在预测节点分布上仍然得以体现。这表明通过自监督坐标预测任务,预训练模型能够较好地获取海岸线几何形态特征,为后续的形态模式判别奠定初始参数基础。

2.3 海岸线形态模式判别结果评价

在海岸线形态模式判别的试验中,将本文所提出的预训练模型(BERT 模型)与适用于处理序列数据的 1D-CNN^[27]和 LSTM^[28]模型方法进行对比。首先,将高维向量降维可视化技术 t-SNE^[29]应用于测试样本的序列嵌入向量,以分析其分布特点与聚类结构。如图 8 所示,BERT 模型获取的不同形态模式海岸线嵌入向量呈现出更显著的类内聚集性与类间分离性。为了定量评价聚类结果与真实标签的一致性,计算了 3 种方法所获取海岸线嵌入向量的调整兰德指数^[30](adjusted Rand index,ARI)。ARI 通过比较任意两个样本在真实标签和聚类结果中是否均为同一类,从而评价模型所学到的特征

空间是否让同类样本靠得更近、异类离得更远^[31-32]。ARI 计算公式如下

$$ARI = \frac{RI - E(RI)}{\max(RI) - E(RI)} \quad (8)$$

$$RI = \frac{TP + TN}{TP + FP + TN + FN} \quad (9)$$

式中,RI 为原始兰德指数; $E(RI)$ 为 RI 的期望; $\max(RI)$ 为根据实际数据分布计算得到的 RI 最大值;TP 为真实标签和聚类结果中均为同类的样本

对数;TN 为真实标签和聚类结果中均为不同类的样本对数;FP 为真实标签中为同类但聚类中不同类的样本对数;FN 为真实标签中不同类但聚类结果中同类的样本对数。ARI 的取值范围为 $[-1, 1]$, 值越大表示聚类结果与真实标签一致性越高。试验结果中,1D-CNN、LSTM 和 BERT 模型的 ARI 分别为 0.42、0.50 和 0.72,表明 BERT 模型能够更好地捕捉相同形态模式海岸线间的一致性与不同形态模式海岸线间的差异性。




图7 预训练模型对遮掩节点的坐标预测结果

Fig. 7 Coordinate prediction results for masked nodes by the pre-trained model




图8 3种方法学习获取的海岸线嵌入向量二维可视化结果

Fig. 8 Two-dimensional visualization results of coastline embedding vectors learned by three methods

表1列出了3种方法在测试集上的形态模式判别结果指标。BERT模型在整体性能上表现相对较好,其精准率、召回率和 F_1 值分别为90.83%、90.75%和90.72%,较1D-CNN和LSTM方法分别高出7.02%~9.07%、7.50%~9.25%和

7.31%~9.38%。图9展示的混淆矩阵进一步显示,BERT模型对5种类型海岸线模式判别的表现均优于对比方法。具体来看,3种方法对在光滑型和粗糙型海岸线的判别性能较为接近, F_1 值均达到86%;对狭长型、宽谷型和人工型这3类结构相

对复杂的海岸线,BERT模型的判别性能提升明显。

表 1 3种方法针对测试集海岸线形态模式判别的精准率、召回率与 F_1 值

Tab.1 Precision, recall, and F_1 score of the morphology pattern discrimination on the test dataset using three methods				%
方法	精准率	召回率	F_1 值	
1D-CNN	81.76	81.50	81.34	
LSTM	83.81	83.25	83.41	
BERT	90.83	90.75	90.72	

表 2 展示了 3 种方法判别结果的典型案例。案例 1 中狭长型海岸线因局部形态粗糙,被 LSTM 方法误判为粗糙型模式。这一结果与图 8(b)呈现的结果相符,即 LSTM 方法学习获得的粗糙型和狭长

型海岸线嵌入向量在特征空间中存在重叠。案例 2 展示的宽谷型海岸线在虚线区域形态较为粗糙,案例 3 展示的人工型海岸线局部呈现近似围合宽阔水域(虚线区域),被 1D-CNN 方法分别误判为粗糙型和宽谷型海岸线。上述案例需要综合考虑海岸线的局部和整体形态特征,1D-CNN 方法因卷积核的局部感受野限制,影响了其对海岸线全局结构的有效感知。类似地,LSTM 方法的顺序处理机制对序列内任意节点间关系的建模能力不足,导致其注重海岸线局部几何特征而忽略整体形态结构。相比之下,BERT 模型凭借自注意力机制可并行建模不同 Token 间的相关性,从而在嵌入向量中更好地兼顾局部细节与全局信息,使得其在海岸线形态模式判别任务中表现更佳。



图 9 3 种方法针对测试集海岸线形态模式判别的混淆矩阵

Fig. 9 Confusion matrices of coastline morphological pattern discrimination on the test dataset using three methods

表 2 海岸线形态模式判别的典型案例

Tab.2 Typical cases of coastline morphological pattern discrimination							%
案例	海岸线形态	方法	判别概率				
			光滑型	粗糙型	狭长型	宽谷型	人工型
案例 1 (狭长型)		1D-CNN	0.00	44.07	55.93	0.00	0.00
		LSTM	2.19	63.31	34.38	0.00	0.12
		BERT	0.00	13.24	86.76	0.00	0.00
案例 2 (宽谷型)		1D-CNN	0.00	57.04	0.22	41.05	1.69
		LSTM	2.48	33.19	1.30	61.05	1.98
		BERT	0.00	17.00	0.00	79.13	3.87
案例 3 (人工型)		1D-CNN	0.00	0.00	10.27	56.09	33.64
		LSTM	0.00	2.20	0.30	22.14	75.36
		BERT	0.00	1.66	0.17	0.00	98.17

同时,发现本文方法对部分复杂形态的海岸线判别能力不足。表 3 列出了两种代表性的案例。案

例 1 展示的海岸线人工标注为狭长型,由于混合了围合较宽水域的海岸线段(红色虚线处),被判别为

宽谷型。狭长型和宽谷型海岸线之间的误判,与海岸线演化过程中存在从狭长型到宽谷型的演变有关^[2]。具体来说,狭长型海岸线被侵蚀的过程中,开口区域逐渐扩大,向宽谷型海岸线演化,导致存在判别上的模糊性。案例 2 展示的海岸线为人工型,

由于分布大量尺寸较小的正交凹凸结构,曲线形态较为粗糙,被误判为粗糙型海岸线。这反映出构建的预训练模型在微观层次几何特征提取方面存在不足,需要在海岸线 Token 化方法及 Token 特征描述方面进行更加深入的探索。

表 3 本文方法的海岸线形态模式误判案例
Tab. 3 Typical cases of coastline morphological pattern misclassification using the proposed approach %

案例	海岸线形态	方法	判别概率				
			光滑型	粗糙型	狭长型	宽谷型	人工型
案例 1 (狭长型)		1D-CNN	0.00	9.46	15.72	68.31	6.51
		LSTM	0.00	7.22	28.25	64.53	0.00
		BERT	0.00	16.34	35.92	47.74	0.00
案例 2 (人工型)		1D-CNN	3.21	73.13	0.25	10.40	13.01
		LSTM	0.79	63.56	2.06	20.93	12.66
		BERT	0.00	84.04	0.00	0.00	15.96

2.4 讨 论

除了上述对比分析工作外,本文还测试了传统几何形态描述方法在海岸线模式判别任务上的表现。将矢量海岸线坐标展开为傅里叶级数,取前 50 项系数构成的向量作为傅里叶形状描述子,并输入支持向量机(support vector machine,SVM)进行形态模式判别^[10,33]。利用标注集样本训练 SVM 模型后,该方法在测试样本取得的 F_1 值为 73.76%,相比 1D-CNN、LSTM 和 BERT 模型分别低 7.58%、9.65%和 16.96%。除了受到训练样本规模不足因素的影响外,这种形态描述方法容易受到局部坐标抖动带来的干扰,从而容易导致形态模式判别不准确。

总体试验结果表明,在标注样本数量有限的情形下,本文方法在海岸线形态模式判别任务中优于传统几何描述方法及常规深度学习方法。本文方法采用“预训练-微调”策略,将“学什么”(通用特征)与“做什么”(形态判别)解耦,从而降低了对标注样本的需求,并且有助于模型的稳健性与可迁移性。另外,相较于 LSTM 和 1D-CNN 的局部感受野,BERT 模型通过自注意力机制捕捉序列内元素间的长程依赖关系,提升了对海岸线整体形态特征的识别能力。如图 8 所示,BERT 模型针对不同类型海岸线生成的序列嵌入向量,呈现更为显著的类内聚集与类间分离性,从而更好地支撑对形态模式的稳健判别。

此外,试验中分析了微调过程对于本文方法判

别性能的影响。具体地,对完成训练的预训练模型进行冻结,使其参数不再依据下游任务表现进行更新。考虑到预训练模型参数冻结后,仅下游分类模块中唯一的全连接层参数参与更新,可能导致判别模型的泛化能力受限。因此,在分类模块的平均池化层前增加两个全连接层。此时,对测试海岸线形态模式判别的精准率、召回率和 F_1 值分别为 85.56%、85.50%和 85.46%。结合表 1 可以发现,相比微调预训练模型参数情形 F_1 值下降了 5.26%。这表明解冻预训练参数并结合下游任务进行微调,对于提升模型在下游任务的表现具有重要作用。

3 结 论

针对矢量海岸线的形态模式判别问题,本文发展了特征学习与判别任务解耦的预训练方法。该方法充分利用 Transformer 出色的上下文感知能力,结合自监督学习策略实现对海岸线通用几何特征的高效学习,从而克服传统方法依赖大规模标注样本数据的难题。试验结果表明,该方法在少量标注样本的情形下能够实现海岸线形态模式的高效判别, F_1 值达到 90.72%,相比基于 LSTM 和 1D-CNN 模型的判别方法提升了 7.31%~9.38%。

为进一步提升海岸线形态模式判别性能,后续将围绕以下两个方面开展进一步研究:拓展模型支持判别的海岸线形态模式类型,构建更加完备的标

注数据集;优化海岸线 Token 化处理方法,构建具有显式地理意义的嵌入学习模型,从而提升对复杂形态模式的判别能力。此外,拟将本文方法应用到其他地物要素(如等高线、行政区界线、建筑物)的

模式判别任务,同时拓展其他下游任务(如分段、化简),探索建立基于预训练模型的矢量地图数据分析与处理方法体系。

参考文献

- [1] 骆永明. 中国海岸带可持续发展中的生态环境问题与海岸科学发展[J]. 中国科学院院刊, 2016, 31(10): 1133-1142.
LUO Yongming. Sustainability associated coastal eco-environmental problems and coastal science development in China[J]. Bulletin of the Chinese Academy of Sciences, 2016, 31(10): 1133-1142.
- [2] JOHNSON D W. Shore processes and shoreline development[M]. New York: Wiley, 1919: 159-190.
- [3] 修淳, 霍素霞, 姚海燕, 等. 注重新形势下自然岸线管控的海岸线分类体系探讨[J]. 地理科学, 2022, 42(2): 333-342.
XIU Chun, HUO Suxia, YAO Haiyan, et al. Coastline classification for strictly controlling natural coastline in the new era[J]. Scientia Geographica Sinica, 2022, 42(2): 333-342.
- [4] 贾建军, 蔡廷禄, 刘毅飞, 等. 考虑人类活动的海岸线分类体系: 近期浙江省海岸线调查的实践与思考[J]. 海洋科学, 2019, 43(10): 13-23.
JIA Jianjun, CAI Tinglu, LIU Yifei, et al. A classification of coastline considering the impacts of human activities: remarks on latest practices on coastline survey in Zhejiang province[J]. Marine Sciences, 2019, 43(10): 13-23.
- [5] AI Tinghua, ZHOU Qi, ZHANG Xiang, et al. A simplification of ria coastline with geomorphologic characteristics preserved[J]. Marine Geodesy, 2014, 37(2): 167-186.
- [6] 杜佳威, 武芳, 李靖涵, 等. 一种河口湾海岸线渐进化简方法[J]. 测绘学报, 2018, 47(4): 547-556. DOI: 10. 11947/j. AGCS. 2018. 20170440.
DU Jiawei, WU Fang, LI Jinghan, et al. A progressive simplification method for the estuary coastline[J]. Acta Geodaetica et Cartographica Sinica, 2018, 47(4): 547-556. DOI: 10. 11947/j. AGCS. 2018. 20170440.
- [7] 刘鹏程, 杨琴. 贝叶斯模型下面向地图表达的海岸线分段模型[J]. 计算机工程与应用, 2016, 52(22): 174-179.
LIU Pengcheng, YANG Qin. Coastline segment model research for map generalization based on Bayesian method[J]. Computer Engineering and Applications, 2016, 52(22): 174-179.
- [8] MANDELBROT B. How long is the coast of Britain statistical self-similarity and fractional dimension[J]. Science, 1967, 156(3775): 636-638.
- [9] 艾廷华. 深度学习赋能地图制图的若干思考[J]. 测绘学报, 2021, 50(9): 1170-1182. DOI: 10. 11947/j. AGCS. 2021. 20210091.
AI Tinghua. Some thoughts on deep learning enabling cartography[J]. Acta Geodaetica et Cartographica Sinica, 2021, 50(9): 1170-1182. DOI: 10. 11947/j. AGCS. 2021. 20210091.
- [10] 刘鹏程, 黄欣, 马宏然, 等. 建筑物多边形高精度识别的傅里叶形状描述子神经网络方法[J]. 测绘学报, 2022, 51(9): 1969-1976. DOI: 10. 11947/j. AGCS. 2022. 20210730.
LIU Pengcheng, HUANG Xin, MA Hongran, et al. Fourier descriptor-based neural network method for high-precision shape recognition of building polygon[J]. Acta Geodaetica et Cartographica Sinica, 2022, 51(9): 1969-1976. DOI: 10. 11947/j. AGCS. 2022. 20210730.
- [11] 晏雄锋, 袁拓, 杨敏, 等. 建筑物形状特征分析表达与自适应化简方法[J]. 测绘学报, 2022, 51(2): 269-278. DOI: 10. 11947/j. AGCS. 2022. 20210302.
YAN Xiongfeng, YUAN Tuo, YANG Min, et al. An adaptive building simplification approach based on shape analysis and representation[J]. Acta Geodaetica et Cartographica Sinica, 2022, 51(2): 269-278. DOI: 10. 11947/j. AGCS. 2022. 20210302.
- [12] 于洋洋, 贺康杰, 武芳, 等. 面状居民地形状分类的图卷积神经网络方法[J]. 测绘学报, 2022, 51(11): 2390-2402. DOI: 10. 11947/j. AGCS. 2022. 20210134.
YU Yangyang, HE Kangjie, WU Fang, et al. Graph convolution neural network method for shape classification of areal settlements[J]. Acta Geodaetica et Cartographica Sinica, 2022, 51(11): 2390-2402. DOI: 10. 11947/j. AGCS. 2022. 20210134.
- [13] 张付兵, 孙群, 马京振, 等. 融合全局和局部特征的建筑物形状智能分类方法[J]. 测绘学报, 2024, 53(9): 1842-1852. DOI: 10. 11947/j. AGCS. 2024. 20240040.
ZHANG Fubing, SUN Qun, MA Jingzheng, et al. An intelligent classification method for building shape based on fusion of global and local features[J]. Acta Geodaetica et Cartographica Sinica, 2024, 53(9): 1842-1852. DOI: 10. 11947/j. AGCS. 2024. 20240040.
- [14] YANG Min, JIANG Chenjun, YAN Xiongfeng, et al. Detecting interchanges in road networks using a graph convolutional network approach[J]. International Journal of Geographical Information Science, 2022, 36(6): 1119-1139.
- [15] 何海威, 钱海忠, 谢丽敏, 等. 立交桥识别的 CNN 卷积神经网络法[J]. 测绘学报, 2018, 47(3): 385-395. DOI: 10. 11947/j. AGCS. 2018. 20170265.
HE Haiwei, QIAN Haizhong, XIE Limin, et al. Interchange recognition method based on CNN[J]. Acta Geodaetica et Cartographica Sinica, 2018, 47(3): 385-395. DOI: 10. 11947/j. AGCS. 2018. 20170265.

- ca,2018,47(3):385-395. DOI:10.11947/j. AGCS. 2018. 20170265.
- [16] YU Huafei, AI Tinghua, Yang Min, et al. A recognition method for drainage patterns using a graph convolutional network[J]. International Journal of Applied Earth Observation and Geoinformation, 2022, 107: 102696.
- [17] 余华飞,邱天奇,周哲,等. 图 Transformer 支持下的河网模式识别[J]. 测绘学报, 2024, 53(11): 2075-2085. DOI: 10.11947/j. AGCS. 2024. 20230582.
- YU Huafei, QIU Tianqi, ZHOU Zhe, et al. Drainage pattern recognition supported by graph Transformer[J]. Acta Geodaetica et Cartographica Sinica, 2024, 53(11): 2075-2085. DOI: 10.11947/j. AGCS. 2024. 20230582.
- [18] 孔博,艾廷华,杨敏,等. 等高线形态知识与图神经网络联合作用下的黄土地貌类型识别[J]. 测绘学报, 2024, 53(6): 1154-1164. DOI: 10.11947/j. AGCS. 2024. 20230445.
- KONG Bo, AI Tinghua, YANG Min, et al. Identification of loess landform types jointly affected by contour morphological knowledge and the graph neural network [J]. Acta Geodaetica et Cartographica Sinica, 2024, 53(6): 1154-1164. DOI: 10.11947/j. AGCS. 2024. 20230445.
- [19] GAO Aji, AI Tinghua, YU Huafei, et al. A vector-based coastline shape classification approach using sequential deep learning model[J]. International Journal of Applied Earth Observation and Geoinformation, 2024, 129: 103810.
- [20] 杨敏,陈果,李连营,等. 序列卷积神经网络支持下线状地图目标的分段方法[J]. 测绘学报, 2023, 52(1): 108-116. DOI: 10.11947/j. AGCS. 2023. 20210317.
- YANG Min, CHEN Guo, LI Lianying, et al. Segmentation of linear map objects using sequential convolutional neural network [J]. Acta Geodaetica et Cartographica Sinica, 2023, 52(1): 108-116. DOI: 10.11947/j. AGCS. 2023. 20210317.
- [21] PATWARDHAN N, MARRONE S, SANSONE C. Transformers in the real world: a survey on NLP applications[J]. Information, 2023, 14(4): 242.
- [22] SCHMIRLER R, HEINZINGER M, ROST B. Fine-tuning protein language models boosts predictions across diverse tasks[J]. Nature Communications, 2024, 15(1): 7407.
- [23] DEVLIN J, CHANG M-W, LEE K, et al. Bert: pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Minnesota: Association for Computational Linguistics, 2019: 4171-4186.
- [24] YAN Xiongfeng, YANG Min, AI Tinghua. Deep learning in automatic map generalization: achievements and challenges[J]. Geo-spatial Information Science, 2025, 28(6): 2905-2926.
- [25] MIKOLOV T, SUTSKEVER I, CHEN K, et al. Distributed representations of words and phrases and their compositionality[C]//Proceedings of the 27th Annual Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2013: 3111-3119.
- [26] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6000-6010.
- [27] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [28] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [29] VAN DER MAATEN L. Accelerating t-SNE using tree-based algorithms[J]. The Journal of Machine Learning Research, 2014, 15(1): 3221-3245.
- [30] HUBERT L, ARABIE P. Comparing partitions[J]. Journal of Classification, 1985, 2(1): 193-218.
- [31] VINH N X, EPPS J, BAILEY J. Information theoretic measures for clusterings comparison: variants, properties, normalization and correction for chance[J]. Journal of Machine Learning Research, 2010(11): 2837-2854.
- [32] STEINLEY D. Properties of the hubert-arabie adjusted rand index[J]. Psychological Methods, 2004, 9(3): 386-396.
- [33] 刘鹏程,艾廷华,杨敏. 基于傅里叶级数的等高线网络渐进式传输模型[J]. 测绘学报, 2012, 41(2): 284-290.
- LIU Pengcheng, AI Tinghua, YANG Min. The internet progressive transmission model for contour based on Fourier series[J]. Acta Geodaetica et Cartographica Sinica, 2012, 41(2): 284-290.

(责任编辑:陈品馨)

A pre-trained model-based method for discriminating morphological patterns of vector-based coastlines

YANG Min¹, MA Hongran¹, KONG Bo¹, LIU Pengcheng^{2,3}, AI Tinghua¹

1. School of Resource and Environmental Sciences, Wuhan University, Wuhan 430079, China;

2. Key Laboratory for Geographical Process Analysis & Simulation of Hubei Province, Central China Normal University, Wuhan 430079, China;

3. College of Urban and Environmental Sciences, Central China Normal University, Wuhan 430079, China

Abstract: Discriminating the morphological patterns of vector-based coastlines is vital for monitoring coastal evolution, marine disaster forecasting, and coastal zone planning, and it also serves as an important step in coastline cartography. Discriminating methods based on traditional machine learning technique rely on manually defined features and require large amounts of labeled samples with long-term training. To overcome these drawbacks, this study proposes a pre-trained model-based method that decouples generic geometric feature learning of coastlines from downstream morphological pattern discrimination. First, the coastlines are represented as Token sequences suitable for embedding learning using the operations of coordinate system resetting and coordinate normalization. Then, a self-supervised coordinate prediction task based on random masking is designed and integrated into the BERT model to construct a pre-trained model for the embedding learning of coastline geometric features. Finally, the pre-trained BERT model is fine-tuned with labeled dataset and transferred to the morphological pattern discrimination task. Based on open-source coastline data, a pre-trained dataset containing 195 649 samples and a labeled dataset with 1000 samples were collected. The proposed method achieves an F_1 score of 90.72% in a discrimination task involving five types of coastline morphological patterns, outperforming methods based on LSTM and 1D-CNN by 7.31%~9.38%.

Key words: vector-based coastline; morphological pattern discrimination; pre-trained model; BERT model

Foundation support: The National Natural Science Foundation of China (Nos. 42471486; 42571519)

First author: YANG Min(1985—), male, professor, majors in geospatial deep learning and intelligent cartography.

E-mail: yangmin2003@whu.edu.cn

Corresponding author: KONG Bo

E-mail: bokong@whu.edu.cn