

引文格式:周洋,孙潇萌,陶然,等. 利用地理流时空相关性分析揭示人群移动规律[J]. 测绘通报, 2024(10): 125-131. DOI:10.13474/j.cnki.11-2246.2024.1021.

利用地理流时空相关性分析揭示人群移动规律

周 洋^{1,2}, 孙潇萌^{1,2}, 陶 然³, 刘鹏程^{1,2}, 郑文升^{1,2}

(1. 地理过程分析与模拟湖北省重点实验室, 湖北 武汉 430079; 2. 华中师范大学城市与环境科学学院, 湖北 武汉 430079; 3. 南佛罗里达大学, 美国 坦帕 33606)

摘要: 人群移动流具有时空依赖特征, 识别和定量刻画其时空相关性是揭示人群移动规律和对其进行模拟预测的基础。本文通过对比和讨论流的空间自相关和时空自相关分析方法, 探索在城市内部和省际两个不同空间尺度下的人群移动流时空依赖特征及其集聚模式。结果表明: ①城市内部和省际的人群移动流均表现出强时空依赖性; ②城市内部和省际人群移动流的高-高模式均以短距离流为主, 低-低模式则是跨组团的远距离流; ③相比于仅考虑空间依赖, 同时考虑时间和空间依赖可以有效捕捉跨区域移动流, 这在省际移动流的集聚模式分析中尤为重要; ④时空相关性中的高-低和低-高模式可以识别流量随时间变化剧烈的流, 有助于进一步揭示局部区域的异常流模式。本文结论进一步强调了时空相关性的优势及特点, 可丰富地理流的探索性分析方法, 服务于人群动态观测的移动规律和模式特征挖掘。

关键词: 人群移动流; 时空依赖; 时空相关性; 集聚模式

中图分类号: P208

文献标识码: A

文章编号: 0494-0911(2024)10-0125-07

Measuring spatio-temporal autocorrelation in flow data to explore human mobility patterns

ZHOU Yang^{1,2}, SUN Xiaomeng^{1,2}, TAO Ran³, LIU Pengcheng^{1,2}, ZHENG Wensheng^{1,2}

(1. Key Laboratory for Geographical Process Analysis & Simulation of Hubei Province, Wuhan 430079, China; 2. College of Urban and Environmental Sciences, Central China Normal University, Wuhan 430079, China; 3. School of Geosciences, University of South Florida, Tampa 33606, USA)

Abstract: Human mobility flows are spatio-temporal dependent. The identifying and measuring the spatio-temporal autocorrelation in flows are critical in uncovering human mobility patterns and building prediction models. This study compares and discusses methods of spatial auto-correlation (SFlowLISA) and spatio-temporal auto-correlation (STFlowLISA) to explore spatio-temporal dependencies and aggregation patterns buried in intra-urban and inter-provincial human mobility flows. The results show that: ① Spatio-temporal dependencies are significant in both intra-urban and inter-provincial human mobility flows. ② Notably, we observe that flows show high-high (HH) patterns are those short-distance travels, while flows with low-low (LL) patterns are those long-distance travels across regions. ③ Specifically, involving both temporal and spatial dependence can effectively capture inter-regional mobility flows than merely measuring spatial dependence. This is particularly important in aggregation patterns of inter-provincial human mobility flows. ④ Furthermore, flows with high-low (HL) and low-high (LH) patterns show sharp temporal fluctuation. This characteristic is helpful to identify local outliers in massive flows. Overall, this study emphasizes the advantage and importance of measuring spatio-temporal autocorrelation when analyzing flow data using two typical case studies. The results will benefit the understanding of human mobility patterns and unveiling the auto-correlation characteristics using effective exploratory analysis of STFlowLISA.

Key words: human mobility flow; spatio-temporal dependence; spatio-temporal autocorrelation; aggregation patterns

地理流代表物质、信息和人员等资源的移动与交换, 反映了地理空间中的相互联系和依赖性^[1-2]。城市内部和省际的空间交互日益频繁, 如通勤、人口迁移等, 这些交互主要以人群移动的形式显示出来, 反映着经济、文化和社会联系的密切程度。作

为一种常见的地理流, 人群移动流可被用于揭示地理区域中的人类活动规律, 反映区域空间结构、功能与特征^[3-5]。

人群移动流具有空间上的自相关性和异质性特征^[2]。向量尺度的莫兰指数^[6]、Ripley K 函数^[7]、

收稿日期: 2024-05-28

基金项目: 国家自然科学基金(42001399; 42071455; 42471486); 广东省城市空间信息工程重点实验室开放基金(2023002)

作者简介: 周 洋(1987—), 女, 博士, 副教授, 研究方向为人群动态观测与建模。E-mail: yzhou2017@cenu.edu.cn

通信作者: 陶 然。E-mail: rtiao@usf.edu

局部 G 统计^[8]等方法被推广和应用到流数据中,捕捉地理流的空间依赖关系,揭示人群移动流的自相关模式。除了空间特征外,人群移动流还具有随时间变化的动态特征^[9-11]。近年来对人群移动流的分析不仅考虑了其起点、终点间的空间相关性,还考虑了其时间依赖特征^[1,12],且越来越重视对地理流时空依赖的刻画。时空 L 函数^[13]、时空动态邻域^[14]、基于时间序列的局部空间相关指标 (LISA)^[11]等方法被提出,用于揭示人群流动的时空模式。文献[12]提出了流的局部时空自相关指标 (STFlowLISA),引入时空权重矩阵捕捉时空依赖特征,识别流的时空自相关模式。然而,与空间特征相比,时空依赖对人群移动流的相关性规律和时空集聚特征识别具有的优势还不明显。尤其是对于城市内部和省际尺度的不同移动流,受人类活动目的和空间尺度影响,是否会表现出不同的时空依赖模式,仍然值得深入探讨。

因此,本文以城市内部和省际人群移动流为例,选择空间自相关(仅考虑空间依赖)和时空自相关(同时考虑空间和时间依赖)指标,分别识别流的自相关模式,并对比流的时空集聚特征与规律,以探究时空依赖对不同空间尺度下人群移动模式识别的优势和影响。

1 研究方法

1.1 地理流的时空依赖关系

时空依赖描述了地理空间数据在时间和空间上的关联。空间邻近和时间邻近的变量之间存在密切的时空关联,往往显示出强时空依赖性。本文根据文献[12]的方法,定义地理流的空间邻居和时空邻居^[12]。地理流的空间关联可以通过起点和终点的邻近程度进行测度,如图1(a)所示,流 f_a 存在3类空间邻居,包括与 f_a 的起点和终点分别相邻的流(如 f_{b1})、与 f_a 起点相邻且终点相同的流(如 f_{b2})、与 f_a 起点相同且终点相邻的流(如 f_{b3})。在此基础上,整合空间和时间邻接关系定义时空邻居,如图1(b)所示。对于 t 时刻的流 f_a ,一方面,其时空邻居包括 t 时刻的3类空间邻居,即 t 时刻与 f_a 的起点和终点分别相邻的流(如 f_{b1})、与 f_a 起点相邻且终点相同的流(如 f_{b2})、与 f_a 起点相同且终点相邻的流(如 f_{b3});另一方面,其时空邻居包含 $t-1$ 时刻与 f_a 起点和终点分别相同的流 f_c 和 f_c 的3类空间邻居 f_{d1} 、 f_{d2} 、 f_{d3} 。

1.2 地理流空间自相关指标 (SFlowLISA)

局部空间自相关 (LISA) 指标可以测度空间变量与临近要素的关联。将 LISA 指标扩展到地理流,

即地理流的空间自相关指标 (SFlowLISA) 被提出,揭示了空间流数据中的空间相互作用^[12,15],公式为

$$FI_{S(i,j)} = \frac{n(f_{(i,j)} - \bar{f}) \sum_{(u,v) \neq (i,j)} w_{ij,uv} (f_{(u,v)} - \bar{f})}{\sum_{(i,j)} (f_{(i,j)} - \bar{f})^2} \quad (1)$$

式中, $FI_{S(i,j)}$ 是由起点 i 到终点 j 流量的空间自相关指标; $f_{(i,j)}$ 为区域 i 到 j 的地理流流量; n 为研究区域内流的总数; $\bar{f}$ 为所有流流量的平均值; $w_{ij,uv}$ 为空间权重矩阵中 $f_{(i,j)}$ 和 $f_{(u,v)}$ 之间的空间权重。空间权重矩阵使用基于流的空间依赖(如图1(a)所示)构建邻接矩阵,若两个流是空间邻居,空间权重设置为1,否则设置为0,最后对空间权重矩阵进行标准化,令每个流的权重总和为1。




图1 地理流的空间依赖和时空依赖示意

1.3 地理流的时空自相关指标 (STFlowLISA)

SFlowLISA 聚焦流的空间关联而忽略了时间依赖。文献[12]提出流时空自相关指标 (STFlowLISA) 测度流的时空关联性^[12],公式为

$$FI_{ST(i,j,t)} = \frac{n(f_{(i,j,t)} - \bar{f}) \sum_{(u,v,t') \neq (i,j,t)} w_{ijt,uv,t'} (f_{(u,v,t')} - \bar{f})}{\sum_{(i,j,t)} (f_{(i,j,t)} - \bar{f})^2} \quad (2)$$

式中, $f_{(i,j,t)}$ 为 t 时刻区域 i 到 j 的地理流流量; n 为研究区域内流的总数; $\bar{f}$ 为所有流的平均流量; $w_{ijt,uv,t'}$ 为时空权重矩阵中 $f_{(i,j,t)}$ 和 $f_{(u,v,t')}$ 的权重。基于流的时空依赖关系(如图1(b)所示)构建邻接矩阵,将其作为时空权重矩阵,并进行标准化处理。

1.4 显著性检验及依赖模式识别

在计算时空自相关指标时,采用基于条件排列的蒙特卡罗模拟(Monte Carlo simulation)方法进行显著性检验,识别地理流的依赖模式。以使用 W_{ST} 计算 $FI_{ST(i,j,t)}$ 为例,进行 M 次模拟,每轮模拟时将所有 n 个流的值进行随机排列,并保持 $f_{(i,j,t)}$ 的值不变,最后将 M 次模拟过程计算得到的 $FI_{ST(i,j,t)}$ 和原始结果一起进行排序,如果原始结果排列在顶部或底部的前 k 个结果中,则可以认为该结果在 $k/(M+1)$ 水平上具有统计显著性。

如果 $FI_{ST(i,j,t)}$ ($FI_{S(i,j)}$) 指标通过显著性检验,代表相应的流表现出显著的局部自相关模式,即高-高(HH)、低-低(LL)、高-低(HL)、低-高(LH)4种主要模式。其中,HH和LL模式说明这些流具有显著的集聚特征。HH模式表示地理流自身为高值,其时空(空间)邻居也为高值;LL模式表示地理流本身为低值,其时空(空间)邻居也为低值。HL模式和LH模式说明这些流为局部异常值,即与其时空(空间)邻居的特征不同。HL模式表示地理流为高值且被低值包围;LH模式表示地理流为低值且被高值包围。

2 试验与分析

2.1 试验数据

以武汉市出租车OD数据和验证登录数据为例(见表1),分析城市内部人群移动流和省际移动流。基于2016年8月1—31日的武汉市出租车轨迹数据,提取出租车OD数据约1435万条。将武汉市分割为500 m×500 m的格网单元,得到覆盖中心城区的3770个格网的移动流。以2 h为时间间隔进行

数据切片,区分工作日和周末。验证登录数据来自某验证登录服务记录的用户电脑和手机端的验证登录信息,仅记录用户ID及登录县市、时间。用户ID经过匿名化处理保护隐私,用户数为5.5万,用户群体无明显偏好人群和特征。数据平均采样间隔为10.8 h,其中88.85%采样间隔在1 d内,67.14%数据采样间隔在1 h内。采集时间为2024年1月15—27日,以省级行政区为研究单元聚合省际流动的OD数据约10万条(其中台湾省数据缺失),按日期进行聚合,得到13 d的省际移动流。聚合后的省际移动流的起点和终点抽象为各省级行政区的几何中心。

表1 试验数据

数据属性	城市内部移动流 (武汉市出租车OD数据)	省际人群移动数据 (验证登录数据)
采集时间	2016年8月1—31日	2024年1月15—27日
OD对数目	14 349 898	99 970
空间单元	500 m×500 m 格网	省级行政区
时间单元	2 h	1 d

2.2 城市内部人群移动流集聚特征

出租车作为城市中的主要交通方式之一,可以反映城市内部的人群移动特征。武汉市是中国中部城市群的核心城市,城市内部人口密集且流动频繁,长江、汉江穿城而过将武汉市划分为三镇,加剧了人群移动模式的复杂性^[16]。以武汉市出租车OD流为例,分别计算SFlowLISA和STFlowLISA指标,识别在1%显著性水平下($p < 0.01$)工作日和周末各时段出租车OD流的4种自相关模式,见表2。

表2 城市内部流工作日自相关模式数量($p < 0.01$)

时间	SFlowLISA				STFlowLISA			
	HH	LL	HL	LH	HH	LL	HL	LH
00:00—02:00	6488	535	84	1338	9553	0	5	767
02:00—04:00	2507	294	43	769	3298	0	3	232
04:00—06:00	1460	316	35	642	1497	0	5	70
06:00—08:00	4520	720	16	2001	6792	0	12	167
08:00—10:00	8113	587	12	2359	14 156	0	8	487
10:00—12:00	8142	662	22	2295	16 213	0	7	690
12:00—14:00	7901	693	14	2318	15 773	0	5	750
14:00—16:00	7819	701	18	2294	15 806	0	5	716
16:00—18:00	7543	813	23	2589	14 345	0	8	730
18:00—20:00	7592	652	11	2354	14 431	0	4	639
20:00—22:00	8555	829	27	2593	16 075	0	8	649
22:00—24:00	9148	899	26	2888	17 207	0	5	741

2.2.1 空间相关性特征

以每2 h为单位,分时段计算空间自相关指标(SFlowLISA),分别得到工作日、周末共24个时段的城市内部人群移动流空间自相关模式。无论工作日或周末,白天(08:00—22:00)是出租车客流量较大的时段,空间自相关模式以区域组团模式为主,具有一定的相似性(如图2(a)、(c)所示)。而夜间(02:00—06:00)的居民活动相对较少,且该时段无公交、地铁运营,出租车是主要交通工具,以交通枢纽(如汉口站、武汉站、武昌站)为核心形成显著的集聚模式(如图2(b)、(d)所示)。以14:00—16:00和04:00—06:00为例进行结果展示和进一步分析,如图2所示。




图2 城市内部人群移动流空间相关模式

在白天,HH相关模式的流主要集中在武汉市中心城区,形成了多个组团,包括汉口、武昌、青山、徐东、光谷、钟家村和王家湾,结果与文献[17]检测的出租车出行需求空间集聚区域一致。在这些移动流中,短距离的流以HH模式为主,大多在组团内部进行交互;中长距离的流以LL模式为主,连接不同的组团。HH模式的移动流数量最多,HL和LH模式的移动流数量较少,表明以出租车为载体的人群流动主要是城市中心分布的中短距离的移动流。类似的,在北京、上海等6个城市的数据集中,20 km以内的出租车行程都超过97%,这主要归因于旅行成本^[18]。

对比工作日和周末白天的结果发现,工作日呈现HH模式的流数量更多、分布范围更广,而周末呈现集聚模式的流的数量少于工作日。以青山组团为例,呈现HH模式流的数量在周末明显低于工作日。这是由于青山区居住用地和工业用地占比较高,出租车出行在周末显著降低。而其他几个组团包含更高比例的商业用地,商业娱乐活动使得这

些组团在周末仍具有较高数量的HH模式流。

LH模式和HL模式显示了空间上异常的流,这些流与其空间邻居的特征不同。在白天,LH模式的流主要分布在汉口和武昌组团内部,且被HH模式的流包围,显示了在出租车出行频繁的区域中流量较小的冷点(如图2(a)所示)。HL模式显示了城市内部定向联系的流,这些流具有较高的流量,但其空间邻居的流量较低。如图2(c)中的①区域内,武汉站—湖口社区的流被识别为HL模式,原因是湖口社区是典型的住宅区,与武汉站之间的交通需求较大,但该区域距离地铁站较远,公共交通不便,人们选择出租车出行。

2.2.2 时空相关性特征

计算时空自相关指标(STFlowLISA),分别得到工作日和周末的城市内部人群移动流时空自相关结果。同样以14:00—16:00(白天)和04:00—06:00(夜间)为例,进行结果展示和进一步分析,如图3所示。在时空自相关模式中,绝大多数的流被识别为HH模式,相比SFlowLISA数量明显增多,其他模式(HL、LH、LL)的流数量较少(见表2),表明STFlowLISA对HH模式更加敏感。当显著性水平设定更为严格时(如 $p < 0.001$),各类模式的流的数量也会随之下降。




图3 城市内部人群移动流时空相关模式

图3(a)中HH模式的流的主要组团分布与图2(a)中空间自相关模式显示的组团一致。进一步对比仅考虑空间依赖的结果(图2(a)所示)发现,更多中长距离的流被识别为HH模式,且有更多跨越区域的流,这说明长距离出租车出行往往在空间上不集聚而在时间上强相关。同时,图2(d)和图3(d)中以火车站为核心的流,其空间邻居的流量较低,但时间邻居存在较高流量,这些跨区域定向

联系的流显示出强时间依赖,因此在 STFlowLISA 结果中表现为 HH 模式,符合“STFlowLISA 方法往往跨越较远的距离,而 SFlowLISA 方法距离较短且受限于区域”这一规律^[12]。因此,STFlowLISA 考虑时间依赖可以检测更多空间相关性弱但时间相关性强的流的集聚特征。

使用时空自相关指标(如图 3(a)所示)识别的大部分 LH 模式的流与仅考虑空间依赖的结果(如图 2(a)所示)相似,主要分布在汉口和武昌组团内部,且被 HH 模式的流包围,说明 LH 模式主要受空间依赖的影响。此外,加入时间依赖还可以将流量骤增(骤减)的流识别为 HL(LH)模式。以图 3(c)中①和②两个流为例,图 4 统计了各时段的流量分布,并标注了使用时空自相关指标识别的模式。图 4 中①为周末新河社区到积玉桥的流,该流在 14:00—16:00 显示为 LH 模式(如图 3(c)中①所示),原因是乘坐出租车前往积玉桥的人数相比上一时段骤减。而图 4 中②为周末从南湖名都到光谷广场的流,14:00—16:00 由南湖名都及周边其他小

区前往光谷广场的人数骤增,居民离开住宅区前往商业区进行休闲娱乐,这导致该流在 14:00—16:00 被识别为 HL 模式(如图 3(c)中②所示)。在相同时段,使用空间自相关指标无法识别出这两个流的空间模式。这表明,考虑时空依赖可以有效识别时空中的异常流,揭示区域间异常的空间交互。




图 4 城市内部人群移动流各时段流量

2.3 省际人群移动流集聚特征

以天为单位分别计算省际人群移动流数据的 SFlowLISA 和 STFlowLISA 指标,识别在 5% 显著性水平下 ($p < 0.05$) 省际人群移动流的 4 种局部自相关模式,结果见表 3。

表 3 省际人群移动流自相关模式数量($p < 0.05$)

日期	SFlowLISA				STFlowLISA			
	HH	LL	HL	LH	HH	LL	HL	LH
2024-01-15	34	26	0	20	78	1	0	6
2024-01-16	36	20	0	13	79	1	0	5
2024-01-17	32	25	0	10	79	5	0	5
2024-01-18	39	24	2	10	73	7	0	8
2024-01-19	35	16	0	11	83	2	0	12
2024-01-20	32	16	1	7	69	2	1	16
2024-01-21	23	11	1	3	64	5	1	9
2024-01-22	30	32	2	7	58	0	1	7
2024-01-23	35	15	2	7	52	1	0	6
2024-01-24	31	19	0	13	51	4	0	4
2024-01-25	30	20	0	7	45	1	1	2
2024-01-26	29	6	1	9	43	2	1	5

2.3.1 空间集聚特征

通过计算空间自相关指标,对 13 d 的省际人群移动流空间集聚模式进行识别,选取 2024-01-19(如图 5(a)所示)和 2024-01-20(如图 5(b)所示)的空间集聚模式为例进行展示。

HH 模式相关的流显示出高度的空间集聚,主要集中在我国东部沿海地区,形成京津冀、长三角和粤港澳组团。这些区域人群流动频繁且相互联系密切,表明在这些区域我国已实现良好的协同发展态势,这与文献[19]使用手机信令数据提取的全国人口流动特征一致。呈现 LL 模式的流则主要为

东西交互(如新疆—上海)或东北—西南交互(如内蒙古—四川、黑龙江—贵州),表明跨越长距离的移动流流量相对较低。

对比工作日和周末呈现 HH 模式移动流的空间分布,周六的 HH 模式流比周五显著减少,且集中在城市群组团内部(如图 5(a)、(b)所示)。LH 模式表示自身流量较低而空间邻居流量较高,如天津—港澳、福建—港澳的流,表明天津和福建流向港澳地区的人数相对较少,而其周边地区如北京、浙江、广东等流向港澳地区的流量较大。

2.3.2 时空集聚特征

计算 STFlowLISA, 得到省际人群移动流在第 t 、 $t-1$ d 的时空相关性(见表 3)。以天为单位的时间尺度下省际人群移动的特征相对稳定, 以 2024-01-19(如图 5(c)所示)和 2024-01-20(如图 5(d)所示)

为例进行分析。呈现 HH 模式的流以城市群组团内相邻省份之间的流为主, 呈现 LL 模式的流则主要是跨越较长的距离省份之间的流, 呈现 HL 和 LH 的流数量较少。这与城市内部的流的时空相关性结论类似。




图5 省际人群移动流空间集聚模式和时空集聚模式

对比图 5(a)和(c),以及图 5(b)和(d)可以看出,省际移动流中的时间依赖显得更加重要。首先,在考虑时间依赖后,跨区域的远距离流的 HH 模式数量增加,如京津冀、长三角和粤港澳 3 个城市群流向其他不相邻省级行政区的流(如粤港澳地区流向四川、重庆、云南等省的流)。这些人群移动流虽然在空间上不相邻且跨越的距离较远,但是时间相关性很强。主要原因是远距离的流虽然流量较高且具有持续性,但空间相关性弱,仅考虑空间依赖难以被识别,而加入时间依赖可以检测出这些流集聚。其次,同时考虑空间和时间依赖可以识别相对孤立的定向联系的流,如图 5(c)和(d)中的川渝城市群。四川和重庆间的内部流动频繁,但与其他省份的连接不够密切,该现象与文献[20]提到的“成渝城市群与其他城市群联系最不紧密”一致,使得仅考虑空间依赖难以识别两者之间的关联。

比较工作日和周末的 STFlowLISA 结果(见表 3)发现,周末检测出的 HH 模式数量比工作日更少。考虑时空依赖后, LH 模式可以显示与上一时

段相比流量骤减的流,如江西—北京的流在 1 月 20 日被识别为 LH 模式(如图 5(d)所示),相比前一天流量大幅减少(如图 6 所示)。与城市内部新河社区—积玉桥的流相似(如图 4 中②所示),使用时空相关性时可以识别江西—北京的流的 LH 模式(如图 6 所示),而仅考虑空间依赖时(如图 5(b)所示)无法识别。

3 结论

本文对比了移动流的空间自相关(SFlowLISA)和时空自相关(STFlowLISA)指标,以城市内部和省际间的移动流为对象进行案例分析,揭示了不同场景下地理流时空自相关指标的优势和互补性,主要结论如下。

(1)城市内部和省际的人群移动流均表现出较强的时空依赖。对城市内部流而言,由于地块之间的空间相关性本身较强,因此,仅考虑空间依赖即可识别出较多的流的自相关模式。然而对于省际流而言,考虑时空自相关更能捕捉省际间人群移动

的 HH 集聚模式。




图6 省际人群移动流逐日流量分布
(以江西—北京为例)

(2)在空间自相关中,城市内部和省际人群移动流的 HH 模式均以短距离的流为主,这些流与临近的空间单元关系密切,大多在组团内部进行交互;LL 模式的流往往是跨组团的远距离流。

(3)与仅考虑空间依赖相比,时空相关性有助于识别更多中远距离移动流的 HH 模式,尤其是捕捉空间相关性不强但存在时间依赖的时空集聚模式,如跨区域定向联系(城市内部组团间联系和各城市群间联系)的流显示出强时间依赖,两者之间的相互对比有助于更好地揭示人群移动模式的时空动态特征。

(4)时空相关性分析中,HL 和 LH 模式可以显示时空中的异常流,这些流与其他时段相比流量发生突变(突然降低或减少),揭示区域间特定时段的空间交互特征。

本文方法和结论有助于加深对不同场景下人群移动流的时空依赖特征和分布规律的理解,丰富地理流的探索性分析方法。

参考文献:

- [1] 刘瑜,姚欣,龚咏喜,等. 大数据时代的空间交互分析方法和应用再论[J]. 地理学报,2020,75(7):1523-1538.
- [2] 裴韬,舒华,郭思慧,等. 地理流的空间模式:概念与分类[J]. 地球信息科学学报,2020,22(1):30-40.
- [3] ZHONG C, BATTY M, MANLEY E, et al. Variability in regularity: mining temporal mobility patterns in London, Singapore and Beijing using smart-card data[J]. PLoS One, 2016, 11(2): e0149222.
- [4] ZHOU Y, THILL J C, XU Y, et al. Variability in individual home-work activity patterns [J]. Journal of Transport Geography, 2021, 90: 102901.
- [5] 段晓旗,张彤,田有亮,等. 居民出行异质性与城市活动结构[J]. 测绘学报,2023,52(1):155-166.
- [6] LIU Y, TONG D Q, LIU X. Measuring spatial autocorrelation of vectors [J]. Geographical Analysis,

2015,47(3):300-319.

- [7] TAO R, THILL J C. Spatial cluster detection in spatial flow data[J]. Geographical Analysis, 2016, 48(4): 355-372.
- [8] TAO R, THILL J C. FlowAMOEB: identifying regions of anomalous spatial interactions [J]. Geographical Analysis, 2019, 51(1): 111-130.
- [9] SEVTSUK A, RATTI C. Does urban mobility have a daily routine? Learning from the aggregate data of mobile networks[J]. Journal of Urban Technology, 2010, 17(1): 41-60.
- [10] CHENG T, HAWORTH J, WANG J Q. Spatio-temporal autocorrelation of road network data [J]. Journal of Geographical Systems, 2012, 14(4): 389-413.
- [11] GAO Y, CHENG J, MENG H H, et al. Measuring spatio-temporal autocorrelation in time series data of collective human mobility [J]. Geo-spatial Information Science, 2019, 22(3): 166-173.
- [12] TAO R, CHEN Y Z, THILL J C. A space-time flow LISA approach for panel flow data [J]. Computers, Environment and Urban Systems, 2023, 106: 102042.
- [13] YAN X R, PEI T, SHU H, et al. Spatiotemporal flow L-function: a new method for identifying spatiotemporal clusters in geographical flow data [J]. International Journal of Geographical Information Science, 2023, 37(7): 1615-1639.
- [14] SHI Y, DENG M, YANG X X, et al. Detecting anomalies in spatio-temporal flow data by constructing dynamic neighbourhoods[J]. Computers, Environment and Urban Systems, 2018, 67: 80-96.
- [15] TAO R, THILL J C. BiFlowLISA: measuring spatial association for bivariate flow data [J]. Computers, Environment and Urban Systems, 2020, 83: 101519.
- [16] 孙立坚,马志勇,常迎辉,等. 人群时空行为与城市昼夜人口空间集聚分析——以武汉市为例[J]. 测绘学报,2023,52(3):464-477.
- [17] KANG C G, QIN K. Understanding operation behaviors of taxicabs in cities by matrix factorization[J]. Computers, Environment and Urban Systems, 2016, 60: 79-88.
- [18] WANG W J, PAN L, YUAN N, et al. A comparative analysis of intra-city human mobility by taxi[J]. Physica A: Statistical Mechanics and its Applications, 2015, 420: 134-147.
- [19] 廖创场,郭仁忠,郭文华,等. 基于手机信令数据的中国人口流动网络空间结构特征研究[J]. 自然资源信息化,2022(5):16-23.
- [20] 胡昊宇,黄莘绒,李沛霖,等. 流空间视角下中国城市群网络结构特征比较——基于铁路客运班次的分析[J]. 地球信息科学学报,2022,24(8):1525-1540.

(责任编辑:纪银晓)