

International Journal of Geographical Information Science

ISSN: 1365-8816 (Print) 1362-3087 (Online) Journal homepage: www.tandfonline.com/journals/tgis20

基于图逆向强化学习的不完整数据地理空间轨迹生成

Generating geospatial trajectories with incomplete data
using graph inverse reinforcement learning

Zi Hen Lin , A. Yair Grinberger & Daniel Felsenstein

引用本文: Zi Hen Lin, A. Yair Grinberger & Daniel Felsenstein (2026年4月27日):
基于图逆向强化学习的不完整数据地理空间轨迹生成, International Journal of
Geographical Information Science, DOI: 10.1080/13658816.2026.2658065

本文链接: <https://doi.org/10.1080/13658816.2026.2658065>



© 2026 作者。由 Informa UK Limited 出版, 以 Taylor & Francis Group 名义运营。



查看补充材料



在线发表: 2026年4月27日。



向本刊投稿



文章浏览量: 832



查看相关文章



查看 Crossmark 数据

基于图逆向强化学习的不完整数据地理空间轨迹生成

Zi Hen Lin^a, A. Yair Grinberger^b & Daniel Felsenstein^b

a计算机科学系, 慕尼黑工业大学 (Technical University of Munich), 德国; b地理学系,
耶路撒冷希伯来大学 (The Hebrew University of Jerusalem), 以色列

摘要 人类系统的地理模拟往往依赖轨迹生成来对智能体行为进行建模。本文探讨数据有限条件下的轨迹生成问题。我们展示深度学习如何利用耶路撒冷的两个数据集复现具有代表性的城市出行模式: 一个基于 GPS 的出行调查数据集, 以及一个包含全部建筑物的 GIS 数据集。为缓解两个数据集之间的数据不匹配, 我们通过多维聚类进行信息传播。为利用由转移矩阵刻画的地理空间网络结构, 我们使用图神经网络 (GNN) 作为奖励函数近似器, 并将其与作为基线的线性方法和多层感知机 (MLP) 进行比较。对基线而言, 转移概率主导行为, 而 GNN 则从全局数据模式或局部邻域结构中学习。结果表明, 由 GNN 导出的奖励与建筑面积的相关性更强, 从而影响转移概率。我们测试了若干初始状态与终止状态配置, 以基于所学策略生成轨迹。在缺乏普遍接受的评价方法的情况下, 我们使用聚合性能指标而非单条轨迹相似度来评估轨迹。研究结果表明, 基于 GNN 的奖励能够提升模拟轨迹的真实性, 但仍需进一步完善。

关键词 模拟; 地理空间轨迹; 数据约束; 机器学习

文章历史 文章历史 收稿日期: 2025年7月1日; 录用日期: 2026年4月6日

通讯作者 A. Yair Grinberger yair.grinberger@mail.huji.ac.il 本文的补充数据可在线获取:
<https://doi.org/10.1080/13658816.2026.2658065>。

© 2026 作者。由 Informa UK Limited 出版, 以 Taylor & Francis Group 名义经营。本文是一篇开放获取文章, 依据知识共享 署名—非商业性使用—禁止演绎 许可协议 (<http://creativecommons.org/licenses/by-nc-nd/4.0/>) 的条款发布。该协议允许在正确引用原文、且未以任何方式改动、转换或基于原文进行创作的前提下, 以任何媒介进行非商业性的再利用、分发和复制。本文的发表条款允许作者本人或经其同意在知识库中发布录用稿 (Accepted Manuscript)。

1. 引言与研究现状

包含城市居民、工作者或访客等移动实体的地理模拟, 需要生成轨迹, 以便对填充模拟的实体的行为进行建模。为了贴近现实, 模拟数据需要包含智能体日常活动丰富的时空属性。生成这种高度精细的数据充满挑战。第一, 空间依赖很可能存在于建筑物、街区乃至城市等相邻单元之间。这会导致连片空间上的行为溢出, 因为一个空间单元中的行为会影响相邻单元中的行为。第二个挑战来自时间层面。时间的序列性意味着时间依赖会产生自回归行为。某一时刻发生的事情受到上一时期行为的影响。高度精细的时空社会经济数据的可得性有限。获取这类数据的一种途径是自愿参与, 但这种方式往往成本高昂且噪声较大 (Si a-Nowicka et al. 2016, Goodchild et al. 2017, Zhang and Zhu 2018)。过去收集的轨迹数据往往不具备当前所需的覆盖范围与分辨率。因此, 轨迹生成成为一种自然的替代方案, 尤其适用于下游的地理模拟, 例如对拥堵收费与交通领域自动驾驶车辆规划等政策干预的响应建模 (de Palma and Lindsey 2011, Kong et al. 2023)、疫情管控措施导致的出行限制 (Toger et al. 2021, Kwak et al. 2021, Lu and Giuliano 2023), 或自然灾害发生时应急避难场所的提供 (Chen and Zhan 2008, Dawson et al. 2011)。

本文研究数据可得性有限情况下的地理模拟中的轨迹生成，并将其作为建模过程的输入。我们强调在数据受限的环境下使用机器学习来生成经验性的、具有代表性的轨迹。作为一个以模拟为基础、且假设情景需要轨迹数据的案例研究，我们的方法侧重于生成未见过的、多样化的轨迹，即生成与总体模式相一致的新轨迹。这与高精度复现观测轨迹形成对比——轨迹预测强调的是相对于距离最小化或成本优化等客观目标的精确性。我们以耶路撒冷为例，说明如何利用两个数据集为智能体生成城市出行模式。第一个数据集来自对该市出行习惯开展的一项独特的 GPS 调查。第二个数据集是覆盖城市区域内全部建筑物的 GIS 数据集。

为揭示出行行为中的自然序列，通常需要从数据中通过观察推断其动机。一种标准做法是采用端到端监督学习范式，例如在自然语言处理领域流行的序列到序列方法（Sutskever 2014, Vaswani et al. 2017）。该方法直接吸收一组训练序列，以自回归预测的形式生成新序列，并针对经验数据优化预测结果。然而，在地理空间轨迹的语境下，由于评估困难、序列长度不规则，加之潜在的隐私问题，很难在此类设定下形式化轨迹生成问题。它还需要大量轨迹数据才能取得良好性能，而这类数据往往不可得。此外，使用优化方法生成与经验轨迹高度相似的轨迹，背离了轨迹生成的初衷。

强化学习（RL）对数据量的要求较低。由于与环境持续交互，该方法在数据利用与探索之间取得平衡，同时揭示实体的行为及其背后的动机。在已知可能状态的集合——即状态空间——以及每个状态所附的奖励（即奖励结构）的情况下，一个移动实体（智能体）能够基于对其环境的局部观测被训练以达成其目标。这通过寻找最优策略（给定状态下动作的概率分布）来实现，该策略在每次动作都获得持续反馈（奖励）的情况下最大化累积奖励。对于地理空间轨迹等现实世界动态，真实的奖励结构难以获得（Safarzadeh and Wang 2024）。因此，在本文中，我们使用逆向强化学习（IRL）作为一种合适的学习范式，从经验轨迹中提取出行奖励结构。假定其中蕴含了现实世界的最优策略。它量化了解释观测到的动作序列（数据）的行为动机（奖励），随后通过微调假定的转移动态，基于该行为生成决策规则（策略）。通过这种方式，可以提取出已观测和未观测的决策规则，以塑造智能体在模拟中的行为。

使用 RL 的一个局限在于，智能体往往只能对奖励函数有一个模糊的认识，而对该函数的优化会产生“可取”的行为（Ng and Russell, 1998）。因此，RL 并不适用，因为不存在可供强化的行为，而且智能体并不总能拥有可供其模仿行为的专家智能体。在 IRL 中，专家智能体的奖励函数被恢复出来，并用于生成可取的行为。为使 IRL 可操作，常采用熵优化。由 Ziebart et al. (2008) 推广的最大因果熵逆向强化学习（MaxEntIRL）算法使用了最大熵原理。它基于“最小错误”的思路：在约束最小的情况下使熵最大的行为分布，提供了“错误最少”的解。Lee et al (2017) 使用类似方法构建了 Schelling 型的空间与社会隔离。

该方法近期在明确的空间语境中的应用见 Oda (2021)。他提出了一个多智能体行为 IRL 模型。该模型被应用于网约车服务场景，将自利型驾驶员行为与乘客需求相匹配。采用马尔可夫决策过程（MDP）形式化方法，计算最优策略，模型学习驾驶员的奖励函数。该方法的验证使用横滨市（Yokohama city）的真实出租车轨迹数据，并据此估计成本函数的参数。在此基础上，算法学习均衡策略。随后通过重复策略传播步骤，并在每一阶段与不匹配距离比（MDR）生成的基线进行比较，计算均衡访问次数。

本文对 IRL 的应用作出贡献，并通过开发一个学习与轨迹生成框架，将其用途拓展至轨迹生成。该框架通过从个体出行记录中学习奖励，并将其与空间转移概率相结合，生成单日、基于家的出行链，即以家为起点和终点、按顺序排列的访问地点序列，且不含一天中时间（time-of-day）的标注。这种基于学习的方法为 Lévy 飞行、连续时

间随机游走等机制模型，尤其是探索一偏好返回（EPR）模型及其扩展，提供了一种互补的视角（Song et al. 2010, Pappalardo et al. 2016, Cornacchia and Pappalardo 2021, Schneider et al. 2026）。尽管我们对日内时间模式的处理更为抽象，但我们系统地纳入了建筑属性、空间连通性和社会经济特征等环境语义，以便通过学到的奖励函数提供对行为动机的可解释洞见。该框架优先关注理解出行的空间驱动因素并支持反事实分析，而非时间预测，这使其适用于城市规划与设计应用，而非业务化预测。

该框架应对了以往 IRL 方法应用所特有的三个主要挑战。第一，为常见的地理空间挑战提供明确的策略，即所收集的轨迹数据仅覆盖目标状态空间的一个子集。此前的文献（如 Ziebart 2010, Oda 2021）并未强调这一点。第二，我们使用图的拉普拉斯矩阵，为已知的 MaxEntIRL 收敛问题提供系统性的解决方案（Ziebart 2010, Barnes et al. 2023）。第三，由于我们的初步发现表明 MaxEntIRL 的线性奖励函数会阻碍对复杂地理空间动态的学习，我们遵循 Wulfmeier et al. (2015) 的做法，引入基于图的深度学习来近似非线性奖励函数，并进行了深入的影响分析。除 Wang et al. (2023a, b) 以外，该方法在此前基于 MaxEntIRL 的工作中尚未被应用，而 Wang et al. (2023a, b) 并不属于地理空间领域。

接下来我们将介绍经验数据，并概述在不完整数据下学习奖励与生成轨迹所涉及的方法与技术问题（第2节）。第3节呈现实证分析及对上述问题的解决方案，第4节讨论这些发现的意义。第5节总结，并就我们的方法对未来地理模拟建模进展的影响提出一些观察。

2. 学习与轨迹生成框架

本节介绍实证数据集以及将 MaxEntIRL 算法付诸实施的主要组成部分（第2.1节），包括特征矩阵、转移矩阵以及初始状态和终止状态。随后我们讨论轨迹生成方法（第2.2节）。将 MaxEntIRL 算法应用于地理空间轨迹情形的一般工作流程如图1所示。将轨迹视为一个序列化的 MDP（Wulfmeier et al 2015, Ziebart 2010），IRL 需要预先界定四个要素：轨迹的初始状态与终止状态、状态转移概率矩阵以及期望状态访问频率（ESVF）。后者体现于特征矩阵之中，而特征矩阵被视为最优策略的具体化（见第2.1.2节）。在初始阶段，该过程利用基于特征矩阵的奖励、终止状态和转移矩阵计算出一个中间策略。这有助于计算 ESVF、将其与专家的 ESVF 进行比较，并最终根据二者的差异更新奖励函数的权重。当损失函数收敛时，奖励与转移矩阵相乘生成策略，并据此生成轨迹。

2.1. 学习框架

2.1.1. 训练数据 我们使用一个经过处理的 GPS 轨迹数据集，该数据集源自耶路撒冷交通总体规划团队（Jerusalem Transport Masterplan Team）于2011年开展的出行习惯调查。其中包含 7,692条经过筛选和处理的轨迹（Grinberger and Shoval 2015），访问了 12,318 栋不重复的建筑。这些建筑略少于耶路撒冷全部建筑的三分之一，平均轨迹长度为 4.92 个停留点。尽管该调查距今已有时日，我们仍假设特征矩阵（见下文第2.1.2节）中包含的诸要素（如距市中心的距离、建筑面积体量等）对奖励施加相同的影响，即日常行为的动机保持不变。




图1. 使用 MaxEntIRL 算法生成轨迹的流程图。

2.1.2. 特征矩阵 按照惯例，MaxEntIRL 的奖励函数要求特征矩阵既要包含整个状态空间，又要充当相应移动性信息的唯一来源。尽管在实践中，所采集的轨迹数据往往只覆盖目标状态空间的一个子集，但以往研究（如 Ziebart 2010, Oda 2021）很少给出带有明确说明的解决方案。为弥补这一空白，我们提出一种策略，将移动性数据集中的信息以每栋建筑期望访问次数的形式传播到目标状态空间。我们采用一种多维聚类流程，利用与空间、城市连通性和社会经济属性相关的建筑特征（完整的特征清单及其阈值见附录1）。这意味着针对每个特征，使用特征特定的阈值来区分不同的建筑组别，从而定义相应的聚类；并根据每栋建筑的特征值，将其分配到多个聚类之中，每个特征对应一个聚类。例如，定义 X 个高度组，每个组有各自的高度值区间，建筑依据其高度所落入的区间被分配到相应组中。阈值根据对特征值分布的目视检查确定，从而在数据中形成自然断点。这些阈值被假定代表与移动性相关的分界值。该过程在 Lin et al. 2025 中有更详细的讨论。尽管这种做法可能被解读为会对结果产生偏倚，但我们的检验表明其具有稳健性（见第3.5节）。将每个特征—聚类组合的访问次数除以该特征—聚类组合所访问的不重复建筑数量，我们就得到“期望访问次数”。借此，我们把来自异质来源的空间—移动性信息融合进一个特征矩阵之中。

为了提取建筑特征，我们使用另一个数据集，其中包含由以色列测绘局（Survey of Israel, SOI）提供的耶路撒冷全部建筑。SOI 是负责制作官方地图与地理数据的以色列政府机构。该数据集包含耶路撒冷的 38,093 栋建筑，并附有坐标、高度、建筑面积和土地利用代码等基本信息。受计算能力限制并出于可视化目的，我们使用由 19 个统计区（即人口普查区）组成的一个子集，其中包含 1,014 栋建筑。该子集从计算得到的特征矩阵中提取，用于 IRL 训练和轨迹生成（图2）。

2.1.3. 转移矩阵 为了模拟建筑物之间的移动动态，我们使用简单重力得分（SGS）生成转移概率。重力公式是与人口从起点到终点转移相关的空间交互模型的基石（Oshan 2021）：

$$\text{SGS}_{ij} = 0, \text{ 当 } i = j; \quad \text{SGS}_{ij} = V_i / D_{ij}^2, \text{ 当 } i \neq j \quad (1)$$

其中, V 是建筑物的体积或建筑面积, D 是两栋建筑物之间的距离。随后对 SGS 进行归一化, 使其成为一个有效的转移矩阵。下文 (第3.1节) 我们将从收敛性和奖励两方面讨论转移矩阵的影响。为减轻计算负载, MaxEntIRL 的转移矩阵被稀疏化至 10% 的密度。

2.1.4. 初始状态与终止状态 由于我们通过将建筑物表示为聚类隶属度向量而从根本上改变了状态空间 (第2.1.2节), 我们无法沿用从数据集中推导初始状态和终止状态的常见做法 (Kong et al. 2023)。相反, 我们将此视为轨迹情境化的问题, 它可由状态空间、初始状态、终止状态和动态来刻画。我们基于聚类的状态空间剥离了移动信息中的情境, 同时保留了动态, 这些动态随后以期望访问次数的形式传播。在本应用中, 我们选择无信息的初始状态和终止状态。我们将研究区内所有建筑物随机指定为初始状态, 并将研究区内所有居住和混合用途建筑物指定为终止状态。该方法假设, 我们可以通过指定特定的初始状态和终止状态来传播并细化移动动态, 并对下游的轨迹生成进行重新情境化 (见第2.2节)。




图2. 耶路撒冷研究区：下图为耶路撒冷建成区。上图为指定研究区内的建筑物。

2.1.5. 奖励的非线性 通过将奖励函数定义为特征权重与特征矩阵的乘积，MaxEntIRL 假定了初始奖励与最终奖励之间的线性关系 (Ziebart 2010; Arora and Doshi 2021)。我们通过在 PyTorch 中实现四种机器学习模型作为奖励函数来考察这

一假设的影响：线性模型（Linear）、多层感知机（MLP）、图卷积网络（GCN）以及 K 维图神经网络（GraphConv）。线性奖励模型是一个不含激活函数的单层前馈层。其

参数数量为 11，与输入数据中的特征数量一致。MLP 模型是一种带有非线性激活函数的基本神经网络形式。它由三个线性层组成，其间穿插 ReLU 和 BatchNorm 层。隐藏 维度为 32。MLP 的参数数量为 1569。MLP 捕捉数据中的全局模式和特征。与 MLP 类 似，GCN 和 GraphConv 算法具有相同的层数以及相同的激活函数和批归一化函数。GCN 和 GraphConv 被认为是更高级形式的奖励模型。除特征矩阵外，它们还利用转移 矩阵作为额外输入，以刻画潜在的建筑物网络拓扑结构。通过这种方式，由于每个节 点都从邻居处聚合信息，它们可以被视为捕捉了局部因素。每个模型的参数数量取决 于层数以及每一层的通道数。GCN 用 GCN 层替代线性层，而 GraphConv 则用 GraphConv 层替代线性层。这些基于图的层由 PyTorch Geometric 支持。GCN 的 参数 数量与 MLP 相同，即 1569，而 GraphConv 的参数数量为 2945。

除线性模型外，所有模型都通过非线性激活函数引入非线性。MLP 作为非线性奖励函数的对照，以进一步区分基于图的模型的几何归纳偏置所产生的影响。我们同时实现 GCN 和 GraphConv，以考察不同图神经网络（GNN）架构的效果。

2.1.6. 收敛性与拉普拉斯矩阵 计算 ESVF 的收敛性是 MaxEntIRL 算法实现中的一个棘手问题（Ziebart et al. 2008, Snoswell et al. 2020, Barnes et al. 2023）。朴素方法在计算上难以处理，而 Ziebart (2010) 对枚举的概率近似只有在矩阵性质满足某些限定条件时才能收敛。我们发现，给定状态下动作概率分布 $p()$ 与中间策略 $P()$ 之积的主特征值决定了这一幂迭代算法的收敛性，因此我们通过将该乘积归一化为其左拉普拉斯矩阵来控制迭代过程中主特征值的增长（图3）。该技术成功地稳定了收敛过程，并为奖励函数的选择提供了更多洞见。关键洞见在于：拉普拉斯矩阵的主特征值与 ESVF 匹配的损失成反比，且基于图的深度学习模型比线性模型和 MLP 具有更高的初始主特征值，从而实现更快的收敛。

Algorithm: Expected state frequency calculation with Laplacian

Require: MDP, $\mathcal{M}_{\text{MDP}}$, stochastic policy $\pi(a_{x,y}|s_x)$, and initial state distribution $P_0(s_x)$

Ensure: state visitation frequencies, D_{s_x} under policy $\pi(a_{x,y}|s_x)$

```

1: for all states  $s_x \in \mathcal{M}_{\text{MDP}}$  do
2:    $D_{s_x} \leftarrow 0$ 
3: end for
4: while not converged do
5:   for all states  $s_x \in \mathcal{M}_{\text{MDP}}$  do
6:      $D'_{s_x} \leftarrow P_0(s_x)$ 
7:   end for
8:   for all actions  $a_{x,y} \in \mathcal{M}_{\text{MDP}}$  do
9:     for all states  $s_z \in \mathcal{M}_{\text{MDP}}$  reachable by  $a_{x,y}$  do
10:       $D'_{s_z} \leftarrow D'_{s_z} + D_{s_x} \text{Laplacian}(\pi(a_{x,y}|s_x)P(s_z|a_{x,y}, s_x))$ 
11:    end for
12:  end for
13:  for all states  $s_x \in \mathcal{M}_{\text{MDP}}$  do
14:     $D_{s_x} \leftarrow D'_{s_x}$ 
15:  end for
16: end while

```

图3. 使用拉普拉斯矩阵稳定期望状态访问频率计算的伪代码。

2.2. 轨迹生成

在解决 MaxEnt IRL 实现中的技术问题之后，我们利用所提取的奖励进行轨迹生成。一种直接的轨迹生成方法是类似马尔可夫链的过程：给定一个初始状态，从转移（概率）矩阵中迭代采样轨迹中的下一个位置，直到到达终止状态。我们假设居民每天都会回家，因此初始状态和终止状态都是居民的家庭建筑物。请注意，此处的初始状态和终止状态与第2.1.4节所讨论的不同。这里我们使用特定的状态，是为了生成一条在特定点开始并结束的唯一轨迹，从而对该过程进行重新情境化，而不是上文所讨论的用于学习的一般性定义。

这种返回家庭的假设会生成在到达终止状态之前访问建筑物数量不切实际的轨迹。施加“所有建筑物对每位居民只能访问一次”的限制只能部分解决该问题。为了彻底消除我们的顾虑，我们使用 Kaplan-Meier 估计量对轨迹数据集进行生存分析，该估计量估计轨迹中每一停靠点的生存概率，如图4所示。我们将生存概率视为轨迹生成的折扣因子。终止概率为 1 减去生存概率。在每一步中，我们将终止概率赋予智能体的家庭，并将生存概率均匀分配给其余建筑物。这组概率与相应的转移概率以及来自 IRL 的奖励相乘，从而得到用于采样的最终策略。由此，生成的轨迹具有与经验数据相似的长尾分布，范围从 2 到 25（我们将在第3.4节中进一步评估所生成轨迹的质量）。对于在实证数据集中，研究区之外的所有建筑物均被排除，长度为1的轨迹也被排除。最终得到6567条实证轨迹。




图4. 使用生存分析从经验轨迹数据集中提取的折扣因子。

为便于说明，我们在附录2（图A2）中提供了生成轨迹的示例。此处需要特别指出的是，这些轨迹在实证数据集中并没有明确的对应物，因为每条轨迹都是基于更新后的转移矩阵生成的，而与任何具体的实证记录无关。因此，对生成轨迹的评估必须通过比较数据集的特征来进行，正如我们在第3.4节中所做的那样。

3. 结果

本节中，我们在一系列结果上比较线性奖励模型与三种非线性机器学习奖励模型。最终，我们希望衡量不同机器学习模型在基于初始移动性数据与建筑物数据、复现研究区内城市居民总体（即平均）实证移动模式方面的相对成效。

3.1. 转移矩阵

我们使用图密度作为度量，用于量化图中边的数量相对于全连接图的比例。密度水平反映了网络中不同程度的连通性。在我们的研究区中，最高0.1%的密度水平会产生约700个连通分量，这些连通分量对应于由谱图分析导出的特征值数量，其中一些建筑物完全孤立。最高1%的密度水平会产生37个连通分量。超过该水平后，我们仅观察到一张连通图。我们尝试了一系列密度（0.1%、1%、10%、30%、50%、80%），在我们的情境中，不同密度产生了相似的输出。然而，密度越高，计算负荷越重。学习过程的结果可能高度依赖于转移矩阵的选择，所学到的策略最终会产生输入转移矩阵的一个修改版本。为评估该过程对这一选择的敏感性，我们实现了另一种简单的转移概率，即逆欧氏距离（IED），用它代替基于SGS的矩阵作为输入，从而产生不同的网络结构：

$$D_{\text{inverse}} = \frac{1}{D_{\text{normalized}}} \quad (2)$$

其中 $D_{\text{normalized}}$ 是 D 的行归一化版本， D 为建筑物之间的欧氏距离矩阵。

在图5（右图）中，连通性图显示耶路撒冷市中心区域的边缘存在若干离散的簇，而不是位于中心本身。基于SGS的转移矩阵优先考虑较大的建筑物和较短的距离（图5，左图），相比之下中心区域的建筑物拥有更多连接，因为较大的建筑面积体量抵消了相对较长的出行距离。使用SGS时所呈现的结构显得更为合理。它强调了现有的活动中心，从而支持使用该矩阵。

3.2. 奖励与转移矩阵

图6展示了基于SGS矩阵的线性与非线性变换在初始化时的奖励（左列）、最终奖励（中列），以及二者之间按建筑物计算的差异（右列）。它显示出线性奖励与MLP的变化极小。基于图的模型产生了非线性映射，高奖励集中在少数建筑物上，尽管不同神经网络架构之间的差异很小。

这种差异可以通过图7中的相关性图进一步说明，其中GCN与GraphConv的奖励与建筑物建筑面积。线性模型（Linear）与MLP的结果呈现出另一番图景，其中相关性不那么明显。当考察学习过程的最终输出，即体现于更新后转移矩阵中的策略时，这种相关性的含义便显现出来（图8）。与原始矩阵（图5（右图））相比，线性模型和MLP模型似乎只是使网络更加稠密，并未改变其基本结构，而几何深度学习模型则在小型建筑与建筑面积最丰富的建筑之间创建了多得多的直接连接。图7与图8的结果表明，基于图的深度学习模型能够识别给定转移矩阵中的潜在动力学，在本例中即凸显了建筑面积体量在决定吸引力方面的核心作用。由于建筑面积最丰富的建筑通常被认为更具吸引力，因为它们能提供更多（商业）机会，这为基于图的方法在生成真实结果方面的成功提供了一个积极迹象。




图5. 基于IED转移矩阵（右图）与SGS（左图）的连通性图。表示建筑物的节点按土地利用着色，边的宽度表示矩阵元素值。为便于说明，仅显示前0.5%的边。




图6. 使用简单重力转移矩阵的Linear、MLP、GCN与GraphConv模型的空间奖励模式。颜色越暖，表示标准化奖励越高，或变化越为正向。为便于更好地可视化，GCN与GraphConv的最大奖励被人工重新缩放至0.8。为避免杂乱，我们未通过图例给出精确数值，且所有数值均标准化为0到1之间。




图7. 使用简单重力得分（SGS）转移矩阵时，四个奖励模型中建筑面积与相应建筑奖励的相关图。




图8. 四个奖励模型所得出的策略，即更新后的转移矩阵。

相比之下，当底层转移矩阵为 IED 时，GCN 与 GraphConv 模型似乎凸显了中心区域的大量建筑，却将外围建筑置于次要地位（图9）。有趣的是，封闭的位于耶路撒冷市中心的市場（Mahane Yehuda）——即建筑面积最大的那栋建筑——所获得的奖励低于 SGS 情景下的奖励（图10）。因此，GCN 再次展现了其识别底层转移矩阵动力学的能力。在 IED 转移矩阵下，奖励与入度连通性之间的关联（ $r = 0.57$ ；图10）反映了

IED 对与邻近建筑距离较近的建筑（这是市中心的特征）的优先考虑。与 SGS 情形一样，尽管 MLP 的参数数量与 GCN 相同，但其得到的最终奖励分布与之相似。




图9. 使用 IED 转移矩阵时，Linear、MLP、GCN 与 GraphConv 模型的空间奖励格局。颜色越暖，表示标准化奖励越高，或变化越趋于正向。

3.3. 轨迹生成、初始状态与终止状态

如上文（第2.2节）所述，轨迹是通过从转移矩阵中采样生成的，直至选中一栋被定义为终止状态的建筑为止。在缺乏评估轨迹的黄金标准的情况下，我们在各学习模型之间进行比较，包括“未训练”的原始矩阵，并采用一系列性能指标，将其与经验轨迹进行比较。我们计算诸如跳跃（即路段距离）分布和流量相似性等常见的移动性指标，其中使用通勤者共同部分（CPC）测度。对于第一个指标，以及轨迹总距离、访问的建筑数量和凸包面积，均使用分布之间的 Wasserstein 距离来评估其与经验轨迹的相似性。CPC 本质上是一种比较性测度。由于经验轨迹与生成轨迹在范围上存在差异——前者覆盖整个城市，而后者仅覆盖建筑的一个子集——因此 CPC 是基于土地利用类型之间的流量（例如从居住到居住、从居住到商业等流量）计算的。我们特意给出逆 CPC（即 $1 - \text{CPC}$ ，其最大值为 1.0），以使表1中的所有指标方向一致，且较低的

CPC 优于较高的 CPC。




图10. 使用逆欧氏距离 (IED) 转移矩阵时, Linear、MLP、GCN 与 GraphConv 的入度与相应建筑奖励的相关图。

CPC 结果对底层的类别构成敏感 (Lenormand et al. 2016), 这意味着结果取决于土地利用的初始构成。由于整座城市与研究区的土地利用构成不同, 我们定义了一种替代度量——归一化流量指标 (NFM)。NFM 的推导方法是用某一给定土地利用组合的观测相对流量 (占比) 除以该组合在随机过程下的期望占比 (式 (3))。为评估经验轨迹与生成轨迹之间的相似性, 我们使用所有起点—终点组合上 NFM 值的均方根误差 (RMSE)。

$$NFM_{ij} = \%F_{ij} / (\%LU_i \cdot \%LU_j) \quad (3)$$

其中 NFM_{ij} 是土地利用 i 与土地利用 j 之间的归一化流量指标, $\%F_{ij}$ 是在 i 中起始并在 j 中结束的轨迹段占有所有轨迹段的比重, $\%LU_m$ 是土地利用为 m 的建筑物占数据集中所有建筑物的比重。

我们最初将终止状态设为与起点相同, 即智能体的家。这表明, 在大多数数量上 GCN 都能得到最相似的分布, 紧随其后的是 GraphConv (表1, 配置1)。偏离这一趋势的三个度量——轨迹长度 (停留点数量)、CPC 和 NFM——则表明未训练的模型更优。然而, 尽管 CPC 在 GCN 与未训练模型之间表现出较大差异, 但在 NFM 上这一差异变得极小。有趣的是, GraphConv 在 NFM 方面的表现要差得多。需要注意的是, NFM 与 CPC 都与土地利用之间的转移有关, 这意味着几何深度学习模型在重现轨迹特征 (长度和面积) 方面比在重现语义 (土地利用) 方面表现更好。当终止状态与初始状态相同时, 与经验轨迹相比, 这往往会生成覆盖面积和距离更小、且由更短路段构成的轨迹。该配置还会遇到智能体无法到达初始状态的边界情形, 此时我们会重置过程并重新抽取轨迹起点。为解决这些问题, 我们探究了另外两种配置。在第一种配置中, 所有居住和混合用途建筑都被定义为终止状态。这解决了边界情形的问题, 并改善了与轨迹长度相关的表现 (表1, 配置2)。即使未训练模型在 CPC 上仍然表现最佳, CPC 和 NFM 方面的差异也变得极小。然而, 该配置在若干度量上表现更差, 因此我们定义

了第三种配置：随机选取居住 / 混合用途建筑之一作为终止状态，以期提高轨迹覆盖更大范围的概率。这确实改善了某些度量的表现（表1，配置3），但边界情形的问题再次出现。这要求我们在重置过程时同时重新抽取起点和终止状态，因此 NFM 问题再次出现也就不足为奇了。

表1. 在三种终止状态配置下，针对四种奖励模型和一个未训练转移矩阵所生成轨迹的度量指标。

配置	模型	总轨迹 距离 (对数)	平均路段 距离 (对数)	轨迹 长度	凸包面积 (对数)	逆 CPC	NFM (RMSE)
1	未训练	2.43	2.19	1.69	4.39	0.21	13.84
	线性	2.36	2.12	1.80	4.24	0.28	17.04
	MLP	2.38	2.09	1.81	4.18	0.30	18.32
	GCN	1.98	1.74	2.47	3.53	0.44	15.91
	GraphConv	2.13	1.88	2.09	3.79	0.38	27.65
2	未训练	3.21	0.62	2.28	5.81	0.46	22.15
	线性	3.10	0.88	2.28	5.63	0.46	22.01
	MLP	3.12	0.90	2.28	5.68	0.46	20.96
	GCN	2.72	0.56	2.27	4.91	0.49	22.44
	GraphConv	2.89	0.69	2.28	5.21	0.47	21.43
3	未训练	1.94	1.74	4.72	3.19	0.40	16.42
	线性	1.86	1.67	4.72	3.06	0.40	26.09
	MLP	1.82	1.63	4.71	2.97	0.39	26.68
	GCN	1.50	1.31	4.83	2.34	0.44	21.33
	GraphConv	1.61	1.41	4.85	2.54	0.41	29.90

3.4. 城市结构实验

迄今为止的实验都假设城市结构恒定、建筑物数量不变。在本节中，我们在不重新训练奖励模型的前提下，通过三个假设情景考察所提出的轨迹生成方法在城市结构发生适度变化时的表现。其动机来自上文的结果：这些结果表明，尽管改变配置能够改善结果，但生成轨迹与经验模式之间仍然存在差异。这或许可以用训练阶段与实施阶段之间的空间不一致来解释：前者涉及整座城市，而后者涉及一个小型案例研究区。使用大规模建筑物集合训练模型，往往会因增大 SGS 的分母而抹平距离效应，从而增大出行距离。相反，使用建筑物的小型子集则会增强距离效应，因而促使产生更短的移动路段。

我们通过减少建筑物数量来检验这一解释的有效性。该操作进行两次：首先系统性地移除区域边缘的建筑物，然后以随机移除的方式重复该过程。这应当会减小 SGS 的分母，从而增大与经验模式之间的差异。在第一种情形下，由于研究区的空间范围被裁剪，距离预计会发挥更大的作用。相对于随机移除情景（其中建筑物之间新形成的空隙会促使人们出行更长的距离），这预计会导致差异出现更大幅度的增大。我们的第三个实验采取了不同的思路，通过操纵建筑的建筑面积（体量）来改变城市结构，以考察奖励模型面对新输入时的推断响应，这可能会在城市规划中带来许多有趣的应用。具体而言，我们选取四栋建筑面积处于中低水平的外围商业建筑，将其原始建筑面积值提高到 10000（即跻身前 10 栋最大建筑面积建筑之列）。这意味着将它们归入建筑面积充裕的类别，其建筑面积特征值为 1.0。由于外围区位应当变得更具吸引力，该实验预计也会增大出行距离。

为简洁起见，此处我们只呈现与一种终止状态配置（智能体的家，对应表1中的配置1）相对应的结果。该结果可与附录3 - 5中提供的其余配置的结果、以及各测试情景相应的补充连通性图进行比较。

我们的第一项测试包括通过排除研究区边缘约 40% 的建筑物（剩余 599 栋建筑物）来压缩研究区（图11）。为评估奖励对城市结构变化的鲁棒性，所选建筑物的学习奖励保持不变，仅对转移矩阵按行重新归一化。有趣的是，结果显示除 CPC 和 NFM 之外，所有模型、所有度量的相似性都略有下降。GCN 在大多数数量上表现最佳的总体趋势得到再次印证，甚至延伸到 NFM：GCN 在此表现最好，GraphConv 的表现也有所提升。这些发现表明，通过裁剪研究区来排除建筑物并不会改变由城市中心建筑物所主导的城市结构。该情景下生成的连通性图（图A3，附录3）支持这一论断。这表明移动性动态并不受研究区边界的约束。在城市结构方面具有充分相似性的前提下，对选定区域得到的结果可能代表大尺度的研究区。



图11. 研究区压缩情景（左）与随机移除情景（中）中被排除（灰色）和使用的（红色）建筑物。对于建筑编辑情景（右），红色建筑物在建筑面积方面经过编辑。

表2. 在三个实验中，针对四种奖励模型和一个未训练转移矩阵所生成轨迹的度量指标。

实验	模型	总轨迹 距离 (对数)	平均轨迹路段 距离 (对数)	轨迹长度 (建筑数)	凸包面积 (对数)	逆 CPC (建筑类型)	NFM (RMSE)
边界 收缩	未训练	2.67	2.43	1.52	4.83	0.18	18.96
	线性	2.52	2.28	1.77	4.55	0.20	16.73
	MLP	2.51	2.27	1.85	4.53	0.20	16.10
	GCN	1.90	1.65	3.44	3.38	0.34	15.71
	GraphConv	2.15	1.91	2.69	3.85	0.30	17.26
随机 移除	未训练	1.01	0.78	1.71	1.80	0.24	20.45
	线性	0.97	0.74	1.78	1.75	0.21	18.39
	MLP	1.02	0.78	1.60	1.78	0.19	17.40
	GCN	0.98	0.76	1.56	1.73	0.18	19.13
	GraphConv	1.03	0.80	1.53	1.80	0.19	17.43
建筑 编辑	未训练	2.43	2.19	1.67	4.39	0.22	15.24
	线性	2.32	2.10	1.89	4.18	0.32	20.68
	MLP	2.34	2.10	1.91	4.22	0.32	19.59
	GCN	1.91	1.67	2.51	3.41	0.45	10.90
	GraphConv	2.03	1.79	2.27	3.62	0.42	13.01

第二个实验通过随机移除研究区内约 30% 的建筑（剩余 709 栋建筑）来补充第一个实验，其效果类似于地震等灾难性事件（图11）。与之前一样，我们不重新训练模型，而是使用基于先前学习到的奖励而重新归一化的转移矩阵。该情景在所有指标上都

显示出相似性的提高（表2）。与上一个实验相比出现了一个显著差异：四个模型在性能上如今似乎几乎难以区分。连通性图（图A4，附录4）提供了一些解释。建筑被排除后形成的空隙导致整个区域内的出行距离增加，这意味着建筑面积充足的区域变得更具有吸引力。换言之，排除建筑并未改变该区域的基本结构（即没有出现新的中心），但可达性

与动态发生了变化。这种变化导致模型结果的同质化，表明在存在强烈失配的情况下，基于先前转移概率学习到的奖励无法抵消新的动态。尽管这些结果因显示出相似性的提高而有悖于我们的预期，但它们实际上支持了我们的一般直觉：随着出行距离的增加，生成的轨迹会与其经验对应轨迹趋于一致。

第三个实验有选择地提高所选外围建筑的建筑面积体量，以将其一举推入前 10 个最大建筑面积单元之列，其结果与第一个实验非常相似（表2），但 NFM 的结果除外。这意味着，即使是可能模拟新商业中心建立的适度干预，也不足以抵消既有城市结构的影响。连通性图（图A5.1，附录5）确实显示出一些变化，尤其是对 GCN 和 GraphConv 模型而言，被编辑的建筑成为局部焦点，但它们并未成为可替代城市结构中原有焦点的锚点。这与被编辑建筑奖励的变化有关，而这种变化在不同模型之间并不一致。对于所有四个模型而言，建筑面积体量与奖励之间都不存在直接对应关系（图A5.2，附录5）。

值得注意的是，各模型相对于原始（无实验）奖励表现出不同的奖励动态（图A5.3，附录5）。虽然该干预在线性模型和 MLP 模型下导致奖励出现简单的线性（或准线性）偏移，且对所有其他建筑几乎没有或完全没有变化，但在 GraphConv 和 GCN 模型下则出现了更复杂的模式。在 GraphConv 下，除最具吸引力的建筑（位于市中心的有顶市场）之外，所有大型建筑的奖励都下降了，这表明其影响遍及整个区域。然而，GCN 模型导致的结果确定性较低，一些建筑的奖励增加，另一些则减少。有趣的是，在被编辑的建筑中，原始奖励最低的那栋建筑增幅最大。这些都指向独特的局部动态，并且与 GraphConv 的结果相比，这种效应是局部的。

所呈现的总体趋势表明 CPC 和 NFM 值有所改善，尤其是在随机移除和建筑编辑情景下 CPC 的改善，以及几何深度学习模型（尤其是 GraphConv）在 NFM 上的改善。这一发现表明，对城市结构进行有意义的改变，会提高土地利用之间转移相对于全市经验模式的相似性。它支持了这样一种观点：案例研究区的底层结构与全市结构不同。此类差异体现为轨迹特征方面的一致，例如总长度和路段长度。

3.5. 敏感性检验——特征矩阵定义与模型参数

这些实验探讨了不同模型对城市结构变化的敏感性。实验2和实验3也可以被解释为对可能的现实世界情景的模拟。这使人担忧结果可能还对其他因素敏感。我们通过改变生成特征矩阵的多维聚类过程所使用的阈值，并通过改变训练模型的参数来对此进行探究。

对于第一项干预，我们运行了四项检验：（a）将“高”建筑面积类别的阈值降至 1,000；（b）将“中”和“高”建筑面积类别的阈值分别提高到 500 和 1,000；（c）将所有家庭收入阈值降低 5,000NIS（新以色列谢克尔）；（d）将“低”、“中”和“高”收入阈值分别降至 15,000NIS、18,500NIS 和 23,000NIS。检验（a）和（b）干预的是物理特征而非社会特征，因而与（c）和（d）形成对照。检验（a）和（c）都扩展了较高值的类别，而检验（b）扩展了较低值的类别，检验（d）则将分布推向两侧的极端值。我们在此仅满足于在附录中呈现奖励相对于原始模型所产生奖励的变

化（原始特征矩阵，无实验；图A6.1，附录6）。这些结果表明，几何深度学习模型在不同配置下都能产生稳定的结果，GraphConv 的相关系数范围为 0.84 至 0.86，GCN 为 0.92 至 0.95。这与线性模型（0.62 - 0.65）和 MLP 模型（0.66 - 0.73）的敏感性形成对比。检验（a）似乎产生了最大的影响，主要是对后两个模型而言，因为（b）至（d）的结果相似。考虑到大型建筑在转移矩阵中的核心作用，这似乎是一个合理的结果。

第二项干预包含两个额外的检验：将每层神经元数从 32 改为 256（意味着 MLP、GCN 和 GraphConv 的参数数量分别增加到 69,889、69,889、138,241）；将隐藏层数从 1 改为 3，同时保持神经元数为 32，使得 MLP、GCN 和 GraphConv 模型的参数数量分别为 3,089、3089 和 7,233。结果（图A6.2，附录6）再次表明 GCN 和 GraphConv 模型相当稳定。当网络更宽（参数更多）时，这些模型收敛得更快，但训练损失仍保持相近，表明它们找到的是相同的最优解。其主要影响是较大建筑与较小建筑之间的分离更加明显。对于 MLP 模型，尽管训练损失更低，但几乎所有建筑的奖励都下降了。在使用更深的网络（更多层）时，GCN 和 GraphConv 模型达到相同的最优解，产生几乎相同的结果，而 MLP 则落在不同的次优解上。

综合来看，这些敏感性检验的结果表明，借助转移矩阵获得几何标识是有用的。它们引入了一种归纳偏置，从而缩小了搜索空间，并引导模型走向最简约的解。

4. 讨论

上述结果表明，由图神经网络生成的奖励有效地捕捉了潜在的动态，并且与线性模型相比，其与建筑面积的相关性更强。这强化了核心建筑转移概率的影响。我们针对基于所学策略的轨迹生成，尝试了若干初始状态与终止状态的设置，结果表明其对网络结构（例如边界情形问题）具有敏感性。对城市结构进行操控的类似实验，则指向建成环境的非弹性。

鉴于目前尚不存在能够涵盖轨迹真实性所有方面的、被普遍接受的基准，我们提出基于性能指标来评估轨迹的聚合属性，而不是强调个体相似性。结果表明，使用图神经网络作为奖励函数会在评价指标上带来改进。尽管这些改进并非在所有指标上都一致，例如空间结构（长度和面积）方面的改进大于土地利用方面，但总体而言，轨迹的真实性得到了提升。

尽管我们的结果并未完全复现经验模式，但我们认为这是由案例研究的性质所致，而非我们方法本身造成的假象。通过移除边缘建筑或随机选择的建筑来操控案例研究所得到的结果，似乎削弱了这一假设。然而，探究结果背后的动态可以看出，随机移除情景下所表现出的更高相似性，与建筑曾经所在之处形成的空隙所导致的出行距离增加有关。这与各模型结果之间的同质化相伴随，指向城市结构的主导性影响，而这种影响预计会随着出行距离的增加而增强。

在此基础上，使用转移矩阵来引导轨迹生成似乎会鼓励短距离出行。同样清楚的是，将涉及整个城市的经验数据集用作可达性空间，同时基于建筑的一个子集来生成轨迹，会因潜在移动模式的失配而影响结果。我们关于排除建筑的实验，是考察这一尺度问题的第一步。这项工作值得在未来进一步关注。实验表明，为更大的区域生成轨迹，或通过使用不同的距离矩阵（例如出行时长）来压缩空间，可能会改善结果。

然而，这些结果还支持一个关于模型选择的、令人意外的洞见。尽管使用图神经网络降低了对特征矩阵定义的敏感性，并且由于归纳偏置将转移概率直接纳入学习过程，从而在预测精度上持续带来更多改进，但这一优势仅在转移概率矩阵被正确设定时才

成立。我们的结果表明，当空间结构的变化所施加的影响足够强时，GNN 相对于更简单模型的效用会大幅降低，除非使用更新后的转移动态对模型重新训练。我们的结果表明，对于具有温和且一般化移动假设的案例研究，后者可能更为高效。

空间结构效应可以通过控制转移矩阵的密度来缓解。然而，我们当前基于距离的启发式方法倾向于偏好距离较短的建筑，除非其被建筑面积所压倒。当前使用分位数控制密度的方法本质上是线性的，这会鼓励要么全局短距离、要么全局长距离。在未来的工作中，诸如用于降低噪声的高斯滤波器之类的非线性滤波器，或鼓励局部最大距离的滤波器，可能是复现经验移动模式的更好选择。另一个有前景的未来方向是推导不同的转移启发式方法，例如上文提到的出行时长，或者使用机器学习和数值方法来学习和优化转移矩阵。

除转移矩阵之外，城市结构、终止状态的配置、折扣因子和奖励剖面等其他因素，也会影响所生成轨迹的真实性。这体现在轨迹指标和连通性图上。这些因素按影响强度递减的顺序排列。城市结构会影响转移矩阵的变化，并且在某些变化下，其影响可以超过终止状态配置的影响。折扣因子的主导性弱于终止状态的配置，否则所生成轨迹中的建筑数量在所有配置下都将相同。奖励的影响在很大程度上是局部的，并且在微观尺度上对移动模式进行微调之后，最能体现在连通性图中。

5. 结论

本文旨在通过提出一个利用 IRL 算法、在不完整经验数据下生成真实地理空间轨迹的框架，来弥合轨迹生成领域理论研究进展与实际应用场景之间的差距。为了增强我们有限的移动数据，我们通过多维聚类进行信息传播，以缓解移动数据集中的数据稀缺问题。我们使用图神经网络作为奖励函数近似器，以利用由转移矩阵所刻画的潜在地理空间网络结构，从而获得更好的收敛性和更具可解释性的建筑奖励。通过这种方式，我们从结果在很大程度上由特征矩阵决定的经典机器学习方法，转向了各种非线性替代方案，这些方案要么从数据中的全局模式学习（例如 MLP 模型），要么从局部特征学习（例如 GCN 模型）。后者尤其值得关注，因为它凸显了从环境中学习的重要性：智能体通过邻接矩阵以及图的拓扑结构从邻居那里收集信息。我们在建筑网络的真实世界场景中对此进行了说明，而不是使用假设的网格型世界。

我们的结果表明，由图神经网络生成的奖励能够有效捕捉潜在的动态，并且与线性模型对应方法相比，其与建筑面积的相关性更强。这强化了核心建筑转移概率的影响。我们还尝试了若干初始状态与终止状态的设置，以基于学习到的策略生成轨迹。鉴于轨迹生成尚缺乏被普遍接受的基准框架，我们提出基于性能指标来评估轨迹的聚合属性，而非强调个体层面的相似性。结果表明，将图神经网络用作奖励函数确实能够提升轨迹的真实性，但仍有进一步改进的空间。

未来在生成合理出行行为方面的工作，不仅需要从图拓扑、空间结构和城市网络中学习，还需要从城市的社会经济结构中学习。我们在建筑层面对结果的初步考察表明，城市中不同的人口群体与不同的奖励水平相关。例如，我们发现耶路撒冷与极端正统派（Ultra-Orthodox）社区相关的建筑始终产生更多的奖励。这表明，我们的轨迹生成方法最终能够带来更高程度的社会经济精细化，并最终形成一种更加以人为本的城市模拟方法。这仍是一片尚未开拓的领域，在生成有意义的城市空间行为模式时需要将其纳入考量。

致谢

本研究得到了泽尔曼·科恩倡议 (Zelman Cowen Initiatives) 资助以及以色列创新、科学与技术部 (Israeli Ministry of Innovation, Science, and Technology) 通过阿基米德中心 (Archimedes Center) 提供的资助支持。我们感谢三位匿名审稿人和编辑提出的宝贵意见。我们还要感谢 Shan Zhao 富有成效的讨论, 这些讨论帮助塑造了本项工作。

作者贡献

CRedit: Zi Hen Lin: 概念化 (Conceptualization)、数据管理 (Data curation)、形式分析 (Formal analysis)、调查研究 (Investigation)、方法论 (Methodology)、软件 (Software)、验证 (Validation)、可视化 (Visualization)、撰写初稿 (Writing - original draft)、审阅与编辑 (Writing - review & editing); A. Yair Grinberger: 概念化 (Conceptualization)、数据管理 (Data curation)、形式分析 (Formal analysis)、经费获取 (Funding acquisition)、调查研究 (Investigation)、方法论 (Methodology)、项目管理 (Project administration)、软件 (Software)、监督指导 (Supervision)、验证 (Validation)、可视化 (Visualization)、撰写初稿 (Writing - original draft)、审阅与编辑 (Writing - review & editing); Daniel Felsenstein: 概念化 (Conceptualization)、经费获取 (Funding acquisition)、调查研究 (Investigation)、方法论 (Methodology)、项目管理 (Project administration)、资源 (Resources)、监督指导 (Supervision)、撰写初稿 (Writing - original draft)、审阅与编辑 (Writing - review & editing)。

人工智能使用声明

在本稿的撰写过程中, 我们偶尔使用 ChatGPT (GPT-4o) 协助进行语言润色并提升表达的清晰度。

利益冲突声明

作者未报告存在潜在的利益冲突。

作者简介

Zi Hen Lin 是慕尼黑工业大学 (Technical University of Munich) 信息学方向的博士研究生。他的研究聚焦于面向模拟的机器学习、科学计算与传染病预测, 尤其关注与 COVID-19 相关的智能体建模和城市扩散。

A. Yair Grinberger 是耶路撒冷希伯来大学 (The Hebrew University of Jerusalem) 地理系的高级讲师。他的研究兴趣包括地理信息科学、志愿者地理信息、出行分析、城市建模, 以及从地理数据中提取文化知识。

Daniel Felsenstein 是耶路撒冷希伯来大学 (The Hebrew University of Jerusalem) 地理学教授。他的研究聚焦于经济地理学、区域科学、空间计量经济学、模拟建模、城市韧性、住房市场, 以及为以色列构建空间一般均衡模型。

ORCID

Daniel Felsenstein <http://orcid.org/0000-0003-0682-672X>

数据与代码可用性声明

支持本研究所报告实现的数据与代码可在 <https://doi.org/10.6084/m9.figshare.29554394> 获取。

参考文献

- Arora, S., and Doshi, P., 2021. A survey of inverse reinforcement learning: Challenges, methods and progress. **Artificial Intelligence**, 297, 103500.
- Barnes, M., et al., 2023. Massively scalable inverse reinforcement learning in Google Maps. **arXiv Preprint arXiv**, 2305.11290 2023.
<https://doi.org/10.48550/arXiv.2305.11290>
- Chen, X., and Zhan, F.B., 2008. Agent-based modeling and simulation of urban evacuation: relative effectiveness of simultaneous and staged evacuation strategies. **Journal of the Operational Research Society**, 59 (1), 25–33.
- Cornacchia, G., and Pappalardo, L., 2021. A mechanistic data-driven approach to synthesize human mobility considering the spatial, temporal, and social dimensions together. **ISPRS International Journal of Geo-Information**, 10 (9), 599.
- Dawson, R.J., Peppe, R., and Wang, M., 2011. An agent-based model for risk-based flood incident management. **Natural Hazards**, 59 (1), 167–189.
- Goodchild, M.F., Aubrecht, C., and Bhaduri, B., 2017. New questions and a changing focus in advanced VGI research. **Transactions in GIS**, 21 (2), 189–190.
- Grinberger, A.Y., and Shoval, N., 2015. A temporal-contextual analysis of urban dynamics using location-based data. **International Journal of Geographical Information Science**, 29 (11), 1969–1987.
- Kong, X., et al., 2023. Mobility trajectory generation: a survey. **Artificial Intelligence Review**, 56 (S3), 3057–3098.
- Kwak, G.H., Ling, L., and Hui, P., 2021. Deep reinforcement learning approaches for global public health strategies for COVID-19 pandemic. **PLoS One**, 16 (5), e0251550.
- Lenormand, M., Bassolas, A., and Ramasco, J.J., 2016. Systematic comparison of trip distribution laws and models. **Journal of Transport Geography**, 51, 158–169.
- Lin, Z., Grinberger, A.Y., and Felsenstein, D., 2025. Simulating Covid-19 Contagion Patterns using a Machine Learning-Augmented Agent Based Model, in Broitman D, Kopczewska K, and Czamanski D (eds) **Handbook on Big Data, Artificial Intelligence and Cities** (pp. 327–348), Edward Elgar, Cheltenham, UK.
- Lu, Y., and Giuliano, G., 2023. Understanding mobility change in response to COVID-19: A Los Angeles case study. **Travel Behaviour & Society**, 31, 189–201.
<https://doi.org/10.1016/j.tbs.2022.11.011>
- Ng, A.Y., 2000. Algorithms for Inverse Reinforcement Learning. In **Proceedings of the 17th International Conference on Machine Learning**, 663–670.
- Oda, T., 2021. Equilibrium inverse reinforcement learning for ride-hailing vehicle network. In **Proceedings of the Web Conference 2021**, pages 2281–2290.

- Oshan, T.M., 2021. The spatial structure debate in spatial interaction modeling: 50 years on. *Progress in Human Geography*, 45 (5), 925–950.
- de Palma, A., and Lindsey, R., 2011. Traffic Congestion Pricing Methodologies and technologies. *Transportation Research Part C: Emerging Technologies*, 19 (6), 1377–1399.
- Pappalardo, L., Rinzivillo, S., and Simini, F., 2016. Human mobility modelling: exploration and preferential return meet the gravity model. *Procedia Computer Science*, 83, 934–939.
- Safarzadeh, R., and Wang, X., 2024. Map matching on low sampling rate trajectories through deep inverse reinforcement learning and multi-intention modeling. *International Journal of Geographical Information Science*, 38 (12), 2648–2683.
- Schneider, M., et al., 2026. Generating semantically enriched mobility data from travel diaries. In Chrysanthi P K, Nørvåg K, Stefanidis K, and Zhang Z (eds) *Advances in Databases and Information Systems* (pp. 181–197), Springer, Cham.
- Si a-Nowicka, K., et al., 2016. Analysis of human mobility patterns from GPS trajectories and contextual information. *International Journal of Geographical Information Science*, 30 (5), 881–906.
- Song, C., et al., 2010. Modeling the scaling properties of human mobility. *Nature Physics*, 6 (10), 818–823.
- Snowwell, A.J., Singh, S.P.N., and Ye, N., 2020. Revisiting maximum entropy inverse reinforcement learning: new perspectives and algorithms. In *2020 IEEE Symposium Series on Computational Intelligence (SSCI)*, pages 241–249.
- Sutskever, I., 2014. Sequence to Sequence Learning with Neural Networks. *arXiv Preprint arXiv*, 1409–3215.
- Toger, M., et al., 2021. Mobility during the COVID-19 pandemic: a data-driven time-geographic analysis of health-induced mobility changes. *Sustainability*, 13 (7), 4027.
- Vaswani, A., et al., 2017. Attention is all you need. In: I. Guyon, eds. *Advances in neural information processing systems*. Vol. 30. Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf
- Wang, G., et al., 2023a. Inverse reinforcement learning with graph neural networks for full-dimensional task offloading in edge computing. *IEEE Transactions on Mobile Computing*, 23 (6), 6490–6507.
- Wang, G., et al., 2023b. Inverse reinforcement learning with graph neural networks for IoT resource allocation. In *ICASSP 2023–2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 1–5. IEEE.
- Wulfmeier, M., Ondruska, P., and Posner, I., 2015. Maximum entropy deep inverse reinforcement learning. *arXiv Preprint, arXiv:1507.04888*. <https://doi.org/10.48550/arXiv.1507.04888>
- Zhang, G., and Zhu, A.-X., 2018. The Representativeness and Spatial Bias of Volunteered Geographic Information: A Review. *Annals of GIS*, 24 (3), 151–162.
- Ziebart, B.D., et al., 2008. Maximum Entropy Inverse Reinforcement Learning, in *Proceedings of The Twenty-third AAAI Conference on Artificial Intelligence*, 1433–1438
- Ziebart, B.D., 2010. *Modeling interaction via the principle of maximum causal entropy*. PhD thesis, Carnegie Mellon University.